

利用微陣列基因表現資料分析癌症相關基因之研究

沈詩珊¹ 石貴中¹ 梁綺雯¹ 劉峰銘¹ 陳榮銘^{2*} 張建國³ 蔡進發¹ 施河^{1,2}

¹ 臺中健康暨管理學院生物資訊研究所

² 臺中健康暨管理學院資訊與設計學系

³ 中國醫藥大學附設醫院

*E-mail: rmchen@thmu.edu.tw

摘要

癌症的形成是多步驟性的，其中包括致癌基因的過度活化、抑癌基因的不活化、DNA 修補基因以及其他相關因子的突變，造成細胞生長、分化、繁殖及死亡過程產生改變。而其中又以致癌基因的過度表現在許多癌症發生的起始階段扮演了非常重要的角色。此外，抑癌基因是可抑制致癌症的發生，如果抑癌基因的正常功能喪失，就會增加癌症的發生率。目前有許多抑癌基因已被鑑定出來，但致癌基因只是冰山一角，因此等待我們去研究。在人類基因中尋找導致基因突變的原因是很難的，尤其是使用傳統的分析方法。而目前不同癌細胞中各種基因表現量的變化已可利用 cDNA Microarray 進行分析。這方面的研究，在過去已累積了相當多的資料。本研究收集分析這些 Microarray 的資料，運用統計的方法進行差異基因的搜尋與篩選，來尋找與癌症有關的基因，如此能縮小基因實驗的範圍，確定實驗的方向，避免一些不必要的實驗，以便協助生物學家更快地找出與癌症相關的基因。

1 前言

癌症是一種很複雜且是家族性的疾病。從分子生物學的觀點來看，癌症是由不正常的基因表現所造成的基因疾病，而基因表現的交綜複雜可說是與 DNA 不穩定有直接的關係[1]-[5]。癌症的形成是多步驟性的，包括致癌基因的過度活化、抑癌基因的不活化、DNA 修補基因以及其他相關因子的突變，造成細胞生長、分化、繁殖及死亡過程產生改變。而其中又以致癌基因的過度表現在許多癌症發生的起始階段扮演了非常重要的角色。此外，因為抑癌基因可抑制致癌基因的生長，如果抑癌基因的功能喪失，就會增加癌症腫瘤的發生。有許多抑癌基因已被鑑定出來[6]-[7]，但致癌基因的研究只是冰山一角，因此等待我們去研究[8]-[12]。在人類基因中來尋找導致基因突變是很難的，尤其是使用傳統的分析方法，一次只針對一個或少數基因研究，對大部分未知功能的人類基因而言，這似乎是一條遙遠而崎嶇的長路。基因為一切生命現象的基礎，回顧過去幾十年來應用於篩選差異表現基因的方法，例如免疫篩選法 (immuno-screening)、刪減篩選法 (subtractive screening)、差異性篩選法 (differential screening)、演化保存區域篩選法 (conserve region between species or gene

family)、蛋白質序列推衍法 (oligonucleotide probe derived from protein sequence) 及差異性顯示法 (differential display) 等[13]-[19]。這些方法或可單獨進行或可結合其他實驗步驟以使篩選基因更加有效率，但仍須耗費大量人力、物力及時間，實驗結果亦往往得到偽陽性訊號(false positive)，而無法以行更進一步的實驗。在監測(monitors)基因表現上，傳統的方式是以北方墨點雜交法，一次一個或少數個基因來進行實驗。對於多基因參與的生化過程或基因網路而言，則需花費相當長的時間才可能完成，或甚至無法進行。而現在有一些高科技的發展，研究人員可透過生物資訊的方法，一次可同時分析很多的基因。因此若能夠運用生物資訊的技術來分析與癌症相關基因的研究，那就能鎖定實驗的方向，也就是降低搜尋空間，以便協助生物學家更快地找出癌症相關的基因。

2 方法

基因晶片之所以能成為本世紀最受矚目的功能基因研究工具之一，乃其具有 (1) 大量樣本；(2) 同時進行；(3) 自動化分析等三項特點及 (1) 基因定量；(2) 差異基因搜尋兩項基本特質，交互運用而衍生出許多應用，不僅於生物醫學上，在微生物及植物界也同樣具有廣大的應用範圍，本研究是針對差異表現基因來做篩選。


2.1 資料前置處理

Microarray 可提供成千上萬個基因同時進行分析工作，進而產生相當龐大的基因表現資料。但是在眾多的基因表現資料當中，有可能因為人為或環境的因素造成資料的誤差、不正確性。所以在進行 Microarray 差異性基因表現資料的分析前，必須對資料做前置篩選動作，資料前處理流程如圖一所示。過濾掉不正確的資料，以確立資料的正確性，並將多筆 Microarray 基因表現資料表合併成單一資料表，以方便進行分析。以下是我們所做的資料前置處理步驟說明。

- (1) 從 Stanford Genomic Resources 網站中的 Stanford Microarray Database 中收集肝癌的 Microarray Raw Data (<http://genome-www.stanford.edu/>)，在此研究中

我們分別取得 HCC (hepatocellular carcinoma) 組織與正常組織的所有檢體樣本的原始資料。

- (2) 刪除所有檢體資料內的無效資料樣本。在基因表現資料裡面，無基因表現度和無基因名稱的欄位並無法幫助我們進行分析。而且這些是最容易發生錯誤的資料，在一開始便可以將這些資料進行刪除動作。
- (3) 建立新合併資料表的目的是將眾多基因表現資料表合而為一，以便分析基因表現的差異度。在一開始只先建立幾項基本固定欄位(NAME、Clone ID、Gene Symbol、Gene Name、Cluster ID、Accession)，這些欄位是固定欄位，並不會做變更或新增的動作。在基本欄位建立後，才會插入每個檢體樣本資料表的基因表現度欄位。
- (4) 由於在 Microarray 實驗過程中，經常將同一基因的表現度做數次的實驗，因此同一基因產生多個基因表現值。然而，同一基因的表現度有高有低、有正有負。因此必須做第二次的資料篩檢動作。在單一檢體樣本的 Microarray 中，同一基因會有正負兩種表現值存在時，我們並不能判斷該基因表現度是過度或不足表現，理論上兩種表現值中只有一種為正確表現值，所以這種情況我們必須放棄該基因的表現值資料。在基因表現都是相同的極性時，因為表現度的值有高低。所以我們將該基因表現資料做平均動作，取平均值作為參考值。
- (5) 匯入合併資料庫。在取得平均後的基因表現度資料後，我們以 Gene Symbol 為 y 軸座標、以基因表現度欄位為 x 軸座標，將該值填入欄位內，經過此處理後會產生癌症組織與正常組織兩個資料庫。



圖一、資料前置處理流程圖

2 差異表現基因篩選

差異性比較是針對在 Microarray 中的各個癌症相


關基因來做研究，探討基因在癌症組織與正常組織中表現的差異。例如比較正常細胞與癌細胞之差異，可大量篩選腫瘤標記基因 (tumor marker) 或應用於具不同癌症轉移能力之細胞株以獲得癌症轉移相關基因。圖二是整個差異表現基因篩選的流程圖，以下我們說明如何處理差異表現的基因。

- (1) 經由文獻探討取得與癌症相關的基因，我們將它分成致癌基因與抑癌基因兩類。
- (2) 從肝癌 Microarray 資料庫中取得基因表現資料，其中包含 102 個 primary HCC (由 82 個病人中取得) 與 74 個 non-tumor liver tissues (由 72 個病人中取得)。
- (3) 篩選出在肝癌微陣列基因表現資料中癌症組織與正常組織皆出現的檢體。
- (4) 在肝癌微陣列基因表現資料中，取每筆微陣列基因表現資料經過 $\log_2$ 轉換計算後紅光與綠光基因表現量的差。
- (5) 將已知的致癌基因與抑癌基因放置到我們建好的肝癌 Microarray 資料庫中做更進一步的搜尋。
- (6) 將已搜尋到的致癌基因與抑癌基因的基因表現資料留在癌症組織與正常組織上皆有出現的檢體。
- (7) 將癌症組織檢體的基因表現資料減正常組織檢體的基因表現資料來做個別基因表現的差異性計算。
- (8) 分別求出致癌基因與抑癌基因在癌症組織與正常組織基因表現上的平均數與標準差。
- (9) 透過致癌基因與抑癌基因在癌症組織與正常組織基因表現上的平均數與標準差來做 T-test 檢定。
- (10) 我們篩選 P 值 < 0.05 的基因，以具有統計上的意義。

在本研究中，我們選擇基因表現資料中癌症組織與正常組織皆出現的檢體全部共 75 個檢體樣本，但是其中也有檢體樣本表現值是不具有公信力，如在同一個檢體有多個點，而表現值有正有負，我們會排除這種檢體，因為此種資料會影響分析結果，所以有些基因的檢體樣本會小於 75 個。

3 測試資料


我們在 NCBI 的 PubMed 文獻中，尋找有討論關於致癌基因 (oncogene) 與抑癌基因 (tumor suppressor gene) 的文章，再經人為經驗判斷來歸類，區分為致癌基因與抑癌基因這兩類，對於定義致癌基因與抑癌基因，或許會有不同的觀點，也會有以前定義為致癌基因到最後定義為抑癌基因的可能性，所以在於資料的篩選，並非是絕對的致癌基因與抑癌基因，但是可以說是大部分都是確定了。



圖二、差異表現基因的流程圖

4 結果


當我們在做分析時，因為只能取得同時在致癌基因與抑癌基因都有資料的檢體，每個基因最多會有 75 個差異表現的檢體樣本，且會有基因的檢體資料分佈圖，我們展示幾個抑癌基因與致癌基因在肝癌 Microarray 資料中差異性表現的分佈圖(如圖三與圖四)，基因上的每一點代表每一個檢體樣本表現值，所以，圖三上的基因都是表現不足的基因，所以其分佈的範圍很明顯的偏向負值，而圖四上的基因都為過度表現的基因，其分佈的範圍偏向正值。另外我們可以使用統計方法來將其分佈結果數據化，如表一與表二的方式，利用平均值與標準差來表示基因的分佈落於正值或負值。



圖三、抑癌基因差異表現的分佈圖

我們了解所謂的致癌基因就是因為表現過度而造

成癌症，抑癌基因則是因為表現不足而導致癌症，所以在正常組織與癌症組織的差異性比較下，如果是正值的



圖四、致癌基因差異表現的分佈圖

表現，我們可以判斷此基因是因為表現過度而造成癌症，所以可以驗證他是致癌基因，抑癌基因則反之。

表一與表二分別為致癌基因與抑癌基因的部份結果，欄位由左至右分別為 Gene Symbol、檢體樣本平均值、檢體樣本變異數、T-test 檢定、過度表現 (Over-expression Layer: OEL) 的檢體數目、表現不足 (Under-expression Layer: UEL) 的檢體數目。紅色與綠色的 Gene Symbol 是經 T-test 檢定後，具有統計上的意義之基因，表示基因在正常組織與癌症組織的分配相同，其差異性的比較是比較具有可信度。

從表一與表二中，我們可以發現大多數的基因平均值都大於 0，可是經由 T-test 檢定後，可以更進一步的篩選出可信度較高的致癌基因。在我們的研究中，我們也有針對檢體來做分類，經過分類後的檢體再進行一次差異性比較後，發現 T-test 小於 0.05 的基因表現是相當的穩定，不會有負值的變動，所以可以確信經 T-test 檢定後基因表現值小於 0.05 的基因是值得相信。而抑癌基因與致癌基因的檢定有相同的結果，只是表現值相反。紅色與綠色的 Gene Symbol 是經 T-test 檢定後，具有統計上的意義之基因，表示基因在正常組織與癌症組織的分配相同，其差異性的比較是比較具有可信度。在抑癌基因的表格中，我們可以找出幾個基因來說，例如 JunB、RAGA、BRCA2 都是目前經生物實驗後分別在文獻上發表的抑癌基因，在我們的資料庫也表示出，這些基因有表現不足的現象。可是 TP53 卻無法很明確的表示出它是屬於過度表現還是表現不足，其原因有很多，TP53 以前被認為是致癌基因，可是近幾年被發現為抑癌基因，所以在以前與現在之文獻上的討論具有兩種認定。在此研究中，我們把造成錯誤的因素放在 Microarray 資料的本身，可能是因為資料在做前置處理時，因 Microarray 實驗的誤差導致的錯誤。總而言之，利用差異性基因表現的方法，確實可以篩選出具有實驗價值的基因。

5 討論

本研究意在收集分析這些 Microarray 的資料，並運用生物資訊的方法來尋找與癌症有關的基因，就能縮小實驗的範圍，確定實驗的方向，避免一些不必要的實驗，以便協助生物學家更快地找出與癌症相關的基因。

Microarray 的實驗目前還是為大家所質疑，所實驗出來的結果也因種種的因素導致有相當的錯誤率，所以在此，我們針對差異表現基因的 Microarray 資料經過 T-test 的檢定，來減少實驗時所造成的雜訊，以提高 Microarray 資料的可靠度。可是由於此動作會造成檢體樣本的減少，而導致樣本不足，使得有些基因無法被辨識出為致癌基因或抑癌基因。對於檢體樣本的減少所造成的誤差，我們未來將針對 Microarray 資料的前置處理來做進一步的研究與分析，以確保在做差異表現基因研究時，有足夠的檢體樣本資料來分析。另外，我們也會繼續的收集各個在網路上分享的 Microarray 資料，更充實我們的資料庫，也同時希望國內有更多的 Microarray 實驗室可以分享他們的資料，以提供大家來做研究。畢竟東方人的人種與西方人的人種有所不同，所以基因的表現量也會有所不同。

Oncogene in Liver Cancer					
Gene Symbol	Mean	SD	T-Test	#Num of OEL Cases	#Num of UEL Cases
AGR2	0.651045	1.847749	0.000924	40	26
ANF32B	0.247716	0.684424	0.002032	47	27
APC	0.515107	0.635663	0.01499	18	10
ARAF1	-0.07772	0.608734	0.377815	6	6
ARHA	0.415109	0.492116	2.73E-11	49	15
ARMET	0.32193	1.10499	0.012224	45	26
BCR	0.120356	0.682627	0.120777	42	31
BUB1	1.650833	1.37886	5.58E-15	62	4
CCNA2	1.499014	1.698417	2.8E-10	59	12
CDK4	0.795081	0.805853	1.46E-12	63	11
CTBP1	0.085833	0.526258	0.154207	26	19
CTNNB1	0.433792	0.580022	3.07E-07	45	5
CTSL	-0.17262	0.692472	0.086051	48	2
CTSL	0.536085	0.95307	2.07E-06	64	0
CTSL	0.54	0.7516	0.292804	28	28
PML				19	16
RAF1				5	3
RET	0.486129	0.577609	0.176132	34	16
RPS19	0.18307	0.454111	0.006364	52	19
RPS27	0.43738	0.654559	7.35E-06	48	24
RPS3	0.283549	0.7216	0.002769	43	28
SETDB1	0.13993	0.617968	0.031084	19	2
SHC1	1.336286	0.950199	1.08E-06	33	33
SKIV2L	0.132778	0.690033	0.055185	61	12
TACC3	0.874425	0.954005	9.96E-11	48	26
TAZ	0.187144	0.987323	0.056506	34	33
TF53	0.036249	0.900516	0.385303	58	16
TPD52	0.643905	0.817825	8.5E-08		

表一、致癌基因的肝癌差異性基因表現表

Tumor Suppression Gene in Liver Cancer					
Gene Symbol	Mean	SD	T-Test	#Num of OEL Cases	#Num of UEL Cases
BNIP3L	-0.43858	0.772753	1.74E-06	17	57
BRCA2	-0.80919	0.709547	0.005187	1	12
BTG2	-0.20438	1.190317	0.067086	37	37
CDKN1A	-0.75982	1.470456	0.000368	22	43
CDKN2A	-0.13028	0.909235	0.124133	30	44
COL18A1	-0.34945	0.998815	0.003446	28	46
CUL1	-0.02784	0.644664	0.407262	33	41
CUL3	-0.19098	0.681247	0.086051	9	13
CUL4A	0.021693	0.659364	0.407679	32	43
DAB2	-0.04172	1.040531	0.391847	24	31
DGKA	-0.32868	1.292807	0.016243	19	40
JUNB	-1.42342	1.088474	1.9E-16	4	58
MEN1	-0.34264	1.199036	0.007794	27	46
NF2	-0.05353	1.257971	0.348224	39	34
PLA2G2A	-1.71512	3.313052	1.45E-05	21	52
PTEN	-0.12759	0.792619	0.11876	38	36
RAGA	-0.277	0.623975	9.85E-05	23	48
RAN	-0.23704	0.762237	0.007525	30	44
RBM6	0.015685	0.651023	0.439804	39	34
TEK	-1.03511	0.881038	1.34E-14	7	67
TGFB1	-0.37579	0.963309	0.148383	2	5
TP53	0.020887	0.902702	0.432547	34	34

表二、抑癌基因的肝癌差異性基因表現表

參考文獻

- [1] W.C. Hahn and R.A. Weinberg, "Modelling the molecular circuitry of cancer," *Nat Rev Cancer*. 2(5), pp. 331-41, 2002.
- [2] A. Kramer, K. Neben and A.D. Ho, "Centrosome replication, genomic instability and cancer," *Leukemia*, 16(5), pp. 767-75, 2002.
- [3] S.E. Andrew, and A.C. Peters, "DNA instability and human disease," *Am J Pharmacogenomics*. 1(1), pp. 21-8, 2002.
- [4] I.M. Frayling, "Methods of molecular analysis: mutation detection in solid tumours," *Mol Pathol*. 55(2), pp. 73-9, 2002.
- [5] C. Bernstein, H. Bernstein, C.M. Payne and H. Garewal, "DNA repair/pro-apoptotic dual-role proteins in five major DNA repair pathways: fail-safe protection against carcinogenesis," *Mutat Res*. 511(2), pp. 145-78, 2002.
- [6] L.S. Kirschner, "Signaling pathways in adrenocortical cancer," *Ann N Y Acad Sci*. 968, pp. 222-39, 2002.
- [7] T. Skorski, "Oncogenic tyrosine kinases and the DNA-damage response," *Nat Rev Cancer*. 2(5), pp. 351-60, 2002.
- [8] Y. Murakami, "Functional cloning of a tumor suppressor gene, TSLC1, in human non-small cell lung cancer," *Oncogene*. 21(45), pp. 6936-48, 2002.
- [9] S.J. Xia, J.G. Pressey and F.G. Barr, "Molecular pathogenesis of rhabdomyosarcoma," *Cancer Biol Ther*. 1(2), pp. 97-104, 2002.
- [10] M. Esteller, "CpG island hypermethylation and tumor suppressor genes: a booming present, a brighter future," *Oncogene*. 21(35), pp. 5427-4, 2002.
- [11] J.P. Tsai, J.G. Chang, S.H. Shih, R.M. Chen, H.W. Hsiao, R.M. Hu, S.N. Chen, M.M. Lee, F.M. Liu, and W.L. Chan, "A Framework for Cancer-related Genes Mining over the Internet," *Proc. IEEE 3rd International Symposium on Bioinformatics and Bioengineering*, Washington DC, USA, March 10-12, 2003.
- [12] J.P. Tsai, J.G. Chang, S.H. Shih, R.M. Chen, H.W. Hsiao, R.M. Hu, S.N. Chen, M.M. Lee, W.L. Chan, P.X. Wu, W.H. Chen, S.S. Shen, F.M. Liu and Y.C. Lin, "A Bioinformatics Approach for Exploring Cancer-related Genes," *Proc. Workshop on Bioinformatics, held in conjunction with 19th Int'l Conf. on Data Engineering*, Bangalore, India, March 5-8, 2003.
- [13] Sargent TD, "Isolation of differentially expressed genes," *Methods Enzymol*. 152: 423-432, 1987.
- [14] Kishimoto TK, O'Connor K, Lee A, Roberts TM and Springer TA, "Cloning of the b subunit of the leukocyte adhesion proteins: homology to an extracellular matrix receptor defines a novel supergene family," *Cell* 48: 681-690, 1987.
- [15] Hogervorst F, Kuikman I, von dem Borne AE and Sonnenberg A, "Cloning and sequence analysis of beta-4 cDNA: an integrin subunit that contains a

- unique 118 kD cytoplasmic domain,” *EMBO J.* 9: 765-770, 1990.
- [16] Suzuki S, Huagn ZS and Tanihara H, “Cloning of an integrin b subunit exhibiting high homology with integrin b3 subunit,” *Proc. Natl. Acad. Sci. USA* 87: 5354-5358, 1990.
- [17] Liang P and Pardee AB, “Differential display of eukaryotic messenger RNA by means of the polymerase chain reaction,” *Science* 257: 967-971, 1992.
- [18] Liang P, Averboukh L and Pardee AB, “Distribution and cloning of eukaryotic mRNAs by means of differential display: refinements and optimization,” *Nucleic Acid Res.* 21: 3269-3275, 1993.
- [19] Heermann KH, Hagos Y and Thomssen R, “Liquid-phase hybridization and capture of hepatitis B virus DNA with magnetic beads and fluorescence detection of PCR product,” *J. Virol. Methods.* 50: 43-58, 1994.