

以調控序列叢集分析人類啟動子區域

陳士農^{1,2} 蔡進發¹ 林俊谷² 黃志瑋¹

¹ 臺中健康暨管理學院資訊科技學系

² 臺中健康暨管理學院生物資訊學系

413 台中縣霧峰鄉柳豐路 500 號

{nung, jptsai}@thmu.edu.tw {std91242005, std91241007}@ms1.thmu.edu.tw

摘要

由於人類基因體計畫(Human Genome Project)提供了完整的人類基因體序列,使用基因體序列資訊來分析基因功能的相關研究,已經在世界各地展開。利用基因體序列資料我們能夠進行基因功能研究,基因可以分成數個結構部份,在這些部份中,對基因表現(gene expression)來說最重要的部份是啟動子(promoter)。本論文提出一個在未知序列中,預測分析啟動子的方法,本研究利用調控蛋白結合部位(regulatory protein binding site)的位置權重矩陣(position weight matrix)來統計調控蛋白對序列結合的強度與位置的相關性,再加上 G+C 含量(G+C content)與 CpG 雙核苷酸(CpG dinucleotide)的數量,利用線性回歸的方法,計算出三個線性分析函數,用於預測人類啟動子在基因序列中的位置,除此之外,還能對啟動子附近的區域進行分析,如核心啟動子(core promoter)的位置、調控蛋白結合部位(regulatory protein binding site)的位置。最後,我們的方法與其他研究比較預測的結果,證實我們的方法的確比較優秀。

關鍵字：啟動子(promoter)、轉錄因子結合部位(transcription factor binding site)、位置權重矩陣(position weight matrix)、調控蛋白結合部位(regulatory protein binding site)、RNA 聚合酶(RNA polymerase)

1. 前言

隨著人類基因體計畫的進行,有越來越多的研究人員投入生物資訊的研究行列,不管是序列預測、藥物研發、或是疾病治療等,都是重要的研究課題。就疾病來說,病症的出現可能是因為代謝途徑(metabolic pathway)發生錯誤或是基因表現的產物—蛋白質(protein)之間相互影響所導致,若要從基因表現層面來研究相關疾病的發病或症狀,可以藉由探索基因表現機制來達成此一目的。但如果一開始就直接利用生物實驗來驗證,將會花費相當大的人力與物力;若先經由生物資訊方法的研究分析,在進行生物實驗之前,將可能的變因範圍縮小,並獲取所需的相關資訊做為參考,必能減少錯誤實驗所導致的浪費,並加速研究的進行。

在公共領域(public domain)的資料庫中, mRNA 的數量遠超過啟動子的數量,這是因為 mRNA 的資料可以合併 dbEST [1]推算出 mRNA 的位置,目前人類的 EST (Expressed Sequence Tags) [2]的數量已經超過 500 萬筆,反觀啟動子必須透過生物實驗驗證—足跡法(footprinting) [3],才能確定啟動子的區域,因此,如果有一個準確率很高的預測分析程式可針對基因進行分析,將可促進對生物轉錄機制的了解。

在基因表現的過程中,從 DNA 轉錄(transcription)成 RNA,再由 RNA 轉譯(translation)

成蛋白質，每個階段都有相對應的調控機制[4]，這也是生物體內最重要的過程。然而，此過程非常複雜且難以理解，因此，若是現有的資料庫中，能夠提供啟動子的相關資訊，生物學家就可以從轉錄的階段進行研究，這將會更準確且更有效率。啟動子對轉錄的重要性在於它可以決定在轉錄的過程中，RNA 聚合酶(RNA polymerase)會以那一股為模板進行轉錄，以及轉錄的起始位置，此外，啟動子也會影響 RNA 聚合酶在 DNA 上面的結合強度，這將會影響整個轉錄的效率。

在真核生物的基因當中，有三種 RNA 聚合酶能與基因發生作用，分別是 RNA 聚合酶 I、RNA 聚合酶 II、RNA 聚合酶 III，且不同的 RNA 聚合酶會產生不同的產物，分別是 rRNA、蛋白質、tRNA。在本論文中，只有針對 RNA 聚合酶 II 相關的基因進行研究，因為在生物體內幾乎所有的生理生化反應都是透過蛋白質與蛋白質之間的作用，或是蛋白質作用於 DNA 上的影響來調節生理現象。在真核細胞典型的轉錄機制中，RNA 聚合酶 II 並不能直接找到基因的位置進行轉錄過程，必須經由轉錄因子的協助，才能順利辨識位於 DNA 上的基因位置進行轉錄。在 2003 年，Stephen T. Smale [5]說明在果蠅與人類的核心啟動子中，會出現特定的共同序列，如 BRE、TATA box、Inr、DPE 等，透過這些特殊的共同序列可以做為預測啟動子的基準，當成尋找啟動子的線索[6] [7] [8]。

在 2002 年，Jennifer [9]的研究中指出，在一組 205 筆啟動子的資料中，有 29%含有 TATA box，26%含有 DPE，14%同時含有 TATA box 與 DPE，31%是兩者都沒有。而沒有 TATA box 與 DPE 的基因，它的轉錄起始機制將是我們的研究重點，究竟是何種機制，才能使沒有 TATA box 與 DPE 的基因進行轉錄？因此，我們懷疑在不同物種間的同源基因中，是否也有不同的轉錄機制出現？或是在相同基因家族內，是否也有相同的轉錄機制？在公共領域的真核啟動子資料庫(Eukaryotic Promoter

Database, EPD) [10]中，記錄了將近 3000 筆真核生物的啟動子資料，其中人類的啟動子資料大約有 1871 筆，在這個資料庫中的轉錄起始點資料是經由生物實驗驗證所得。而在人類啟動子資料庫(Human Promoter Database, HPD) [11]中，則記錄了 2004 筆的啟動子資料，然而進行啟動子研究如果只利用這些資料來分析，這樣的數量是不夠的，因此，一個具有高準確性的啟動子預測程式，對調控機制的研究將有極大的幫助。

2. 方法

2.1 資料收集

在本研究中，收集的資料可分為兩大類，第一類為啟動子資料，第二類為非啟動子資料。啟動子資料有兩個主要的來源，其一是從真核啟動子資料庫中取得，其版本號碼為 77，擷取長度為 250bp 的人類啟動子序列，範圍為上游-199bp 到下游+50bp，總共有 1871 筆序列資料，這些序列包含了轉錄起始點(transcription start site)的位置。另一個啟動子資料來源是人類啟動子資料庫，擷取的範圍同樣是從上游-199bp 到下游+50bp 的位置，資料共有 2004 筆。非啟動子資料則取自 NCBI 的 GenBank [12]資料庫與 RefSeq [13]資料庫，序列組合版本號碼為 34。

為了避免與啟動子區域重疊，從序列資料庫中擷取正股基因 CDS (coding sequence)的 DNA 序列，選取的範圍是從轉譯起始點(translation start site)往下游+1501bp 到+1750bp 的區域。我們從人類第一號到第二十二號染色體的正股上，總共取得 11731 筆非啟動子序列，為了取得與 3875 筆啟動子序列相同數量的非啟動子序列，我們由 11731 筆非啟動子序列中，隨機選取 10 組 3875 筆的非啟動子序列做為訓練之用。最後，為了與其他研究進行比較分析，我們採用 Matthias Scherf 在 PromoterInspector [14]中使用的其中一組序列，其

編號為 AC002397，總長度為 227538bp，含有 17 個轉錄起始點。

2.2 位置權重矩陣

本研究所使用的調控蛋白結合部位的權重矩陣包含了 ap1、ccaat、cre、e2f、ere、ets、gata、lsf、mef2、myc、myf、nfl、sp1、srf、tata、tef 等 16 個[15][16][17][18][19][20][21][22]。我們先將每個位置出現的次數除以全部出現的次數以轉換成頻率，由於背景的機率是 0.25，所以將頻率再除以 0.25 以得到勝率分數(odds score)，最後，將勝率分數轉換成以 2 為底的對數值，做為最後的權重矩陣，然後再利用這些權重矩陣來計算不同位置的分數。

在 16 個權重矩陣中，寬度並不一定相同，範圍則從 8 個鹼基到 16 個鹼基。在本研究中，我們使用固定長度的方法，因為我們發現在權重矩陣中，單一核苷酸出現次數較高的共同長度大約為 8 個鹼基，也就是說每個權重矩陣中，結合強度最好的範圍是集中在中間 8 個鹼基的位置。在權重矩陣中，由於某些位置的核苷酸出現次數為 0，當轉換成對數勝率時會變成無限小的值，在這裡我們直覺地使用 -10 來取代無限小的值，原因是如果出現一次 -10 的情形，除非其他的核苷酸分數非常高，否則，這一組序列的分數成為前五大的機率是非常小的。

2.3 調控蛋白結合部位計分

我們使用一個 8bp 的滑動窗(sliding window)在 250bp 長度的序列中，利用不同的調控蛋白結合部位的權重矩陣，計算每個位置的分數，並記錄前五大的分數與位置。不同的調控蛋白結合部位會在不同的位置與不同的調控蛋白結合，只有在正確位置的調控蛋白結合部位會有較高的分數，例如，起始子(initiator)的位置在轉錄起始點的附近幾個鹼

基，如果在位置內，將會有較高的分數，如果在可能的位置外，則分數將會很低。在整個計算過程中，我們使用 16 個調控蛋白結合部位的權重矩陣，分別得到前五大分數與位置，而且前五大分數的值必須大於 0，如果沒有大於 0 則以 0 計算。因此，可以獲得兩組 80 個分數與位置的變數值，再加上 CpG 雙核苷酸與 G+C 含量比例，總共會有 162 個變數可以用來判別啟動子的位置與調控蛋白結合部位的分佈情形。

2.4 線性分析函數(Linear Analysis Function)

將分數、位置、CpG 雙核苷酸所組成的變數值分別使用線性回歸(linear regression)方法，使得兩群啟動子與非啟動子的分數到分界線的垂直距離為最小，也就是使得所有序列中的前五大調控蛋白結合部位的分數、位置、CpG 雙核苷酸的分數與這條分界線的垂直距離平方和為最小，分界線公式如下：

$$LSF(S_i) = \sum_{i=1}^{80} A_i \cdot S_i + C_s \quad (1)$$

其中， $LSF(S_i)$ 為線性分數函數， S_i 是由權重矩陣計算產生的前五大分數值， A_i 為係數， C_s 為常數。

$$LPF(P_j) = \sum_{j=1}^{80} A_j \cdot P_j + C_p \quad (2)$$

其中， $LPF(P_j)$ 為線性位置函數， P_j 是由權重矩陣計算產生的前五大分數的位置， A_j 為係數， C_p 為常數。

$$LCF(C_k) = \sum_{k=1}^2 A_k \cdot C_k + C_c \quad (3)$$

其中， C_1 為 G+C 的比例， C_2 為 CpG 雙核苷酸的數量， A_k 為係數， C_c 為常數。

為了測試上述三個線性分析函數的準確性，我們將三個線性分析函數的計算結果與其他預測程式相互比較，這些程式包含了PromoterInspector [14]、TSSG [23]、TSSW [24]、NNPP 2.1 [25]、Promoter 2.0 [26]等，所使用的測試序列為Matthias Scherf在PromoterInspector [14]中使用的其中一組序列，其編號為AC002397，總長度為227538bp，含有17個轉錄起始點。

3. 結果

3.1 訓練資料組(Training Set)與測試資料組(Testing Set)

選取真核啟動子資料庫與人類啟動子資料庫組成具有啟動子的序列資料共有 3875 筆，另外在 NCBI 的 GenBank 資料庫與 RefSeq 資料庫中，從 11731 筆資料中隨機選取 10 組 3875 筆序列做為訓練使用。在測試資料組中，由 PPR 的 4737 筆組成，長度分別為 250bp 與 3001bp，以及一組長度為 227538bp 的序列。

3.2 訓練資料組的 G+C 比例與 CpG 雙核苷酸的數量

表1. 訓練資料組的G+C比例與CpG雙核苷酸的數量

	啟動子		非啟動子
	LCF 相關	LCF 非相關	
G+C 平均值	0.68289	0.51509	0.451751
G+C 變異數	0.06913	0.09198	0.103749
CpG 平均值	26.0498	6.40941	3.683318
CpG 變異數	6.85115	4.66613	0.103667

表 1 顯示在啟動子相關的序列中，平均的 G+C 比例均大於 50%，非啟動子的 G+C 比例只有 45%。在 CpG 雙核苷酸的數量上，啟動子的 CpG 雙核苷酸平均數遠大於非啟動子的 CpG 雙核苷酸

平均數，與 LCF 函數相關的啟動子，CpG 雙核苷酸的平均數為 26.05，標準差為 6.85，與 LCF 函數非相關的啟動子，CpG 雙核苷酸的平均數為 6.41，標準差為 4.67，非啟動子相關序列的 CpG 雙核苷酸平均數為 3.68，標準差為 0.1。

3.3 線性分析函數的係數比較

表2. 兩個線性分析函數的變數、係數分析比較表


	$A_i/A_j, A_k$ 大於0的數量	$A_i/A_j, A_k$ 小於0的數量	$A_i/A_j, A_k$ 大於0的變數類型
LSF	36(12)	44(14)	cre, e2f, mef2, myc, spl, srf, tata
LPF	45(5)	38(1)	cre, e2f, ere

表 2 顯示 LSF 與 LPF 兩個線性分析函數的係數比較情形。在 LSF 中，大於 0 的係數有 36 個，其中 12 個大於 0.01，最大為 0.45759；小於 0 的係數有 44 個，其中 14 個大於 -0.01，最大為 -0.051852，影響較大的變數類型分別為 cre、e2f、mef2、myc、spl、srf、tata。在 LPF 中，大於 0 的係數有 45 個，其中 5 個大於 0.001，最大為 0.001417；小於 0 的係數有 38 個，其中 1 個大於 -0.001，最大為 -0.001278，影響較大的變數類型分別為 cre、e2f、ere。


3.4 訓練資料組分析

在圖 1 的(A) (B) (C)中，啟動子資料共有 3875 筆，另外可將啟動子資料分成左右兩群，左邊的資料與 LSF、LPF、LCF 相關程度較低，右邊的資料與 LSF、LPF、LCF 相關程度較高。在圖 1 的(D) (E) (F)中，非啟動子資料共有 11731 筆，LSF、LPF、LCF 的平均值也遠小於啟動子 LSF、LPF、LCF 的平均值，兩者相距超過 2 倍的標準差，非啟動子平均值+2 倍非啟動子標準差<0.43<啟動子平均值+2 倍啟動子標準差，所以，我們取輸出值大於 0.5 的序列為啟動子序列，輸出值大於 0.5 可以降低誤判非啟動子為啟動子的機率。


(A)




(D)




(B)



(E)



(C)



(F)




圖 1. 三個線性分析函數輸出值次數分佈圖，此例以所有訓練資料為輸入值，(A)~(C)為啟動子分佈圖，(D)~(F)為非啟動子分佈圖，(A)、(D)為 LSF，(B)、(E)為 LPF，(C)、(F)為 LCF。(A)以 0.5 為分界線，左邊區域平均值為 0.237738，變異數為 0.141387，右邊區域平均值為 0.853385，變異數為 0.190675。(B)以 0.5 為分界線，左邊區域平均值為 0.227332，變異數為 0.188471，右邊區域平均值為 0.842643，變異數為 0.188471。(C)以 0.5 為分界線，左邊區域平均值為 0.238256，變異數為 0.136892，右邊區域平均值為 0.84626，變異數為 0.205104。(D)平均值為 0.125604，變異數為 0.426452。(E)平均值為 0.129683，變異數為 0.431492。(F)平均值為 0.125935，變異數為 0.426624。




圖 2. 三個線性分析函數輸出值大於 0.5 的資料交互情形。

圖 2 顯示在訓練資料中，經由三個線性分析函數輸出值大於 0.5 的資料交互情形，LSF 共有 2401 筆，LPF 共有 2393 筆，LCF 共有 2429 筆，LSF 與 LPF 同時大於 0.5 的資料共有 2184 筆，LSF 與 LCF 同時大於 0.5 的資料共有 2166 筆，LPF 與 LCF 同時大於 0.5 的資料共有 2169 筆，LSF、LPF 與 LCF 同時大於 0.5 的資料共有 2026 筆。

3.5 預測結果分析

表 3. 預測結果比較表

序列編號	方法	TP	FP
AC002397	TSSG	8	97
	TSSW	6	101
	NNPP 2.1	10	658
	Promoter 2.0	5	455
	PromoterInspector	5	1
	Our method	8	3

表 3 是我們的方法與其他研究的預測結果比較表，在我們的方法中，只有正股序列接受測試，反股序列並沒有加入測試，在正股序列中，共有 13 個轉錄起始點，我們預測了 11 個調控序列叢集，其中有 8 個包含了轉錄起始點。在其他研究中，PromoterInspector [14]預測了 6 個轉錄起始點，其中有 5 個正確，TSSG [23]預測了 105 個轉

錄起始點，其中有 8 個正確，TSSW [24]預測了 107 個轉錄起始點，其中有 6 個正確，NNPP 2.1 [25]預測了 668 個轉錄起始點，其中有 10 個正確，Promoter 2.0 [26]預測了 560 個轉錄起始點，其中有 5 個正確。

4. 討論

我們利用真核啟動子資料庫與人類啟動子資料庫做為訓練資料組，並沒有去除部份沒有關聯的資料，而是全部用來訓練，經過多次訓練的結果，雖然無法將所有的啟動子與非啟動子完全分成兩群，但已經能將啟動子序列分成與線性分析函數相關與非相關兩群資料，由於與線性分析函數非相關啟動子與非啟動子資料較為相似，而無法使用本研究所提出的三個線性分析函數來區分，因此，線性函數非相關的啟動子序列仍是非常值得研究的部份。

在 LCF 分析函數中，輸出值大於 0.5 的資料可以發現 CpG 雙核苷酸的數量在 15 以上，G+C 的比例則超過 50%，這個結果與其他以 CpG islands 為判別標準的研究大致相符 [27] [28] [29]。利用本研究所提出的三個線性分析函數交互確認啟動子區域以縮小預測範圍，雖然速度較慢，但是準確率卻可提高，因此，我們還是決定使用三個線性分析函數交互確認的方式做為啟動子區域的預測法則。最後，與其他研究比較的結果，證實我們的方法確實有效。

5. 結論

在我們提出的方法中，的確能藉由三個線性分析函數的交互確認來確定啟動子區域，雖然還不能確定啟動子區域的起始與結束的位置，卻已經能夠從大範圍的序列中，找到轉錄起始點的位置，與其他研究的方法比較，我們的方法也有較高的敏感度。

参考文献

- [1] Boguski MS, Lowe TM, Tolstoshev CM. (1993) dbEST - database for expressed sequence tags *Nature Genetic*, **4**, 332-333.
- [2] Adams MD, Kelley JM, Gocayne JD, Dubnick M, Polymeropoulos MH, Xiao H, Merrill CR, Wu A, Olde B, Moreno RF, et al. (1991) Complementary DNA sequencing: expressed sequence tags and human genome project. *Science*, **252**, 1651-1656.
- [3] Komura J, Ono T. (2003) Nucleosome Positioning in the Human c-FOS Promoter Analyzed by in Vivo Footprinting with Psoralen and Ionizing Radiation. *Biochemistry*, **42**, 15084-15091.
- [4] Gerhard Krauss. (2001) *Biochemistry of Signal Transduction and Regulation*, 2nd edition Wiley-VCH Verlag GmbH press, pp 1-88.
- [5] Stephen T. Smale and James T. Kadonaga. (2003) The RNA Polymerase II Core Promoter. *Annu. Rev. Biochemistry*, **72**, 449-479.
- [6] Uwe Ohler, Guo-chun Liao, Heinrich Niemann and Gerald M Rubin. (2003) Computational analysis of core promoters in the *Drosophila* genome, *Genome Biology*, **12**, 87-98.
- [7] James T. Kadonaga. (2002) The DPE, a core promoter element for transcription by RNA Polymerase II, *EXPERIMENTAL and MOLECULAR MEDICINE*, **34**, 259-264.
- [8] ALAN K. KUTACH and JAMES T. KADONAGA. (2000) The Downstream Promoter Element DPE Appears To Be as Widely Used as the TATA Box in *Drosophila* Core Promoters, *MOLECULAR AND CELLULAR BIOLOGY*, **20**, 4754-4764.
- [9] Jennifer E.F. Butler and James T. Kandonaga. (2002) The RNA polymerase II core promoter: a key component in the regulation of gene expression, *Genes & Development*, **16**, 2583-2593.
- [10] Cavin Perier R, Praz V, Junier T, Bonnard C, Bucher P. (2000) The Eukaryotic Promoter Database (EPD). *Nucleic Acid Res*, **28**, 302-303.
- [11] <http://zlab.bu.edu/~mfrith/HPD.html>
- [12] Benson DA, Karsch-Mizrachi I, Lipman DJ, Ostell J, Wheeler DL. (2003) GenBank. *Nucleic Acids Research*, **31**, 23-27.
- [13] Pruitt KD, Maglott DR. (2001) RefSeq and LocusLink: NCBI gene-centered resources. *Nucleic Acids Research*, **29**, 137-40.
- [14] Matthias Scherf, Andreas Klingenhoff and Thomas Werner. (2000) Highly Specific Localization of Promoter Regions in Large Genomic Sequences by PromoterInspector: A Motif Context Analysis Approach. *Journal of Molecular Biology*, **297**, 599-606.
- [15] Martin C. Frith, Ulla Hansen and Zhiping Weng. (2001) Detection of cis-element clusters in higher eukaryotic DNA. *Bioinformatics*, **17**, 878-889.
- [16] Bucher P. (1990) Weight matrix descriptions of four eukaryotic RNA polymerase II promoter elements derived from 502 unrelated promoter sequences. *Journal of Molecular Biology*, **212**, 563-578.
- [17] Mantovani R (1999) The molecular biology of the CCAAT-binding factor NF-Y, *Gene* **239**, 15-27.
- [18] Matys, V., Fricke, E., Geffers, R., Kel-Margoulis, O.V. et al. (2003) TRANSFAC: transcriptional regulation, from patterns to profiles. *Nucleic Acids Research*, **31**, 374-378.

- [19] Mimeault M. (2000) Structure-function studies of ETS transcription factors. *Critical Reviews in Oncogenesis*, **11**, 227-253.
- [20] O'Lone R, Frith MC, Hansen U (in preparation).
- [21] Grandori C & Eisenman RN. (1997) Myc target genes, *TIBS*, **22**, 177-181.
- [22] Wasserman WW, Fickett JW. (1998) Identification of regulatory regions which confer muscle-specific gene expression, *Journal of Molecular Biology*, **278**, 167-81.
- [23] Kel AE, Kel-Margoulis OV et al. (2001) Computer-assisted identification of cell cycle-related genes: new targets for E2F transcription factors. *Journal of Molecular Biology*, **309**, 99-120.
- [24] Solovyev, V. & Salamov. (1997) A. The gene-finder computer tools for analysis of human and model organisms genome sequences. *ISMB*, 294-302.
- [25] Reese MG. (2001). Application of a time-delay neural network to promoter annotation in the *Drosophila melanogaster* genome, *Computer Chem*, **26**, 51-56.
- [26] Kundsén, S. (1999), Promoter 2.0: for the recognition of Pol II promoter sequences. *Bioinformatics*, **15**, 356-361.
- [27] Ioshikhes I and Zhang MQ. (2000) Large-scale human promoter mapping using CpG islands. discrimination. *Nature Genetics*, **26**, 61-63.
- [28] Leonardo Marino-Ramirez, John L. Spouge, Gavin C. Kanga and David Landsman, (2004) Statistical analysis of over-represented words in human promoter sequences, *Nucleic Acids Research*, **32**, 949-958.
- [29] Loic Ponger and Dominique Mouchiroud, (2002) CpGProD : identifying CpG islands associated with transcription start sites in large genomic mammalian sequences, *Bioinformatics*, **19**, 31-633.