

結合資料探勘與基因演算法用於特徵選取

陳台晟

教育部

jason123@mail.moe.gov.tw

柯兆軒

電子工程系

高雄應用科技大學

a092205237@cc.kuas.edu.tw

楊正宏

電子工程系

高雄應用科技大學

chyang@cc.kuas.edu.tw

摘要

處理分類問題時通常會遇到資料的特徵維度過大而導致分類效率降低的問題，然而在分類問題中，並非資料的每個特徵對於分類結果都是有幫助的。然而在未進行分類之前先進行特徵選取的動作，藉此剔除不重要的特徵、選出較重要的特徵，再利用分類器進行分類，可提升分類效率並提升分類正確率。基因演算法常被用於解決最佳化的問題，但其缺點是容易落入區域最佳解。在本文中，我們利用資料探勘的方式來改善基因演算法容易落入區域最佳解的缺點，並利用此方法來做特徵選取，結果證實可以有效的改善基因演算法落入區域解的問題，並可選取較好且數量較少的特徵，有效的提升分類效率並得到較佳的分類正確率。

關鍵字：特徵選取、資料探勘、基因演算法、分類正確率、最佳化。

1 前言

特徵選取是一種從原始的特徵集合中挑選出較為重要的特徵子集合來代表原始資料的動作[7]，且所挑選出來的特徵子集合，不會與原始資料有太大的差異性，目前通常用於圖形辨識、生物資訊和文件分類等研究中[6][10]。而特徵選取在處理分類問題研究上所面臨的特徵維度過大而導致運算時間過長的問題，也有良好的成效，因此特徵選取可當作處理大量資料的一種前處理動作，對於像是微陣列(Microarray)等生物計算研究中需計算高特徵維度的資料[1]，可以先利用特徵選取選擇出

重要的特徵來代表原始資料，之後在分類計算上可以大幅的降低計算時間，並提高其分類正確率。

目前最佳化的研究已被廣泛的用於許多工程領域中，例如機械設計、衛星工程和電力控制等；而目前已有許多最佳化的演算法被廣泛的運用，例如基因演算法、螞蟻演算法、禁忌搜尋法和粒子族群最佳化[3]等。基因演算法是一種模仿自然界藉由交配和突變等演化機制所提出的一種最佳化演算法，利用適者生存的原理，將較適合的結果留下，不適合的結果自然淘汰，如此達到持續演化以獲得最佳的結果。當運用在一般的研究中，先將可能解編碼成一個固定長度的染色體，經數次迭代之後，染色體會逐漸的改變，演化成多種的組合可能；然而在經過多次的迭代後，染色體之間的組合將越來越相似，導致不管再經過多少次的迭代，都將只獲得一種相同的最佳解，此時通常定義此種情況為已落入區域最佳解，基因演算法的缺點便是容易若入區域最佳解，縱使具有突變的動作，但由於突變的機率並不高，因此對於解決區域最佳解的問題不容易有太多的貢獻。

資料探勘是結合了知識探勘和知識管理所組成的新的研究主題，其主要在探討知識或資料間是否具有某些的相關性與意義存在；在目前逐漸數位化的社會中，資訊數量已大量的增加，而許多原始的文字資料已被轉化為數位資訊，因此，如何從大量的資訊中找出具有相關性並藉此發掘出隱藏其中的重要資訊，即是資料探勘目前著重的研究部分。資料探勘在近年來已被大量的運用在商業領域中，在金融、物流、品管和銷售等處皆可見其蹤跡，藉由其發掘大量資訊中的隱藏意義，已經有越來越多

的商業團體導入資料探勘的研究，希望藉此能夠提升其獲利，其中最著名的莫過於發掘出超級市場中尿布與啤酒的有趣結果；因此，如果能夠利用資料探勘的優勢來發掘研究資訊中的隱藏意義，或許可以找出更好的研究價值。

由於基因演算法有落入區域最佳解的問題，在我們的研究中，我們導入資料探勘的方式來改善區域最佳解的問題，藉由發掘染色體中基因彼此之間的關聯性意義，發掘出染色體中具有關連性且重要的編碼資訊，當判斷出基因演算法已經落入區域最佳解時，此時利用資料探勘所找出重要的資訊編碼組成染色體取代原始母體中的染色體，經由實驗證明，如此可以有效的改善基因演算法落入區域最佳解的問題；我們使用 UCI repository 中的 8 筆分類資料做特徵選取[5][9]，再將所選取出來的資料作分類計算，研究結果顯示，經過特徵選取後，可以得到較少的特徵維度，並得到更好的分類正確率。

本文的架構依序如下：在第二部分會說明基本的相關研究，即基因演算法和資料探勘；第三部分會說明整個研究的流程和詳細的敘述；在第四部分說明了實驗結果；最後第五部分則是結果與討論。

2 相關研究

基因演算法(Genetic algorithm)通常被用於解決最佳化問題，例如尋找最大或最小值等。然而基因演算法通常容易只找到次佳解，並無法保證能更找到最佳解，其原因在於進化速度過慢，且突變機率小，因此容易若入區域最佳解。在本文中，我們利用資料探勘的方法尋找出資料中每個特徵的關聯性，將關聯性高的特徵留下，重新編碼成新的染色體，並加入基因演算法的染色體中，藉以改善基因演算法容易落入區域最佳解的問題。

2.1 基因演算法

基因演算法是一種進化式演算法(Evolutionary Algorithm, EA)，在1975年由 John Holland 所提出[3]，觀察生物演化的步驟，提出藉由染色體選擇、交配和突變的步驟來解決最佳化問題；透過選擇出的染色體互相交配，可以產生出較佳的下一代，也利用突變的特性，產生突破性的發展。在基因演算法的設計中，通常將許多的解編碼成一個染色體(Chromosome)，而染色體中每一個基因(Gene)代表著一個解，染色體長度越長，其複雜度越高。基因演算法俱有影響效能的四個主要變數依序為：族群數量、迭代次數、交配率和突變率。通常擁有大量的族群和較多的迭代次數較容易得到最佳解，但相對的其缺點是會增加計算的時間。而基因演算法的步驟依序為：1. 初始化染色體 2. 計算適應值 3. 選擇染色體 4. 交配 5. 突變 6. 取代 7. 終止條件。

2.1.1 初始化染色體

使用基因演算法作為解決最佳化問題時，首先要決定染色體的編碼方式。在生物中基因是構成染色體的基本單元，因此在編碼時我們將一個基因表示為一個實數或整數，亦或是一個位元；而染色體上有許多個基因，基因的數目就是欲求解的編碼長度。目前常見的編碼法有二進位編碼、實數編碼和符號編碼；在解決不同的問題時，可以利用不同的編碼方式來表示問題解。選擇了編碼方式後，每個染色體則須被初始化來代表問題的初始解，而染色體的初始化通常使用隨機的方式來產生初始的編碼結果。

2.1.2 適應函數值

每個染色體依據其基因表現，利用適應函數(Fitness Function)計算出其適應函數值(Fitness Values)。每個染色體皆具有一個適應函數值，而依據適應函數值可以得知目前染色體上的基因排列是屬於較好的或是較差的。

2.1.3 選擇染色體

選擇染色體的步驟是為了從族群中所有的染色體選出兩個或兩個以上的染色體當作父代與母代,利用選出來的染色體之後進行交配或突變的動作。一般常用的選擇方式有輪盤式選擇法與競爭式演算法。

2.1.4 交配

利用選擇方法所選出的染色體來做交配的動作,藉此產生下一個子代。通常由父代與母代兩個染色體產生新的子代。而一般常用的交配方法有單點交配、雙點交配與均勻交配。

2.1.5 突變

經過數次的迭代之後,染色體之間的相似性越來越高,若持續演化下去,則無法產生差異性較大的結果,為了可以獲得出其他演化結果,因此加入了突變的動作,如此將能夠改變目前相似的結果,使得產生不同的子代演化下去。

2.1.6 取代

經由交配或突變所產生出新的染色體,則會取代原有族群中的某些染色體,以維持固定數量的族群。一般常用的取代方法為隨機取代和精英取代。

2.1.7 終止條件

若滿足 1. 獲得最佳解 2. 達到預設的迭代次數,兩者其中之一的條件,則停止演算法。

2.2 資料探勘

資料探勘(Data mining)的定義為從資料中擷取出隱藏性的、有意義的、以及具有潛在價值的訊息[8],是一個為了能夠從大量的資料或者資料庫中提取出有用資訊的新研究主題。其利用統計分析等方法,到資料中尋找有用的特徵(Patterns)以及關連性(Relationships)。而一般而言,資料

探勘的功能包含了:分類(Classification)、推估(Estimation)、預測(Prediction)、關聯規則(Association rule)和分群(Clustering)。

在關聯規則的部分,以市場買賣物品為例,其關聯法則就是表示什麼物品與什麼物品相關,常被一起購買就是有具有相關性,可搭配促銷,在賣場中應擺在一起,如此對客戶較方便。而支持度(Support)與信賴度(Confidence)是取得關聯規則的兩個重要變數;支持度代表著物品在所有資料中出現的次數,其數目不能過小,否則將失去預測準確性;而信賴度表示兩件物品間的相關程度,當高於某一門檻值,則表示此兩件物品間具有足夠的關聯性。

2.2 K 最近鄰居法

K 最近鄰居法(K-nearest neighbor)是由 Fix 和 Hodges 所提出,利用特定的距離測量方式如:歐幾里得距離(Euclidean distance)等方式,來找出最接近預測點的 K 個已知點,利用此 K 個已知點的結果來當作預測點的結果。在分類問題中,可由已知類別的資料利用 K 最近鄰居法對於未知類別的資料做分類,利用計算未知類別資料與已知類別資料的最小距離,計算後可得知依序有 K 個已知類別資料點與未知類別資料點的最小距離,此 K 個已知類別資料點的類別結果,其出現頻率最高的類別即是此未知類別資料的分類結果。

3 研究方法

此次研究的架構為利用基因演算法結合資料探勘的方式而構成新的演算法,在整個演算法部分仍是以基因演算法為主要架構,但另外新加入了資料探勘的方法。也因此,在基因演算法部分須要有所修改,我們在基因演算中新加入一個稱為 DNA 池的部分[11],此 DNA 池主要用於儲存經利用資料探勘方法探勘出染色體中重要的基因,編碼後所形成新的染色體。整個演算法流程圖如下:




圖 1. 演算法流程圖

3.1 演算法流程

以下會詳細說明整個演算法的流程，並如下步驟依序執行：

- 一、 初始設定基因演算法參數，依序為染色體數量、迭代次數、交配率和突變率。
- 二、 初始化支持度與信賴度陣列，支持度與信賴度陣列更新過程請參閱圖 2。
- 三、 依據適應值函數計算每個染色體的適應函數值。
- 四、 紀錄適應函數值高於門檻值的染色體（更新支持度與信賴度陣列）。
- 五、 執行交配與突變的動作。
- 六、 判斷是否符合終止條件。若符合則終止演算法，否則執行下一個步驟。
- 七、 判斷是否落入區域最佳解。若符合則執行下一個步驟，否則回至步驟 5。
- 八、 判斷所有染色體皆已記錄完畢，若符合則執行下一個步驟，否則記錄其他染色體。
- 九、 判斷信賴陣列是否滿足門檻值。

十、 符合門檻值的信賴值陣列重新編碼成新的染色體，並將其放入 DNA 池中。

十一、 將支持與信賴陣列歸零。

十二、 隨機從 DNA 池中選出一條染色體隨機取代一條原始的基因演算法族群中染色體。

十三、 回至步驟 3。

3.2 以資料探勘方法製作新的染色體

支持度與信賴度一般在資料探勘中是判斷是否具有關連性的重要變數，若支持度與信賴度超過所設定之門檻值時，則可判斷其具有關聯性。在此研究中，我們定義支持度 Sup 為一個一維的陣列，其陣列長度與染色體長度 n 相同，專門用來記錄符合門檻值的染色體中基因出現的次數。舉例來說，在一個維度為 10，二進位編碼的染色體 $C_k = f_1 f_2 f_3 f_4 f_5 f_6 f_7 f_8 f_9 f_{10}$ ，原始編碼為 $C_k = 1001000100$ ，若此染色體的適應函數值大於門檻值，則將編碼為 1 的基因位置記錄下來。而信賴度 $Conf$ 為一個行與列相同的二維陣列，陣列

大小的行與列與染色體長度 n 相同，用來記載符合門檻值的染色體中兩個基因 i, j 出現的比例。舉例來說，在一個維度為 10，二進位編碼的染色體，原始編碼為 $C_k = 1001000100$ ，此染色體第 1、4 和 8 的基因被編碼為 1，表示特徵被選取或是具有意義，因此記錄下 1、4 和 8 的組合，此例為記錄 $\{1,4\}$ 、 $\{4,1\}$ 、 $\{1,8\}$ 、 $\{8,1\}$ 、 $\{4,8\}$ 和 $\{8,4\}$ 。

我們定義 Th_a 當作支持度部分的門檻值，若某染色體的適應值大於 Th_a ， Sup 則記錄下該染色體的基因位置。定義 Th_c 當作信賴度的門檻值，若某染色體的適應值大於 Th_c ， $conf$ 則記錄下該染色體的組合。

3.2.1 支持度與信賴度更新演算法

1. 初始化 Sup 和 $Conf$ ，將此兩個陣列全部數值歸零。
2. 利用適應函數 f ，計算每個染色體 C_k 的適應函數值 $f(C_k)$ 。
3. 若 $f(C_k) \geq Th_a$
 - 3.1 染色體 C_k 中的基因 g_i 若不為零，則 $Sup[i] = Sup[i] + 1$
 - 3.2 染色體 C_k 中的基因 g_i 與 g_j 若不為零，則 $Conf[i, j] = Conf[i, j] + 1$ 且 $Conf[j, i] = Conf[j, i] + 1$
4. 重複步驟 2，直至所有染色體皆被記錄
5. 若已達到預設迭代次數，至下一步，否則回至步驟 2。
6. 更新 $Conf[i, j]$ 。利用 $Conf[i, j]$ 除以對應的 $Sup[i]$ 值來獲得更新後的 $Conf[i, j]$ 值。

$$Conf[i, j] = \frac{Conf[i, j]}{Sup[i]}。$$

3.3 編碼新的染色體

染色體經由數次迭代之後，有可能獲得最佳解，但也可能若入了區域最佳解。為了避免落入區域最佳解，此時即須要利用 Sup 與 $Conf$ 值編碼出新

的染色體，並加入原始族群中來幫助跳脫目前的區域解。利用 Sup 與 $Conf$ 值所編碼成新的染色體在此我們稱其為 $DNA[11]$ ， DNA 被編碼完成之後會放入 DNA 池中， DNA 編碼過程如下：

DNA編碼演算法

1. 設定一長度與原始染色體長度 n 一樣之陣列，稱其為 $DNA[n]$ 。
2. 找出 Sup 最大值的陣列位置，並定義其為 max_i 。
3. 搜尋 $Conf$ 中第 max_i 列，若 $Conf[max_i, j]$ 中第 j 個數值大於 Th_c ，則第 $Conf[max_i, j]$ 數值記錄在 $DNA[j]$ 中。
4. 搜尋完 $Conf$ 中第 max_i 列並依序記錄後， $DNA[n]$ 即為一新染色體，將其放入 DNA 池中。

在圖 2 中，依序用(圖 2-1)至(圖 2-9)來描述 DNA 的編碼。此例中原始的染色體數量為 5 條染色體，每條染色體的長度為 5，適應函數為 f ；此 5 條染色體 C_1 至 C_5 的編碼及依據編碼條件利用適應函數所計算出的適應函數值如下所示，而支持度門檻值 Th_a 與信賴度門檻值 Th_c 依序為 0.6 和 0.5。(圖 2-1)為初始 Sup 和 $Conf$ 陣列，兩個陣列數值皆設定為 0。(圖 2-2)為 Sup 和 $Conf$ 記錄第一條染色體 C_1 時，由於 C_1 的適應函數值大於 Th_a ，所以 Sup 和 $Conf$ 依據 DNA 編碼演算法更新 Sup 和 $Conf$ ；(圖 2-3)為 Sup 和 $Conf$ 記錄第二條染色體 C_2 時，由於 C_2 的適應函數值也大於 Th_a ，所以 Sup 和 $Conf$ 依據更新演算法持續更新；(圖 2-4)至(圖 2-7)依序為第 3 至第 5 條染色體的 Sup 和 $Conf$ 更新，不過由於第 4 條染色體 C_4 的適應函數值小於 Th_a ，所以在(圖 2-6)中可以看到 Sup 和 $Conf$ 的更新將不會有變動。最後，依據編碼演算法判斷 Sup 陣列最大值為陣列中第 1 行，定義為 max_1 ，搜尋 $Conf$ 中第 max_1 列，依序判斷 $Conf[max_i, j]$ 中第 j 個數值是否大於 Th_c ，由(圖 2-8)可得知第 2、3 和 5 行大於 Th_c ，如此可組成一組(圖 2-9)新的二進位染色體，並置入 DNA 池中。

$$C_1 = 11100 \quad f(C_1) = 0.8$$

$$C_2 = 10110 \quad f(C_2) = 0.75$$

$$C_3 = 10101 \quad f(C_3) = 0.7$$

$$C_4 = 11001 \quad f(C_4) = 0.4$$

$$C_5 = 11010 \quad f(C_5) = 0.65$$

$$Th_a = 0.6, Th_c = 0.5$$

C_1	1	1	1	0	0
Sup	<u>1</u>	<u>1</u>	<u>1</u>	0	0
Conf	g_1	g_2	g_3	g_4	g_5
g_1		<u>1</u>	<u>1</u>	0	0
g_2	<u>1</u>		1	0	0
g_3	<u>1</u>	<u>1</u>		0	0
g_4	0	0	0		0
g_5	0	0	0	0	

(圖 2-2)

C_2	1	0	1	1	0
Sup	<u>2</u>	1	<u>2</u>	<u>1</u>	0
Conf	g_1	g_2	g_3	g_4	g_5
g_1		1	<u>2</u>	<u>1</u>	0
g_2	1		1	0	0
g_3	<u>2</u>	1		<u>1</u>	0
g_4	<u>1</u>	0	<u>1</u>		0
g_5	0	0	0	0	

(圖 2-3)

Sup	0	0	0	0	0
Conf	g_1	g_2	g_3	g_4	g_5
g_1		0	0	0	0
g_2	0		0	0	0
g_3	0	0		0	0
g_4	0	0	0		0
g_5	0	0	0	0	

(圖 2-1)

C_3	1	0	1	0	1
Sup	<u>3</u>	1	<u>3</u>	1	<u>1</u>
Conf	g_1	g_2	g_3	g_4	g_5
g_1		1	<u>3</u>	1	<u>1</u>
g_2	1		1	0	0
g_3	<u>3</u>	1		1	<u>1</u>
g_4	1	0	1		0
g_5	<u>1</u>	0	<u>1</u>	0	

(圖 2-4)

C_4	1	1	0	0	1
Sup	3	1	3	1	1
Conf	g_1	g_2	g_3	g_4	g_5
g_1		1	3	1	1
g_2	1		1	0	0
g_3	3	1		1	1
g_4	1	0	1		0
g_5	1	0	1	0	

(圖 2-6)

C_5	1	1	0	1	0
Sup	<u>4</u>	<u>2</u>	3	<u>2</u>	1
Conf	g_1	g_2	g_3	g_4	g_5
g_1		<u>2</u>	3	<u>2</u>	1
g_2	2		1	<u>1</u>	0
g_3	3	1		1	1
g_4	<u>2</u>	<u>1</u>	1		0
g_5	1	0	1	0	

(圖 2-7)

Sup	4	2	3	2	1
Conf	g_1	g_2	g_3	g_4	g_5
g_1		0.5	0.75	0.5	0.25
g_2	1		0.5	0.5	0
g_3	1	0.33		0.33	0.33
g_4	1	0.5	0.5		0
g_5	1	0	1	0	

(圖 2-8)

DNA	1	1	1	1	0
-----	---	---	---	---	---

(圖 2-9)

圖 2. 支持度與信賴度更新過程

3.4 將新染色體置入原始染色體中

當判斷原始的基因演算法已落入區域最佳解時，我們則執行將DNA池之染色體取代原始基因演算法族群中之染色體，使其之後能夠跳脫目前狀態，進而得到不同的演化結果。其方法為在DNA池隨機挑選一染色體，且在原始母體中也隨機挑選一

染色體，將從DNA池隨機挑選出之染色體取代原始族群中隨機挑選出之染色體。

3.5 應用於特徵選取

為使基因演算法能運用於特徵選取，在染色體的編碼部分，我們將染色體編碼為二進位來表示；

當位元值為 1 時，表示此特徵被選取，當位元值為 0 時，表示此特徵不被選取。以染色體 C_k 被編碼為 $C_k = 1001000100$ 時，表示第 1、第 4 和第 8 個特徵被選取，其他則不被選取。

3.6 資料正規化

在將要作特徵選取的分類資料中，為避免在辨識時資料彼此之間差異過大而影響分類正確率，我們採用標準的正規化方法[1]是將全部的資料先轉換成介於 0 至 1 的數值範圍來表示原始的資料，如此則可以減少分類時產生的錯誤，進而提高分類正確率。

3.7 分類正確率評估

在此次研究我們以 K 最近鄰居法當作適應函數，並搭配使用 Leave-one-out 交叉驗證方式來評估分類的正確率。我們依據每個染色體所選出的特徵，利用這些選出的特徵來表示原始資料，並使用 K 最近鄰居法搭配 Leave-one-out 交叉驗證方式做分類正確評估，而所得到的分類正確率，即是此研究的適應函數值。舉例來說，目前我們欲分類的每筆資料都各有 10 個特徵維度 $C_k = f_1f_2f_3f_4f_5f_6f_7f_8f_9f_{10}$ ，在演化過程中某一個染色體選出了 6 個特徵 $C_k = f_1f_3f_5f_7f_9f_{10}$ ，在計算適應值函數時，則將欲分類資料的選用這 6 個特徵當作資料維度利用 K 最近鄰居法做分類計算，分類之後所得到之分類結果即是我們的分類正確率。

4 實驗結果

在此次的研究中我們會呈現利用資料探勘結合基因演算法先作特徵選取後，利用分類器分類所得到之分類結果，比較不同的支持度與信賴度門檻值是否會有差異，並與原始之基因演算法作特徵選取分類後所得結果做比較。

4.1 研究資料集

我們使用了 UCI repository[2]資料集的 8 筆資料，分別為：glass、vowel、wine、vehicle、segmentation、wdbc、ionosphere 和 sonar，詳細資料如表 1。此 8 筆資料集中，特徵維度最小為 10，最大則是 60，挑選出原始的特徵數量有大有小，目的是為了比較特徵數量的大小是否會影響實驗結果。

表 1. 分類問題資料格式

檔案名稱	類別數	維度數量	資料數量
glass	7	10	213
vowel	11	10	990
wine	3	13	178
vehicle	4	18	846
segmentation	7	19	2310
wdbc	2	30	569
ionosphere	2	34	351
sonar	2	60	208

4.2 參數設定

在基因演算法部分染色體族群數量設定為 30，迭代次數 100 次，交配率 1.0，突變率 0.005，並採用單點交配。設定迭代次數若連續 3 次皆是獲得相同的最佳解值時則判斷落入區域最佳解。在分類器部分，K 最近鄰居法的 K 值設為 1。

4.3 結果

在此次的研究中，我們將支持度皆設定為 0.5，信賴度則是依序為 0.5、0.6、0.7、0.8 和 0.9；依據此些不同的參數，經由選取後的特徵做分類所得到的分類正確率，與利用原始基因演算法作特徵選取後所得到的特徵做分類所得到的分類正確率兩者做比較。表 2 為經由利用基因演算法與此次研究的方法做特徵選取後，利用所得到的特徵做分類計算所得到的分類正確率；其中 DM-GA(S, C)

表示不同的參數設定，S 表示支持度 Sup ，C 表示信賴度 $Conf$ ；圖 3-1 至圖 3-8 依序是 8 個檔案分

類正確率的曲線圖。




圖 3-1. Glass 在不同信賴度分類正確率曲線圖




圖 3-2. Vowel 在不同信賴度分類正確率曲線圖




圖 3-3. Wine 在不同信賴度分類正確率曲線圖




圖 3-4. Vehicle 在不同信賴度分類正確率曲線圖




圖 3-5. Segmentation 在不同信賴度分類正確率曲線圖




圖 3-6. Wdbc 在不同信賴度分類正確率曲線圖




圖 3-7. Ionosphere 在不同信賴度分類正確率曲線圖




圖 3-8. Sonar 在不同信賴度分類正確率曲線圖

圖 3. 8 個分類檔案在不同信賴度之分類正確率曲線圖

5 討論

我們的研究利用了資料探勘結合基因演算法來改善原始的基因演算法中容易落入區域解的問題；從結果中可以發現，將改善後的基因演算法用來做特徵選取，利用選取出的特徵做分類計算所得到的分類正確率比原始的基因演算法作特徵選取後所得到的分類正確率整體平均要來的高；我們發現不同的信賴度會得到不同的分類結果，在此 8 筆資料中，可以發現在導入了資料探勘的方法做特徵選取後皆可以得到比原始基因演算法作特徵選取後所得到的分類正確率要來的好，此結果可以說明我們導入了資料探勘的方式的確有改善了基因演算法區域最佳解的問題，進而提升其在最佳化問題部分的效果。

信賴度是資料探勘判斷兩個物品是否具有強烈關聯性的依據，當信賴度越強時，所能符合的物品將會越少，而信賴度越低時，所能符合條件的物品將會越多，也就是說當越高的信賴度時所找出的特徵關聯性越高，表示此特徵對於分類問題時的意義越大，因此信賴度越高越能提高分類正確率的結果，此次研究也符合此定義的結果；然而要注意的是不能只利用信賴度越高越能表示其關聯性越高的這一個單一條件來表示信賴度在尋找關聯法則中所具有的重要性，其中也要考慮到支持度的問題；支持度代表著單一物品的出現次數，支持度越大時，越能代表物品的意義，而支持度過小時，將無法代表物品是否具有意義，如同統計研究中當挑選母體夠大則越能代表真實性，若挑選母體太小，則無法確實具有代表性；也因此當支持度過小時將容易造成信賴度提高的假象，然而造成數據判斷的錯誤，因此支持度在設定時也需要特別注意，而此次研究設定支持度為 0.5，目的在於不要太輕易的將所有特徵列入考慮，但也不要設定太高造成日後計算可獲得的特徵樣本過少。從研究的結果發現，在維度比較小的資料集如 glass、vowel、wine、vehicle 和 segmentation 中，不同的信賴度與所得到的分類正確率似乎沒有什麼關聯，從圖 3-1 至圖 3-5 中可以看到，此 5 個檔案的分類正確率在不同的信

賴度會有不同的結果，但其分類結果不會因為信賴度的提升而得到更高的分類正確率；但在特徵維度較高的資料集上，如 wdbc、ionosphere 和 sonar，信賴度的大小似乎就影響了日後分類正確率的關係，從圖 3-6 至圖 3-8 中，此 3 個檔案中在越高的信賴度將會有越高的分類正確率；我們推測，造成此現象的原因在於當特徵數量較少時，由於數量不大，容易造成彼此間的關聯性提升，在信賴度門檻提升的實驗下，少量的資料也會造成符合高信賴度的條件，因此將無法正確的判斷出特徵間的關聯性是否真正的具有意義；但在高維度的資料中，在越高的信賴度門檻值條件的實驗下，越能提高在分類時的分類正確率，此原因在於由於特徵數量越多，若能符合信賴度的門檻值，表示此特徵的關聯性越強，越能表示特徵與特徵間的確具有較高的關聯，在此次研究作特徵選取的動作中，如此能夠選出真正具有意義的特徵，之後在做分類計算時，將可有效的提升分類正確率。

我們在基因演算法的族群數量設定為 30，目的在於不使運算時間過於冗長，我們另外採用了族群數量為 100 的相同研究中發現，在某些資料集的分類正確率是會有些許的提升，但仍無法有效的提升至滿意的結果，相對的造成增加無謂的計算時間，因此我們建議在此類問題的研究中，增加族群數量似乎不是獲得更好研究結果的唯一步驟；也因此我們開始在資料探勘的參數部分作變動，在本次的研究果中發現，在信賴度的部分確是個可以有更多值得討論的空間，而支持度的部分也可以再利用不同的數據來進行研究，日後我們將試圖採取不同的支持度以及增加信賴度的範圍來獲得更多的研究結果，或是利用不同的關聯性演算法來做特徵間關聯性的發掘，希望能夠獲得更好的研究成果。

6 結論

我們利用了資料探勘的方式結合基因演算法當作分類問題的特徵選取方法，經由實驗結果發現，利用我們的方法做特徵選取所得到的特徵作分類計算，所得到之分類結果平均為 94.07%，比原始的

基因演算法作特徵選取所獲得的分類正確率平均 93.71%要來的較好,表示此次研究所導入的資料探勘方法的確可以發掘出較有意義的特徵;因此,在日後相關的分類問題中,可以使用我們的方法當作分類前的前置處理方式,如此可發掘出較有意義的特徵,並降低運算時間及提高分類結果。

References

- [1] A. Statnikov, C.F. Aliferis, I. Tsamardinos, D. Hardin, and S. Levy, "A comprehensive evaluation of multicategory classification methods for microarray gene expression cancer diagnosis", *Bioinformatics*, Vol. 21, 2005, pp.631–643.
- [2] C. Blake and C. Merz. UCI repository of machine learning databases, 1998. URL: <http://www.ics.uci.edu/~mllearn/MLRepository.html>.
- [3] Elbeltagi E, Hegazy T, Grierson D. Comparison, "among five evolutionary-based optimization algorithms". *Advanced Engineering Information* 2005, 19(1):43-53.
- [4] Feng Tan; Xuezheng Fu; Yanqing Zhang; Bourgeois, A.G "Improving Feature Subset Selection Using a Genetic Algorithm for Microarray Gene Expression Data", *Evolutionary Computation*, 2006. CEC 2006. pp. 2529- 2534, Jul 16-21, 2006.
- [5] I.-S. Oh, J.-S. Lee, and B.-R. Moon., "Local Search-Embedded Genetic Algorithms for Feature Selection" *Proc. Int'l Conf. Pattern Recognition*, 2002.
- [6] J. Yang and V. Honavar., "Feature subset selection using a genetic algorithm". *IEEE Intelligent Systems*, 13:44-49, 1998.
- [7] Oh, I.- S., Lee, J.-S., and Moon, B.-R. Hybrid Genetic Algorithms for Feature Selection. *IEEE Trans. Pattern Analysis and Machine Intelligence*, Vol. 26, no.11, Nov. 2004.
- [8] Sigurdur Olafsson, Xiaonan Li and Shuning Wu, "Operations research and data mining", *European Journal of Operational Research*, Vol. 33, Issue 11, Available online 15 Nov. 2006.
- [9] P.L. Lanzi, "Fast feature selection with genetic algorithms: a filter approach", *IEEE International Conference on Evolutionary Computation*, pp. 537-540, 1997.
- [10] Wenqian Shang, Houkuan Huang, Haibin Zhu, Yongmin Lin, Youli Qu, and Zhihai Wang, "A Novel Feature Selection Algorithm for Text Categorization", *Expert Systems with Applications*, Vol. 33, Issue 1, July 2007.
- [11] Yi-Ta Wu, Y. J. An, J. Geller, and Y.-T. Wu, "A data mining based genetic algorithm," 3rd Workshop on Software Technologies for Future Embedded & Ubiquitous Systems, Gyeongju, Korea, April 2006.

表 2. 分類正確率

	GA	DM-GA (0.5,0.5)	DM-GA (0.5,0.6)	DM-GA (0.5,0.7)	DM-GA (0.5,0.8)	DM-GA (0.5,0.9)
glass	98.59	98.59	98.59	98.59	98.59	98.59
vowel	99.39	99.49	99.19	99.19	99.49	99.49
wine	98.88	98.31	98.88	98.88	98.88	98.31
vehicle	73.05	73.76	73.4	74.11	73.76	74.11
segmentation	97.71	97.75	97.49	97.71	97.53	97.75
wdbc	96.84	97.36	97.36	97.19	97.19	97.36
ionosphere	92.88	92.31	93.16	93.16	93.45	93.73
sonar	91.83	91.82	91.35	91.83	91.83	92.31
Average	93.65	93.67	93.68	93.83	93.84	93.96

註：DM-GA(S, C)中, S 表示支持度 *Sup*, C 表示信賴度 *Conf*