

生物晶片之探針辨識數目問題

吳哲賢

中華大學生物資訊學系

顏士勛、王立凡、陳顧仁

中華大學資訊工程研究所

摘要

生物晶片之探針辨識數目問題，目前相關研究只探討非週期性光罩序列類型。本論文將擴大研究領域至週期性光罩序列類型，假設探針序列長度為 m ，以及光罩序列長度為 $4n$ ，針對週期性同步光罩序列類型，首先提出時間 $O(mn)$ 演算法，計算探針辨識數目；接著提出線性時間 $O(m)$ 演算法，計算週期性非同步光罩序列類型之探針辨識數目。

1. 簡介

生物晶片(biochip)為將數量龐大的探針(probes)放在小面積的晶片上，利用雜交(hybridization)技術顯示擁有互補序列的探針位置[1, 5]。在醫療與生物工程上，有著短時間內作出大量檢驗的優勢。生物晶片上之探針，為分佈在核苷酸字元{A, T, G, C}上，長度約為 20 至 25 的序列。

光罩(mask)的目地為合成製造所需之探針，主要分為三大類型：週期性同步、週期性非同步、以及非週期[1, 4]，描述其特性如下。(一)週期性同步類型：光罩序列依照 ATGC 字元週期出現，探針在每一週期中只可合成一個字元。(二)週期性非同步類型：光罩序列依照 ATGC 字元週期出現，但是探針在每一週期中可合成不只一個字元。(三)非週期性類型：光罩序列不需依照 ATGC 字元週期出現，探針可在任意位置合成字元。

所謂探針辨識(realization)數目問題，為給定探針以及光罩序列下，找出探針序列在光罩序列位置上之所有辨識數目[2-3]。例如給定長度為 7 的光罩序列 AATTATC，可發現下列 4 個位置序列：(1, 3, 5, 6, 7)、(2, 3, 5, 6, 7)、(1, 4, 5, 6, 7)、以及(2, 4, 5, 6, 7)，皆可合成出探針序列 ATATC，因此探針辨識數目為 4。

針對非週期性類型，假設探針序列長度為 m 及光罩序列長度為 n ，Guénoche[3]已提出 $O(mn)$ 演算法計算探針辨識數目。本論文將擴大研究到週期性類型，假設探針序列長度為 m 以及光罩序列長度為 $4n$ ，首先針對週期性同步光罩序列，提出時間 $O(mn)$ 演算法；接著針對週期性非同步光罩序列，提出線性時間 $O(m)$ 演算法。

2. 非週期性探針辨識數目

非週期性類型為光罩序列不需依照 ATGC 字元週期出現，每一探針可在任意位置合成字元。針對非週期性類型，假設探針序列長度為 m 及光罩序列長度為 n ，Guénoche[3]已提出 $O(mn)$ 演算法計算探針辨識數目。利用表一及表二，舉例說明其演算法。

表一中，假設給定光罩序列 ATTATTACAC 以及探針序列 ATTAC，首先建立探針每個字元，在光罩序列上所有可能的合成位置。其中，符號+為第一次合成位置、符號-為最後合成位置、符號*為其餘合成位置。

接著，將表一轉換成表二。表二為探針序列 ATTAC 每個前置(prefix)子字串，在光罩序列 ATTATTACAC 每個位置上，探針所有可能辨識數目。最後將第一列的所有的值 20 及 3 相加，得到 23 即為最後所有探針辨識數目。

建構表一及表二的演算法，需要表格大小的時間複雜度。給定探針序列長度為 m 及光罩序列長度為 n ，則表格大小為 $m \times n$ 。因此 $O(mn)$ 時間，可計算出探針辨識數目。

現在我們設計如圖一的圖形，來表示表一及表二的演算法。在圖一中，點表示探針序列 ATTAC 每個字元在光罩序列 ATTATTACAC 所有可能的合成位置。探針兩相臨字元的合成位置，如果一前一後，則可拉一條線連接兩點。最後增加起點 S 連接到第一個字元之所有合成位置，以及最後字元所有合成位置連接到終點 E 。

利用累加路徑數目方式，計算從起點 S 到每個點的所有路徑數目。最後得到起點 S 到終點 E 之所有路徑數目 23，即為所有可能探針辨識數目。

我們所設計的演算法，應用了起點到終點所有路徑數目，即為所有探針辨識數目的特性。相較於 Guénoche[3]所提出，利用建立表格計算探針辨識數目的演算法，我們所提出的演算法較為簡單及易懂。

我們將利用此特性，推導到週期性同步以及週期性非同步類型的探針辨識數目問題，並進而設計出有效率之演算法。

3. 週期性同步探針辨識數目

本論文擴大研究範圍到週期性類型，包括週期性同步以及週期性非同步兩大類型。首先針對週期性同步光罩序列，假設探針序列長度為 m 以及光罩序列長度為 $4n$ ，我們將提出時間 $O(mn)$ 演算法，計算出探針辨識數目。

我們先設計時間 $O(m)$ 演算法，計算出探針最少合成週期數目。依照 ATGC 字元週期，掃描長度為 m 之探針序列，因此最多只需時間 $O(4m) = O(m)$ ，即可計算出探針最少合成週期數目。舉例說明如表三，假設探針序列為 ATTAC，依照 ATGC 字元週期掃描探針，可發現最少合成週期數目為 3：[AT][T][AC]。

假設給定光罩序列為 8 個週期的 ATGC 序列，總共有 32 個字元。由於探針在每一週期中只可合成一個字元，因此可推導出探針每個字元，在光罩序列上所有可能的合成位置如表四。其中符號 + 為第一次合成位置、符號 - 為最後合成位置、符號 * 為其餘合成位置。

接著，將表四轉換成圖二，探針兩相臨字元的合成位置，如果一前一後，則可拉一條線連接兩點。計算起點到終點所有可能路徑數目，因此終點 E 之路徑總數目 142，即為探針辨識數目。

針對週期性同步類型，會形成如圖三的位置關係圖。黑線連接為不同週期的點，紅線連接同週期的點。首先說明黑線規則：假設點坐標 (c, d) 表示每一週期第一個字元的所有可能位置， $f(c, d)$ 為點坐標 (c, d) 之所有路徑數目，可得到如下之遞迴關係式(recurrence relations)。

$$f(c, d) = \begin{cases} \sum_{i=1}^d f(c-1, i), & \text{for } c > 1 \\ 1, & \text{for } c = 1 \end{cases} \quad (1)$$

接著說明紅線規則：假設圖形有 a 行以及 b 列，共 $a \times b$ 個點，點坐標 (c, d) 表示每一週期非第一個字元的所有可能位置， $f(c, d)$ 為點坐標 (c, d) 之所有路徑數目，可得到如下之遞迴關係式。

$$f(c, d) = \begin{cases} \sum_{i=1}^{d+1} f(c-1, i), & \text{for } d < b \\ \sum_{i=d}^b f(c-1, i), & \text{for } d = b \end{cases} \quad (2)$$

描述我們所提出的 $O(mn)$ 時間演算法如下：首先利用 $O(mn)$ 時間建構探針每個字元，在光罩序列上所有可能的合成位置表；接著利用 $O(m)$ 時間計算探針最少合成週期數目 c ；然後利用上述兩結果，利用 $O(mn)$ 時間建構建構有 a 行以及 b 列的位置關係圖，其中 $a = m, b = n - m + 1$ ；最後利用 $O(mn)$ 時間計算起點到終點所有路徑數目 p ，即為探針辨識數目。

[演算法：週期性同步光罩之探針辨識數目]

輸入：|探針序列| = m , |光罩序列| = $4n$;

// 光罩序列為 n 個週期的 ATGC 序列//
建構探針在光罩的合成位置表; // $O(mn)$ 時間//
計算探針最少合成週期數目 c ; // $O(m)$ 時間//
建構探針及光罩之 $a \times b$ 個點的位置關係圖;
// $O(mn)$ 時間, $a = m, b = n - m + 1$ //
計算終點所有可能路徑數目 p ; // $O(mn)$ 時間//
輸出：探針辨識數目 p ;

4. 週期性非同步探針辨識數目

接著探討週期性非同步類型，光罩序列依照 ATGC 字元週期出現，但探針在每一週期中可合成不只一個字元。假設輸入探針序列長度為 m ，我們將提出線性時間 $O(m)$ 演算法，計算出探針辨識數目。

首先同週期性同步類型，先利用 $O(m)$ 時間，計算探針最少合成週期數目 c 。假設探針序列為 ATTAC，如表三可知最少合成週期數目為 $c = 3$ ：[AT][T][AC]。

接著建構探針每個字元，在光罩序列上所有可能的合成位置。給定長度為 $m = 5$ 探針序列 ATTAC，以及 $n = 8$ 週期的 ATGC 序列，總共 32 個字元的光罩序列，可得到合成位置如表五。

然後建構有 a 行以及 b 列的位置關係圖，其中 $a = m, b = n - c + 1$ 。將表五轉換成圖四，可得到 $a = m = 5, b = n - c + 1 = 8 - 3 + 1 = 6$ 的 5 行以及 6 列的位置關係圖。

最後計算起點到終點所有路徑數目 p ，即為探針辨識數目。在圖四中計算起點到終點所有可能路徑數目為 252，即為探針辨識數目。

針對週期性非同步類型，會形成如圖五的位置關係圖。假設圖形有 a 行以及 b 列，全部皆為黑線連接， $f(c, d)$ 為點坐標 (c, d) 之所有路徑數目，可得式(1)。分析式(1)之遞迴關係式，我們可推導出：

$$f(c, d) = \prod_{i=1}^{d-1} \left(\frac{c+i-1}{i} \right) = C_{c-1}^{c+d-2} \quad (3)$$

所以終點之所有可能路徑數目總合為：

$$f(a+1, b) = C_{a+1-1}^{a+1+b-2} = C_a^{a+b-1} \quad (4)$$

舉例說明計算探針辨識數目方法，輸入探針序列 ATTAC 以及 8 個週期的 ATGC 光罩序列，因此 $m = 5$ 及 $n = 8$ 。計算探針最少合成週期數目 $c = 3$ ，可得到 $a = m = 5, b = n - c + 1 = 8 - 3 + 1 = 6$ 。最後輸出探針辨識數目為：

$f(5+1,6) = C_5^{5+6-1} = C_5^{10} = 252$ (5)

描述週期性非同步類型之 $O(m)$ 線性時間演算法如下。

[演算法:週期性非同步光罩之探針辨識數目]
輸入:|探針序列|= m ,|光罩序列|= $4n$;
//光罩序列為 n 個週期的ATGC序列
計算探針最少合成週期數目 c ;// $O(m)$ 時間//
 $a = m, b = n - c + 1$;
輸出:探針辨識數目 C_a^{a+b-1} ;

5. 結論

假設探針序列長度為 m 及光罩序列長度為 $4n$ ，本論文先針對週期性同步光罩序列，提出 $O(mn)$ 時間演算法計算探針辨識數目。接著再針對週期性非同步光罩序列，提出線性時間 $O(m)$ 演算法計算探針辨識數目。

參考文獻


[1] S. Fodor, J. Read, M. Pirrung, L. Stryer, L. Tsai, and D. Solas, "Light-directed, spatially addressable parallel chemical synthesis", *Science*, vol. 251, no. 4995, pp. 767-773, 1991.
[2] A. Guénoche, "Supersequences of masks for oligo-chips", *J. Bioinformatics Comput. Biol.*, Sep.2(3), pp. 459-469, 2004.
[3] A. Guénoche, "About the design of oligo-chips", *Discrete Applied Mathematics*, vol. 147, Issue 1, pp. 57-67, 2005.
[4] A. Kahng, I. Mandoiu, P. Pevzner, S. Reda, and A. Zelikovsky, "Computer-Aided Optimization of DNA Array Design and Manufacturing", *IEEE Trans. Comput. Aided Des.*, vol. 25, no. 2, pp. 305-320, 2006.
[5] S. Kasif, Z. Weng, A. Derti, R. Beigel, and C. DeLisi, "A computational framework for optimal masking in the synthesis of oligonucleotide microarrays", *Nucleic Acids Res.*, vol. 30, no. 20, pp. e106, 2002.

表一、非週期類型：探針序列 ATTAC 在光罩序列 ATTATTACAC 上，可能合成位置表。
符號+為第一次合成位置、符號-為最後合成位置、符號*為其餘合成位置。

位置	1	2	3	4	5	6	7	8	9	10
	A	T	T	A	T	T	A	C	A	C
A	+			-						
T		+	*		-					
T			+		*	-				
A				+			*		-	
C								+		-

表二、非週期類型：探針序列每個前置子字串，在光罩序列每個位置上，探針所有辨識數目。

位置	1	2	3	4	5	6	7	8	9	10
	A	T	T	A	T	T	A	C	A	C
A	20			3						
T		11	6		3					
T			5		3	3				
A				2			2		1	
C								1		1




圖一、非週期類型：起點 S 到每個點的可能路徑數目。最後終點路徑數目 23，即為探針辨識數目。
表三、探針序列 ATTAC 最少合成週期數目為 3：[AT][T][AC]。


週期	1	2	3
	A T G C	A T G C	A T G C
A	A		
T	T		
T		T	
A			A
C			C

表四、週期性同步類型：探針每個字元在光罩序列上所有可能的合成位置。

位置	0 0 0 0	0 0 0 0	0 1 1 1	1 1 1 1	1 1 1 2	2 2 2 2	2 2 2 2	2 3 3 3
	1 2 3 4	5 6 7 8	9 0 1 2	3 4 5 6	7 8 9 0	1 2 3 4	5 6 7 8	9 0 1 2
	A T G C	A T G C	A T G C	A T G C	A T G C	A T G C	A T G C	A T G C
A	+	*	*	-				
T		+	*	*	-			
T			+	*	*	-		
A				+	*	*	-	
C						+	*	-




圖二、週期性同步類型：終點路徑總數目 142，即為探針辨識數目。




圖三、週期性同步類型：圖形有 a 行以及 b 列，黑線連接不同週期的點，紅線連接同週期的點。

表五、週期性非同步類型：探針每個字元在光罩序列上所有可能的合成位置。

位置	0	0	0	0	0	0	0	0	0	1	1	1	1	1	1	1	2	2	2	2	2	2	2	2	2	2	3	3	3			
	1	2	3	4	5	6	7	8	9	0	1	2	3	4	5	6	7	8	9	0	1	2	3	4	5	6	7	8	9	0	1	2
	A	T	G	C	A	T	G	C	A	T	G	C	A	T	G	C	A	T	G	C	A	T	G	C	A	T	G	C	A	T	G	C
A	+				*				*				*				*				-											
T		+				*				*				*				*				-										
T							+				*			*				*				*										
A												+			*			*			*				*		*					
C													+			*		*		*		*		*		*		*				



圖四、週期性非同步類型：終點路徑總數目 252，即為探針辨識數目。



圖五、週期性同步類型：圖形有 a 行以及 b 列，皆為黑線型式。