

由語料庫自動學習上下文無關文法

陳泰宏、陳嘉平

國立中山大學資訊工程學系

m943040071@student.nsysu.edu.tw cpchen@mail.cse.nsysu.edu.tw

摘要

本論文致力於研究從語料庫中自動學習上下文無關文法 (Context-Free Grammar) 的方法。我們定義了一個成本函數，並探討如何降低此成本。我們一方面研究如何透過自動學習，來從語料庫中獲得文法，一方面也比較不同的編碼方式對此成本的影響。在本論文中，我們採用兩種編碼方式：第一種方法比較簡單，即每一個符號的長度都是一樣的。第二種方法則採用 Shannon 編碼的方式。我們所使用的語料庫為中央研究院平衡語料庫。實驗結果顯示，採用 Shannon 編碼的方式對降低成本的效果較佳。

關鍵字：上下文無關文法、中文語言處理、中央研究院平衡語料庫。

1 簡介

在本論文中，我們探討由已標註詞性的語料庫中自動學習上下文無關文法 (Context-Free Grammar) [1]。雖然上下文無關文法並不足以涵蓋所有人類的語言，但是針對許多特定目的的工作而言，上下文無關文法已經足以應付這些工作了。而對於一個自然語言而言，一個好的上下文無關文法可以產生這個語言中大部份的句子；從另一個角度來看，這個語言中的每一個句子，也都很有可能可以用這個文法產生出來。

一般而言，要從語料庫中取得上下文無關文法是一項困難的工作。在此，我們希望能藉由自動學習的方法來取得一個上下文無關文法，而且這個文法所能產生的語言，必需包含這個語料庫中的所有句子。很明顯的，這樣的文法有無限多個。所以，我們定義了一個成本函數 (cost function) 來作為自動學習文法的依據。我們一方面研究如何透過自動學習，來從語料庫中獲得文法，一方面也比較不同的編碼方式對此成本的影響。在本論文中，我們使用了五種方法來獲得文法，而符號的編碼方式主要有兩種：第一種編碼方式比較簡單，即每一個符號的長度都一樣。第二種編碼方式則是採用 Shannon 編碼[2]，這是一種符號長度不同的編碼方式。實驗結果顯示，採用第一種編碼方式時，無法有效降低成本。另外，我們也針對這兩種編碼方式對成本的影響，作了一個簡單的比較。比較的結果，可以看的出來採用

Shannon 編碼的方式較佳。

本論文其餘內容安排如下：第二節介紹相關的研究。第三節說明實驗的方式。第四節針對實驗的結果進行討論。第五節為結論。

2 相關研究

與上下文無關文法的相關研究相當得多。在[3]中，一個只能產生一個句子的上下文無關文法，可以被轉換成一個更簡單的文法，而這個比較簡單的文法仍然可以產生上述的句子，而且這個轉換過程是一個無損耗的資料壓縮過程。[4]中提出了一個複雜度為 $O(N^2)$ 的隨機上下文無關文法 (stochastic context-free grammar) 的學習演算法，其中 N 為非終端 (non-terminal) 符號的個數。[5]中提出了一個使用模糊上下文無關文法 (fuzzy context-free grammar) 分析自然語言文本的演算法，這提供了一個分析自然語言的方法。

上下文無關文法的應用範圍很廣，[6][7]中建立了一個整合聲學分析、斷詞與分類、非線性時間對齊及動態規劃的自動語音辨識系統，這個系統可以用於連續語音的辨識工作。另外一個好處是，這個系統的辨識結果不需要再經過後處理。至於離散語音辨識系統 (isolated word recognition system) 的部份，[8]中也提出了一個以上下文無關文法為基礎的架構。另外，在資訊擷取 (information extraction)、問題答覆 (question answering)、互動式語音回應 (interactive voice response) 系統方面，上下文無關的文法的設計和實作也會影響這些系統的成敗。[9]中，上下文無關文法即被用於了解問題及答案。[10]則提出了一個可以自動產生和調整上下文無關文法的方法，並且將產生的文法用於互動式語音回應系統。

在我們先前的工作中[11]，我們定義了一個成本函數，而這個成本函數包含了兩個部份，第一個部份是為了要表示每一條規則，所必需花費的成本，即針對下列規則

$$A \rightarrow \beta \quad (1)$$

A 是一個非終端符號， β 是一些符號組成的字串，則 (1) 所需要的成本為

$$C_R = (1 + |\beta|) \log |\Sigma| \quad (2)$$

其中， Σ 為全部的符號所形成的集合， $|\Sigma|$ 為 Σ

表 1 中央研究院平衡語料庫統計資料。 $|V|$ 為符號集合的元素個數， q 為句子個數， $|R(S)|$ 為不同的句子的個數， N_q 為語料庫中符號個數， N_R 則為不同句子中的符號個數。

$ V $	Q	$ R(S) $	N_q	N_R
51	229852	203651	4838540	4729276

集合內元素個數。

第二個部份，則是以這些規則來表示語料庫中的每一個句子時，所需要花費的成本。假設由這些規則我們可以產生一個句子 W ，產生的過程如下

$$S \xRightarrow{R_1(s_1)} u_1 \xRightarrow{R_2(s_2)} u_2 \Rightarrow \cdots \Rightarrow u_m = W \quad (3)$$

所以我們可以把 W 用這些規則表示如下

$$W = R_{r_1}(s_1) R_{r_2}(s_2) \cdots R_{r_m}(s_m) \quad (4)$$

其中， $R_{ik}(s_k)$ 為左邊符號為 s_k 的規則中的第 ik 個。則 (4) 所需要的成本為

$$C_D = \sum_{k=1}^m \log |R(s_k)| \quad (5)$$

其中， $|R(s_k)|$ 為左邊符號為 s_k 的規則的個數。結合 (2) 和 (5)，即可得到全部所需要花費的成本

$$C = \sum_{i=1}^p C_R(i) + \sum_{j=1}^q C_D(j) \quad (6)$$

其中， p 為全部規則的個數， q 則為全部句子的個數。

在我們先前的工作中，我們只針對了下列形式的規則作研究

$$X \rightarrow YZ \quad (7)$$

我們所採用的語料庫為中央研究院平衡語料庫 (Academia Sinica Balanced Corpus)，我們將此語料庫經過前處理後，統計資料如表 1。

根據表 1 的統計資料，我們可以計算出成本的首值約為三千兩百二十萬，我們先前的實驗結果顯示，當得到第九十二條規則時，全部所需要的成本可以降到最低，約為兩千七百七十萬。

3 實驗方法

3.1 加入新規則

在第二節中所描述的工作，主要是自動學習 (7) 式中的規則形式，所以我們所得到的規則，並不包含下列形式

$$A \rightarrow B|C \quad (8)$$

所以，在此我們針對 (8) 這種規則作了一些實驗。有一點要注意的是，當套用 (8) 這種規則時，對於每一個符號 A ，都將會需要一個額外的成本來區別 A 應該變成 B 或 C 。以下列出了幾個我們嘗試過的方法，並針對實驗結果進行分析。

• 方法一：

挑選出現次數最多的兩個符號，假設是 B 和 C ，接著以新的符號（假設是 A ）取代全部的 B 和 C ，亦即加入 (8) 這條規則。

• 方法二：

挑出連續出現次數最多的符號組合，假設是 DB ，再從 $DX (X \neq B)$ 中挑選出現次數最多的一組，假設是 DC ，接下來與方法一相同，以新的符號取代全部的 B 和 C ，即加入 (8) 這條規則。

• 方法三：

挑出連續出現次數最多的符號組合，假設是 DB ，再從 $DX (X \neq B)$ 中挑選出現次數最少的一組，假設是 DC ，接下來與方法二相同，以新的符號取代全部的 B 和 C ，即加入 (8) 兩條規則。

• 方法四：

挑出連續出現次數最多的符號組合，假設是 YZ ，其出現次數假設是 F ，然後找出所有出現次數超過 $F/2$ 的符號組合，並對這些符號組合進行分類，將所有符號組合中的第一個符號相同的，歸類為一類；第二個符號相同的，也歸類為一類；因此，同一個符號組合，也有可能出現在不同類中。例如： BC 、 BD 、 BE 、... 屬於同一類； BD 、 CD 、 DD 、... 屬於同一類； BE 、 CE 、 DE 、... 屬於同一類，依此類推。然後，再從每一類中挑選出現次數最多的兩個符號組合，舉例來說，可能是 (BD, BE) 、 (BD, CD) 、 (CE, DE) 、...。再從這一對一對的符號組合中挑選出現次數總和最多的一對，假設是 (BD, CD) 。接下來與方法二相同，以新的符號取代全部的 B 和 C 。即加入 (8) 這條規則。

• 方法五：

從所有的符號中，任意取兩個符號出來，假設是 B 和 C ，接下來與前述方法相同，以新的符號取代全部的 B 和 C ，即加入 (8) 這條規則。然後再檢查成本是否有下降。

3.2 採用 Shannon 編碼

除了前述五種實驗方法之外，我們也採用了 Shannon 編碼的方式來重新計算成本。當我們採用 Shannon 編碼時，全部的規則所需要的成本為

$$\sum_{i=1}^p C_R(i) = \sum_{t=1}^{|V|} F(s_t) \log \frac{1}{P(s_t)} \quad (9)$$

其中， s_t 為 Σ 中的第 t 個符號， $F(s_t)$ 則為 s_t 在全部的規則中出現的次數， $P(s_t)$ 則為 s_t 的出現機率。這裡需特別說明的是，在 Shannon 編碼中，符號長度應該是

$$\left\lceil \frac{1}{\log P(s_t)} \right\rceil \quad (10)$$

在這裡為了能觀察成本的變化趨勢，所以直接以

$$\frac{1}{\log P(s_t)} \quad (11)$$

來做計算。相同的道理，全部的句子所需要的成本為

$$\begin{aligned} & \sum_{j=1}^q C_D(j) \\ &= \sum_{t=1}^{|R(S)|} F(R_t(S)) \log \frac{1}{P(R_t(S))} \end{aligned} \quad (12)$$

其中， $R_t(S)$ 為左邊是 S 的規則中的第 t 條規則， $F(R_t(S))$ 則為此規則在全部的句子中出現的次數， $P(R_t(S))$ 則為其出現機率

$$P(R_t(S)) = \frac{F(R_t(S))}{\sum_{k=1}^{|R(S)|} F(R_k(S))} \quad (13)$$

如果是套用 (7) 這種形式的規則，並不會產生額外的成本；相對地，如果是套用 (8) 這種規則，就會產生額外的成本。最後，結合 (9) 和 (12) 式，再加上額外的成本即可算出全部所需要的成本。

4 結果與分析

4.1 加入新規則

針對第三節所提出的實驗方法，分別針對其結果討論如下：

- 方法一：

這個方法實驗的結果顯示，挑選出現次數最多的兩個符號來作取代後，造成全部的 B 和 C 所需要的額外的成本太大，即使在其他地方可以減少成本，但是減少的量遠小於這些額外的成本增加的量，所以這個方法無法有效的降低成本。舉例來說，我們找到的

符號為 Na 和 VC ，而 Na 在全部的規則之中總共出現 100968 次， VC 則出現 97250 次，取代之後額外的成本總共需要 204883。在取代全部的 Na 和 VC 之後，有一些規則變成是一樣的，所以我們可以把重複的規則去掉（保留一條即可）。當我們把重複的規則去掉之後，可以發現全部的句子所需要花費的成本也跟著減少，但是減少的量只有 218.3，與上述的 204883 相較之下，實在是小太多了，所以全部所需要的成本並沒有減少。

- 方法二：

這個方法的實驗結果顯示，得到的結果與方法一類似。舉例來說，我們第一個挑選出來的符號組合為 $D \bullet M7$ ，符號 D 和符號 $M7$ 連續出現的次數為 4573 次；而第二個挑選出來的符號則為 $D \bullet VCL$ ，符號 D 和 VCL 連續出現的次數為 3718 次。接下來，我們用新符號來取代每一個 $M7$ 和 VCL 。取代之後，額外所需要的成本總共增加了 59551，而句子的成本只減少了 16.3，遠小於 59551。所以，全部所需要的成本仍然無法下降。

- 方法三：

這個方法的實驗結果顯示，得到的結果與方法一類似。舉例來說，我們第一個挑選出來的符號組合為 $D \bullet M7$ ，符號 D 和符號 $M7$ 連續出現的次數為 4573 次；而第二個挑選出來的符號則為 $D \bullet Neqb$ ，符號 D 和 $Neqb$ 連續出現的次數只有 1 次。接下來，我們用新符號來取代每一個 $M7$ 和 $Neqb$ 。取代之後，額外所需要的成本總共增加了 37461，比方法二的 59551 少，但是，在這裡句子的成本只減少了 1.63，還是遠小於 37461。所以，全部所需要的成本仍然無法下降。

- 方法四：

這個方法的實驗結果，與上述方法的結果類似。舉例來說，我們取到的出現次數最多的符號組合為 $D \bullet M7$ ，其出現次數為 4573。接著取得出現次數總和最多者為 ($VC \bullet M3$, $VC \bullet Nh$)。其中 $VC \bullet M3$ 出現次數為 4187，而 $VC \bullet Nh$ 出現次數為 4400。最後，再以新的符號取代每一個的 $M3$ 和 Nh 。取代之後，我們可以計算額外需要的成本為 138063，而句子成本只減少 140.1。很明顯，全部所需要的成本仍然無法下降。

- 方法五：

我們用這個方法檢查了全部的符號組合之後，發現均無法減少成本。這裡舉出兩個比較極端的例子做比較。第一個例子是取符號 DK 和 Dc 時， DK 和 Dc 在全部規則之中的出現次數都只有一次，所以用新的符號取代這兩個符號之後，額外所需要的成本只有增

加 2，是全部符號組合中額外成本增加最少的。但是，在全部的規則和句子的成本部份，並沒有下降，規則的部份成本增加了 32959，句子成本則是不變。所以，全部所需要的成本還是增加了。這個例子也是成本增加的最少的情況。第二個例子則是取符號 Nb 和 Nh 時， Nb 和 Nh 在全部的規則中出現的次數分別為 61687 和 70470 次。以新的符號取代這兩個符號之後，產生許多重複的規則，將這些重複的規則去掉後，規則數總共減少了 202 條，這也是規則數減少最多的狀況。另外，額外所需要的成本增加了 137982，而句子的成本只減少了 329，雖然這是句子成本減少最多的狀況，但是，比起 137982 還是差太多了。所以，全部所需要的成本仍然無法下降。

事實上，方法一到方法四，可以視為方法五的特例。所以，既然方法五無法讓成本下降，方法一到方法四當然也無法讓成本下降。其中，方法五已經採用了窮盡法來做測試，結果仍然找不到可以使成本降低的情形。所以，我們可以推測，在每一個符號的長度都相同的情況下，套用 (8) 這種規則會讓成本增加。

4.2 採用 Shannon 編碼

至於使用 Shannon 編碼的部份，我們利用 (9) 和 (12) 式計算出成本初值約為兩千六百四十萬，其中語料庫的初值如同表 1 所示。接下來，我們利用方法五檢查所有的符號組合。結果發現只有兩組符號組合可以讓成本下降。第一組取到的符號為 Nv 和 VA ，出現次數分別為 92681 和 83253 次。以新的符號取代這兩個符號之後，額外所需要的成本增加了 179413，而規則所需要的成本減少了 180196，句子的成本也減少了 568。所以整體而言，成本總共減少了 1351。第二組取到的則是 VC 和 VH ，其出現次數分別為 273038 和 275297 次。以新的符號取代這兩個符號之後，額外所需要的成本增加了 561045，而規則所需要的成本減少了 558439，句子的成本也下降了 3750。所以，全部所需要的成本總共減少了 1144。

4.3 不同編碼方式之比較

針對本論文中所提到的兩種編碼方式，我們簡單的以圖 1 來表示這兩種編碼方式對成本的影響。圖 1 中，節點 R 內的值即採用第一種編碼方式時，成本的初值，這時成本為三千兩百二十萬。從節點 R 往節點 N_1 移動，是指編碼方式改採 Shannon 編碼，節點內的值即為此時的成本值，為兩千六百四十萬。從節點 R 往節點 N_2 移動，是指套用 (8) 這種形式的規則，結果會使成本增加。從節點 R 往節點 N_3 移動時，表示是套用 (7) 這種形式的規則，結果可以使成本下降到兩千七百七十萬。從節點 N_1 往節點 N_4 移動時，是指套用 (7) 這種形式的規則，結

果可以使成本下降到兩千四百萬。從節點 N_1 往節點 N_5 移動時，是指套用 (8) 這種形式的規則，結果成本只有下降一千左右，下降幅度很小。從節點 N_3 往節點 N_6 移動時，是指編碼方式改採 Shannon 編碼，成本值可以下降到兩千四百三十萬。從節點 N_3 往節點 N_7 移動時，是指套用 (8) 這種形式的規則，結果成本是增加的。從這些討論可以看的出來，當編碼方式改成 Shannon 編碼時，可以有效的降低成本。

5 結論

在本論文中，我們提出了五種不同的方法來測試成本函數，其中第五個方法為窮盡法。我們檢查了所有可能的情形之後發現，當符號長度相同時，套用 (8) 這種規則會使成本增加，所以我們改用 Shannon 編碼的方式去做測試，實驗結果顯示，當符號長度不同時，成本才有可能下降。而且當我們採用 Shannon 編碼時，成本初值約為兩千六百四十萬。而在符號長度相同的情況下，成本初值為三千兩百二十萬。這之間的差距已經相當得多了。從上一節的討論中，我們可以得到一個結論，即採用 Shannon 編碼對於降低成本的效果較佳。

另外，從前面的討論中，我們可以發現，符號取代之後額外所需要的成本和規則成本的減少量，對於總成本是否下降的影響也很大。




圖 1 兩種編碼方式對成本的影響。(單位：百萬)。

參考文獻

- [1] J. E. Hopcroft, R. Motwani and J. D. Ullman, "Introduction to Automata Theory, Languages and Computation", Addison-Wesley (2001).
- [2] T. Cover and J. Thomas, "Elements of Information Theory", John Wiley and Sons,

- Inc., 1991, USA, ISBN: 0-471-06259-6.
- [3] John C. Kieffer and En-hui Yang, "Design of context-free grammars for lossless data compression", Proceedings of the 1998 IEEE Information Theory Workshop, pp. 84-85.
 - [4] H. Lucke, "Reducing the Computation Complexity for Inferring Stochastic Context-Free Grammar Rules from Example Text", Proceedings of ICASSP 1994, pp. 353-356.
 - [5] Patrick Carter and Stefan C. Kremer, "Fuzzy Grammar Induction from Large Corpus", Fuzzy Systems, 2006 IEEE International Conference on July 16-21, 2006 Page(s):2083 - 2089.
 - [6] H. Ney, "Dynamic Programming Speech Recognition Using a Context-Free Grammar", Proceedings of ICASSP'87, pp. 69 - 72.
 - [7] H. Ney, "Dynamic Programming Parsing for Context-Free Grammars in Continuous Speech Recognition", Signal Processing, IEEE Transactions on [see also Acoustics, Speech, and Signal Processing, IEEE Transactions on] Volume 39, Issue 2, Feb. 1991 Page(s):336 - 340.
 - [8] Chaiyaporn Chirathamjaree, "The Use of Context-Free Grammars in Isolated Word Recognition", TENCON 2004. 2004 IEEE Region 10 Conference Volume B, 21-24 Nov. 2004 Page(s):140 - 143 Vol. 2.
 - [9] C. Yuan and C. Wang, "Parsing Model for Answer Extraction in Chinese Question Answering System", Proceedings of IEEE NLP-KE '05, pp. 238 - 243.
 - [10] M. Balakrishna, D. Moldovan, E.K. Cave, "Automatic Creation and Tuning of Context Free Grammars for Interactive Voice Response Systems", Natural Language Processing and Knowledge Engineering, 2005. IEEE NLP-KE '05. Proceedings of 2005 IEEE International Conference on 30 Oct.-1 Nov. 2005 Page(s):158 - 163.
 - [11] Tai-Hung Chen, Chun-Han Tseng and Chia-Ping Chen, "Automatic Learning of Context-Free Grammar", Proceedings of Rocling 2006.
 - [12] 中央研究院漢語料庫的內容與說明, <http://www.sinica.edu.tw/SinicaCorpus/98-04.pdf>. Bart Simpson and Joe Isuzu. A not so junk paper in 1 day. *Journal of Junk Papers*, 1994.