

基於字尾樹演算法之避免交互雜交 DNA 微陣列探針集合自動化選擇研究

林婉婷

中華大學資訊工程研究所

侯玉松、吳哲賢

中華大學生物資訊學系

摘要

本論文研究目的為設計全基因組 DNA 微陣列探針集合自動化選擇軟體，以全基因組整體觀點，利用字尾樹演算法，自動化挑選避免交互雜交的探針集合。最後並以大腸桿菌的基因組序列做測試，探討軟體的執行效能。

1. 簡介

近年來，DNA 微陣列 (DNA microarray) 廣泛應用於基因體研究，其高產量的分析能力，使人類可以快速的對所有基因做分析檢測。

在 DNA 微陣列實驗中，探針(probe)通常是一段已知的單股核酸序列，目標物為待測樣本中的 mRNA 核酸序列，探針固定在微陣列上透過雜交反應(hybridization)，經螢光顯色後，以探針亮度觀察基因表現的相對量。

在微陣列中每一點的探針會有其互補的檢測 mRNA，而原則上一個探針應該只能與特定目標的 mRNA 雜交。所謂探針選擇問題是如何從成千上萬待檢測標的 mRNA 序列中，分別選取適當的序列片段為探針序列。

探針選擇問題要考慮許多因素，例如：GC 內容含量(GC content)、探針長度(probe length)、熔化溫度(melting temperature)、自我互補(self-complementarity)與交互雜交(cross-hybridization)。本論文僅就交互雜交因素，探討字尾樹(suffix tree)演算法，如何應用在探針選擇。

2. 研究方法

在生物基因組中，不同基因之間的序列相似性、不同探針之間的序列相似性，都有可能產生一個探針與多個基因的 mRNA 雜交，或一個基因的 mRNA 與多個探針雜交，造成探針非專一性，這些情形就叫做交互雜交，而交互雜交問題造成所測得的數據並非該基因的表現量，可能形成結果失真，使我們在分析微陣列時造成誤判[1]。

以過往探討微陣列交互雜交問題的文獻中，觀察到的交互雜交情形中，不同的探針與 mRNA 片段區域的序列，超過 50 個鹼基對的長

度，片段區域有連續 15 個鹼基對相同，或具有 75%相似度，則可能造成交互雜交的現象[2]。

本研究所採用的方法，是先避免連續 15 個鹼基對相同的現象，其方法是將測試物種的全部的 mRNA 序列，建構字尾樹，分別找出每段 mRNA 部分序列，與其他 mRNA 序列的最長共同字串的長度，再從這些長度資料中，找出小於 15 的部分序列，做為候選探針序列。

然後再避免具有 75%以上相似度的因素，其方法是使用區域對齊法(local alignment)，兩兩比對候選探針序列，再從中選出低於 75%相似度的候選序列，為探針序列，以達到自動化挑選避免交互雜交的探針集合。

在建構字尾樹方面，我們採用 Gusfield[2]團隊所開發的精確字串比對程式，稱作 strmat，其中的 Ukkonen 演算法的字尾樹建構程式，將測試物種的 mRNA 序列，一一插入到字尾樹中。

在計算每段 mRNA 部分序列與其他 mRNA 序列的最長共同字串的長度方面，我們利用先深搜尋法(depth-first search)，計算字尾樹的每個內部節點到樹根的距離為共同子字串的長度，與內部節點下含的樹葉資料，推測具有共同字串的 mRNA 部分序列的位置，建立成共同子字串長度資料表，再根據長度資料表，選擇候選探針序列。

為說明選擇候選探針序列的過程，以字串 $S1 = \text{ttattaat}$ 和字串 $S2 = \text{atgtaat}$ 和字串 $S3 = \text{attatgat}$ 為三條 mRNA 序列，假設使用者要找長度為 6，連續相同鹼基對長度上限 4 的探針序列為例，附錄圖一為三序列所建立的字尾樹示意圖。

接下來利用先深搜尋，求出每個內部節點到根節點的距離，例如：走到第一個內部節點得知為 1:6、2:5 的內部節點，從根節點到此內部節點的長度為 3 是第一個及第二個字串的共同子字串，所以將此長度記錄在第一個字串第六個字及第二個字串第五個字的位置，如圖二，依序建立出共同子字串長度資料表，完成後，則可得知每個序列中的字尾樹為與另二個序列中相同的子字串長度，如圖三。

再來建立候選探針表(如圖八)，利用使用者輸入的資訊及滑動視窗找出每個序列中的候選探針及其與其他序列共同子字串長度的最大值，流程如圖四至圖七。

再從圖八的候選探針表中，選擇共同子字

串長度最小值且符合使用者要求的序列為探針，由我們假設的探針長度為 6、上限長度為 4，所以最後可得到結果為：

S1：由於圖八的 S1 表格內的共同子字串長度皆為 4，並不小於 4，代表連續相同鹼基對長度抵觸使用者的上限，所以無探針結果。

S2：圖八的 S2 表格內，第一格的共同子字串長度為 3，小於 4，可選出 S2 的第 1 至 6 字 atgtaa 為探針。

S3：圖八的 S3 表格內，第三格的共同子字串長度為 3，小於 4，可選出 S3 的第 3 至 8 字 tatgat 為探針。

3. 測試結果

本論文的實驗數據以大腸桿菌的微生物基因組來探討，主要以大腸桿菌(*Escherichia coli* K12)為主，由於大腸桿菌含有 4254 條開放讀碼區序列，實驗資料採用 NCBI 網站的資料庫中取得的微生物基因組資料來進行，資料取得位置為 <ftp://ftp.ncbi.nih.gov/>。

本論文實驗使用的硬體配備，架構於單機環境下，電腦規格如表一。

本 DNA 微陣列探針集合自動化選擇系統是由 Visual C++ 撰寫，實驗在單機架構下，針對 *Escherichia coli* K12 使用字尾樹設計的 DNA 微陣列探針集合自動化選擇系統，進行三次實驗，其探針長度分別取 60、70、80，表二為不設限連續相同鹼基數上限所求得的探針組，根據文獻得知不同的探針與 mRNA 片段區域的序列，超過 50 個鹼基對的長度，片段區域有連續 15 個鹼基對相同，則可能造成交互雜交的現象，表三為連續相同鹼基數上限定為 15 的實驗結果。

原則上，一個目標基因應有一個相對應的探針，由表二可知，若無考慮條件限制，則本系統可有效的找出目標基因相對應的探針，但事實上基因組中可能有相同重複序列再加上條件限制，所以不可能達到 100%，由表三實驗數據可以得知若探針長度為 60 則得到的探針數量比例為 98.17%，探針長度為 70 則得到的探針數量比例為 97.90%，探針長度為 80 則得到的探針數量比例為 97.41%，整體來說本論文方法可以為整個基因組中的基因找到唯一探針比例高達 97% 以上，以這樣的比例來說是相當高的，而且程式執行時間在 540 秒以內，應足以符合 DNA 微陣列探針實務上的需要。

此外由於根據文獻，序列相似度太高也是造成交互雜交的原因之一，序列有 70~80% 相似度時也有可能會有交互雜交，因此再利用 local alignment 去比較探針組與基因組間的相似度，

而 local alignment 所需的參數則參照 NCBI 的 BLAST2 的預設值 (match=1, mismatch=-2, gap=-2) 得到的結果如表四、表五、表六所示。

若選出的探針序列相似超過 80% 以上則明顯有交互雜交的情形產生，再看表四中 80% 以上佔 6.1%、表五中 80% 以上佔 2.62%、表六中 80% 以上佔 1.8%，以這個結果來看，其在所挑選出的探針組所佔比例甚低，效果良好。

經由比較表四、表五、表六後，在相同相似度下，探針序列越長，則序列越少，其發生交互雜交的可能性也越低，故平衡探針的適用性和控制實驗上的成本，將取決於使用者所輸入的條件閾值。

4. 結論


DNA 微陣列技術廣泛應用在生物醫學領域，而配合過去的文獻資料，我們知道在 cDNA 微陣列實驗中交互雜交影響著實驗結果，增加實驗的誤差，降低晶片的使用正確率，所以交互雜交問題是值得注意的。而過去所設計出來的基因探針選擇軟體需要耗費許多時間或僅適合探針較短的寡核苷酸微陣列，本論文利用字尾樹找尋共同子字串的特性和其線性時間和空間技術，加速序列相似度比對工作，克服耗費時間與記憶體空間的技術問題，以完成全基因組 DNA 微陣列探針選擇軟體。

而運用在基因表現的觀察，結合醫學的實驗，觀察檢測基因表現，並且降低晶片成本，設計出可避免交互雜交的探針更為重要，本論文以避免片段區域有連續 15 個鹼基對相同的方式來設計，並求基因組中每個基因都有一個相對應的唯一探針，希望能夠為專家們在做實驗時，提供一組可避免交互雜交的探針選擇，使其實驗結果數據更精準、正確。

參考文獻

- [1] 許維中, cDNA 微陣列晶片上探針交互雜交問題之探討與分析, 長庚大學資訊管理研究所碩士論文, 2005。
- [2] M.D. Kane, Jatkoe T.A., Stumpf C.R., Lu J., Thomas J.D. and Madore S.J.. Assessment of the sensitivity and specificity of oligonucleotide (50mer) microarrays. *Nucleic Acids Res.*, 28, 4552–4557, 2000.
- [3] D. Gusfield, *Algorithms on strings, trees, and sequences : computer science and computational biology*, New York Cambridge Press, 1997.

附錄




圖一：字串 ttattaat 和字串 atgtaat 和字串 attatgat 的字尾樹示意圖

S1								S2								S3							
t	t	a	t	t	a	a	t	a	t	g	t	a	a	t	a	t	t	a	t	g	a	t	
					3							3											


圖二：建立共同子字串長度資料表

S1								S2							S3							
t	t	a	t	t	a	a	t	a	t	g	t	a	a	t	a	t	t	a	t	g	a	t
4	3	4	3	4	3	2	1	3	2	1	4	3	2	1	4	4	3	3	2	1	2	1


圖三：共同子字串長度資料表




圖四：建立候選探針表流程-1




圖五：建立候選探針表流程-2



圖六：建立候選探針表流程-3



圖七：建立候選探針表流程-4



圖八：建立候選探針表

表一：電腦規格表

軟體名稱	規格
中央處理器	Celeron(R) 3.06G
記憶體	1.50GB
作業系統	Windows XP
編譯器	Microsoft Visual C++ 6.0

表二：不同探針長度的實驗數據

生物名稱		Escherichia coli K12	
序列數量		4254	
探針長度	探針數量	100%相同序列	執行時間(秒)
60	4204	50	530
70	4204	50	507
80	4204	50	474

表三：不同探針長度及考慮相同鹼基對上限的實驗數據

生物名稱		Escherichia coli K12	
序列數量		4254	
探針長度	探針數量		執行時間(秒)
	符合條件	不符合條件	
60	4176(98.17%)	78	531
70	4165(97.90%)	89	532
80	4144(97.41%)	110	535

表四：長度 60 的各相似度序列數

探針長度	60
探針數量	4176
相似度	序列數
70%以上	1478(35%)
75%以上	740(17.7%)
80%以上	256(6.1%)

表五：長度 70 的各相似度序列數

探針長度	70
探針數量	4165
相似度	序列數
70%以上	521(12.5%)
75%以上	218(5.2%)
80%以上	109(2.62%)

表六：長度 80 的各相似度序列數

探針長度	80
探針數量	4144
相似度	序列數
70%以上	198(4.77%)
75%以上	113(2.72%)
80%以上	75(1.8%)