

生物晶片之不相交雙探針辨識問題

吳哲賢、侯玉松

中華大學生物資訊學系

摘要

生物晶片製程主要有光罩蝕刻法與點墨法兩種，光罩蝕刻法之光罩序列類型分為三大類：非週期性、週期性同步、以及週期性非同步。假設探針序列長度為 m ，光罩序列長度為 n ，生物晶片之不相交雙探針辨識問題，目前相關研究只針對非週期性光罩序列類型提出時間 $O(m^2 + 4n)$ 演算法。本論文將擴大研究領域至週期性光罩序列兩類型，針對週期性同步光罩序列類型，首先提出時間 $O(m^2)$ 演算法；接著亦提出時間 $O(m^2)$ 演算法，解決週期性非同步光罩序列類型之不相交雙探針辨識問題。

1. 簡介

生物晶片(biochip)是將數量龐大的探針(probes)放在小面積的晶片上，利用雜交(hybridization)技術顯示擁有互補序列的探針位置[1, 5]。在醫療與生物工程上，有著短時間內作出大量檢驗的優勢。生物晶片上之探針，為分佈在核苷酸字元{A, T, G, C}上，長度約為 20 至 25 的序列。

生物晶片製程主要有光罩蝕刻法(photolithographic synthesis)與點墨法(spotted)兩種，光罩蝕刻法之光罩(mask)目的為合成製造所需之探針，主要分為三大類型：週期性同步、週期性非同步、以及非週期[1-4]，其特性描述如下。(a)週期性同步類型：光罩序列依照 ATGC 字元順序週期出現，探針在每一週期中只可合成一個字元。(b)週期性非同步類型：光罩序列依照 ATGC 字元順序週期出現，但是探針在每一週期中可合成不只一個字元。(c)非週期性類型：光罩序列不需依照 ATGC 字元順序週期出現，探針可在任意位置合成字元。表一為探針 ATAGC 在三大光罩序列下，探針合成的方法。

探針合成過程中，如果有對應光罩產生錯誤，則無法正確合成出所需要之探針。為增加生物晶片製程之可靠度及容錯能力，針對重要探針，設計出兩組光罩序列不相交的合成方法，如果萬一光罩產生錯誤，仍然可正確合成出所需要之重要探針。

所謂不相交雙探針辨識問題(two-disjoint realization)，為給定光罩序列 S 及探針序列 P ，找出探針序列 P 在光罩序列 S 上，兩種互相沒有交集的最短光罩序列合成方法。表二中非週期性光罩序列 S 為 ACGACGACTACT，探針序

列 P 為 ACGACT。在表(a)中探針序列 P 只得到一種辨識方法，而在表(b)中，探針序列 P 在光罩序列 S 上，得到+及-兩種互相沒有交集的合成方法。

針對生物晶片之不相交雙探針辨識問題，假設探針序列長度為 m 及光罩序列長度為 n ，目前相關研究[3]，只針對非週期性光罩序列，提出時間 $O(m^2 + 4n)$ 演算法。本論文將擴大研究領域至週期性同步以及週期性非同步兩光罩序列類型，針對週期性同步光罩序列類型，首先提出時間 $O(m^2)$ 演算法；接著亦提出時間 $O(m^2)$ 演算法，解決週期性非同步光罩序列類型之不相交雙探針辨識問題。

2. 週期性同步不相交雙探針辨識

週期性同步光罩序列類型之特性為，每一 ATGC 週期內，單一探針只能合成一個字元，即下一個字元需在下一個週期合成。兩探針字元如果不同，可在同一週期合成；如果兩探針字元相同，則需要在不同週期合成。要確保探針辨識方法的不相交，只需對探針序列做比對時，將相同的字元錯開即可，因為這樣即代表兩探針不會在相同的週期內合成相同的字元。

給定光罩序列 S 長度為 n 及探針序列 P 長度為 m ，本論文設計意義上相似的兩種方法：最短完成合成週期法及最多同時合成週期法，皆可解決週期性同步光罩序列之不相交雙探針辨識問題。

一、最短完成合成週期法

本論文定義 $G(i, j)$ 為探針序列 P 之長度 i 與長度 j 的不相交雙探針序列 P_1 及 P_2 辨識方法所需最短完成合成週期長度。 $G(i, j)$ 之初始值為 $G(i, 0) = i$ 、 $G(0, j) = j$ 、 $G(0, 0) = 0$ 。遞迴關係式如下：

$$G(i, j) = \text{Min} \begin{cases} G(i, j-1) + 1 \\ G(i-1, j) + 1 \\ G(i-1, j-1) + 1 & , P[i] \neq P_2[j] \\ G(i-1, j-1) + 2 & , P[i] = P_2[j] \end{cases}$$

表三中探針序列 P 為 AAATTTCC，光罩序列 S 為 ATGCATGC…。根據上述 $G(i, j)$ 之初始值及遞迴關係式，可得到表(a)。灰色部分為回溯路徑：平行路徑對應探針 P_1 、垂直路徑對應

探針 P2、對角線路徑對應探針 P1 及 P2 同時合成。表(b)表示回溯結果，共需要光單序列 11 週期，合成不相交雙探針。

二、最多同時合成週期法

本論文定義 $H(i, j)$ 為探針序列 P 之，長度 i 與長度 j 的不相交雙探針序列 P_1 及 P_2 辨識方法所需最多同時合成週期。 $H(i, j)$ 之初始值為 $H(i, 0) = 0$ 、 $H(0, j) = 0$ 、 $H(0, 0) = 0$ 。 $H(i, j)$ 遞迴關係式如下：

$$H(i, j) = \begin{cases} H(i, j-1) \\ H(i-1, j) \\ H(i-1, j-1) & , P_1[i] = P_2[j] \\ H(i-1, j-1) + 1 & , P_1[i] \neq P_2[j] \end{cases}$$

表四中探針序列 P 為 AAATTTCC，光單序列 S 為 ATGCATGC…。根據上述 $H(i, j)$ 之初始值及遞迴關係式，可得表(a)。灰色部分為回溯路徑：平行路徑對應探針 P1、垂直路徑對應探針 P2、對角線路徑對應探針 P1 及 P2 同時合成。表(b)表示回溯結果，最多同時合成 5 週期，所以共需要光單序列 11 週期，合成不相交雙探針。

上述兩種方法都因為動態規劃而要建立 $O(m^2)$ 的 $G(i, j)$ 及 $H(i, j)$ 表格，所以週期性同步不相交雙探針問題演算法之時間複雜度為 $O(m^2)$ 。

3. 週期性非同步不相交雙探針辨識

週期性非同步與週期性同步光單序列類型不同點在於，每一 ATGC 週期內，探針序列不只合成一個字元，若與探針序列目前要合成的字元相符合，便可直接合成，不同於週期性同步同一週期只能作一次合成的限制。

給定光單序列 S 長度為 n 以及探針序列 P 長度為 m ，本論文首先針對光單序列 ATGCATGC…，定義 $\text{Pos}(i, j)$ 為 A、T、G、C 字元在光單序列 S 位置 j ，下次重複出現位置，如表五所示。我們可利用下列式子，直接推導出 $\text{Pos}(i, j)$ 表格的值。

$$\text{Pos}(i, j) = \begin{cases} 4 \left\lceil \frac{j}{4} \right\rceil + 1 & , i = 1 \\ 4 \left\lceil \frac{j-1}{4} \right\rceil + 2 & , i = 2 \\ 4 \left\lceil \frac{j-2}{4} \right\rceil + 3 & , i = 3 \\ 4 \left\lceil \frac{j-3}{4} \right\rceil + 4 & , i = 4 \end{cases}$$

接著定義 $T(i, j)$ 為探針序列 P 之長度 i 與長度 j 的不相交雙探針序列 P_1 及 P_2 辨識方法所需最短完成合成光單序列長度。 $T(i, j)$ 表格第一列

$T(0, j)$ 與第一行 $T(i, 0)$ 之初始值，為探針序列 P 在光單序列 S 上由左至右的第一種可能辨識方法位置， $T(0, 0) = 0$ 。 $T(i, j)$ 遞迴關係式如下：

$$T(i, j) = \text{Min}\{\text{Pos}(P_1[i], T(i-1, j)), \text{Pos}(P_2[j], T(i, j-1))\}$$

表六中探針序列 P 為 TCACGCG，光單序列 S 為 ATGCATGC…。根據上述 $T(i, j)$ 之初始值及遞迴關係式，可得到表(a)。推導 $T(3, 4)$ 值，說明遞迴關係式如下：

$$\begin{aligned} T(3, 4) &= \text{Min}\{\text{Pos}(P_1[3], T(2, 4)), \text{Pos}(P_2[4], T(3, 3))\} \\ &= \text{Min}\{\text{Pos}(A, 12), \text{Pos}(C, 9)\} \\ &= \text{Min}\{13, 12\} \\ &= 12 \end{aligned}$$

灰色部分為回溯路徑：平行路徑對應探針 P1、垂直路徑對應探針 P2、數字代表對應光單序列合成位置。表(b)表示回溯結果，最短光單序列長度 27，合成不相交雙探針。

上述演算法建立 $O(m^2)$ 的 $T(i, j)$ 表格，遞迴關係式中只需要 $O(1)$ 時間即可推導 $\text{Pos}(i, j)$ 值，所以週期性非同步不相交雙探針問題演算法之時間複雜度為 $O(m^2)$ 。

4. 結論

不相交雙探針問題，假設探針序列長度為 m 及光單序列長度為 n ，本論文先針對週期性同步光單序列，提出 $O(m^2)$ 時間演算法。再針對週期性非同步光單序列，提出時間 $O(m^2)$ 演算法。

參考文獻

- [1] S. Fodor, J. Read, M. Pirrung, L. Stryer, L. Tsai, and D. Solas, "Light-directed, spatially addressable parallel chemical synthesis", *Science*, vol. 251, no. 4995, pp. 767-773, 1991.
- [2] A. Guénoche, "Supersequences of masks for oligo-chips", *J. Bioinformatics Comput. Biol.*, Sep.2(3), pp. 459-469, 2004.
- [3] A. Guénoche, "About the design of oligo-chips", *Discrete Applied Mathematics*, vol. 147, Issue 1, pp. 57-67, 2005.
- [4] A. Kahng, I. Mandoiu, P. Pevzner, S. Reda, and A. Zelikovsky, "Computer-Aided Optimization of DNA Array Design and Manufacturing", *IEEE Trans. Comput. Aided Des.*, vol. 25, no. 2, pp. 305-320, 2006.
- [5] S. Kasif, Z. Weng, A. Derti, R. Beigel, and C. DeLisi, "A computational framework for optimal masking in the synthesis of oligonucleotide microarrays", *Nucleic Acids Res.*, vol. 30, no. 20, pp. e106, 2002.

表一、探針序列 ATAGC 在三大光罩序列下，探針合成的方法。

(a) 週期性同步，光罩序列為 ATGCATGCATGCATGCATGC

	A	T	G	C	A	T	G	C	A	T	G	C	A	T	G	C	A	T	G	C
ATAGC	+					+			+						+					+

(b) 週期性非同步，光罩序列為 ATGCATGCATGCATGCATGC

	A	T	G	C	A	T	G	C	A	T	G	C	A	T	G	C	A	T	G	C
ATAGC	+	+			+		+	+												

(c) 非週期性，光罩序列為 CTATTATGCCATAT

	C	T	A	T	T	A	T	G	C	C	A	T	A	T
ATAGC			+	+		+		+	+					

表二、非週期光罩序列 S 為 ACGACGACTACT，探針序列 P 為 ACGACT。

(a) 探針序列 P 一種辨識方法

	A	C	G	A	C	G	A	C	T	A	C	T
ACGACT	+	+	+	+	+				+			

(b) 探針序列 P 在光罩序列 S 上，+ 及 - 兩種互相沒有交集的合成方法

	A	C	G	A	C	G	A	C	T	A	C	T
ACGACT	+	+	+	-	-	-	+	+	+	-	-	-

表三、最短完成合成週期法：探針序列為 AAATTTCC，光罩序列 ATGCATGC...

(a) 最短完成合成週期長度 $G(i, j)$

		A	A	A	T	T	T	C	C
	0	1	2	3	4	5	6	7	8
A	1	2	3	4	4	5	6	7	8
A	2	3	4	5	5	5	6	7	8
A	3	4	5	6	6	6	6	7	8
T	4	4	5	6	7	7	7	7	8
T	5	5	5	6	7	8	8	8	8
T	6	6	6	6	7	8	9	9	9
C	7	7	7	7	7	8	9	10	10
C	8	8	8	8	8	8	9	10	11

(b) 最短完成合成 11 週期，合成不相交雙探針

-	-	-	A	A	A	T	T	T	C	C
A	A	A	T	T	T	-	C	C	-	-

表四、最多同時合成週期法：探針序列為 AAATTTCC，光單序列 ATGCATGC...

(a) 最多同時合成週期 $H(i, j)$

		A	A	A	T	T	T	C	C
	0	0	0	0	0	0	0	0	0
A	0	0	0	0	1	1	1	1	1
A	0	0	0	0	1	2	2	2	2
A	0	0	0	0	1	2	3	3	3
T	0	1	1	1	1	2	3	4	4
T	0	1	2	2	2	2	3	4	5
T	0	1	2	3	3	3	3	4	5
C	0	1	2	3	4	4	4	4	5
C	0	1	2	3	4	5	5	5	5

(b) 最多同時合成 5 週期，共需要光單序列 11 週期，合成不相交雙探針

-	-	-	A	A	A	T	T	T	C	C
A	A	A	T	T	T	-	C	C	-	-

表五、Pos(i, j) 表格：光單序列 ATGCATGCATGC...

		0	1	2	3	4	5	6	7	8	9	10	11	12	...
		A	T	G	C	A	T	G	C	A	T	G	C	...	
1	A	1	5	5	5	5	9	9	9	9	13	13	13	13	...
2	T	2	2	6	6	6	6	10	10	10	10	14	14	14	...
3	G	3	3	3	7	7	7	7	11	11	11	11	15	15	...
4	C	4	4	4	4	8	8	8	8	12	12	12	12	16	...

表六、週期性非同步不相交雙探針辨識，探針序列為 TCACGCG，光單序列 ATGCATGC...

(a) 最短完成合成光單序列長度 $T(i, j)$

		T	C	A	C	G	C	G
	0	2	4	5	8	11	12	15
T	2	6	6	6	8	11	12	15
C	4	6	8	8	12	12	16	16
A	5	6	8	9	12	13	16	17
C	8	8	12	12	16	16	20	20
G	11	11	12	13	16	19	20	23
C	12	12	16	16	20	20	24	24
G	15	15	16	17	20	23	24	27

(b) 最短光罩序列長度 27，合成不相交雙探針

	1	5	9	13	17	21	25	29
	A T G C	A T G C	A T G C	A T G C	A T G C	A T G C	A T G C	A T G C
TCACGCG	+ +	+	+ +		+	+		
TCACGCG		- -		-	-	-	-	