

基因演算法應用於基因體之操作組預測

莊麗月

義守大學

化學工程系

chuang@isu.edu.tw

蔡瑞鴻

國立高雄應用科技大學

資訊工程系

1097308102@cc.kuas.edu.tw

楊正宏

國立高雄應用科技大學

資訊工程系

chyang@cc.kuas.edu.tw

摘要

操作組(Operon)為轉錄的基本單元,位於相同操作組的基因會共同轉錄成 mRNA 序列,因此預測操作組是了解轉錄規則的關鍵,然而經由實驗的方式檢測操作組相當困難且耗時,為了降低生物學家對於了解轉錄規則的困難,本研究提出以基因演算法應用於基因體(Genome)的操作組預測,我們使用二進制的編碼方式,改善以往使用實數編碼需於交配及突變後進行調整的缺點。並且藉由相鄰基因的距離及方向作為初始化的依據,使得母體染色體於初始化後即可獲得不錯的結果。在適應函數的部份,則是加入了特性選取的概念,將各個特性集合進行預測正確率(Accuracy, ACC)、敏感度(Sensitivity, SN)及特異度(Specificity, SP)的分析,以挑選最佳的特性集合。實驗結果顯示,由相鄰基因之距離搭配代謝路徑作為適應函數的計算標準最佳,其中大腸桿菌、枯草桿菌及綠膿桿菌的預測正確率分別為 0.900、0.906 及 0.916,相較於其他使用較多評分依據的方法,不僅能大幅減少時間的耗費,亦可有效的提升預測正確率。

關鍵詞：基因演算法、操作組預測、預測正確率、敏感度、特異度。

要功能是將乳糖分解成葡萄糖及半乳糖,其中包含了啟動子(Promoter)、終止子(Terminator)、操縱基因(Operator)及三個連續的結構基因(Structure gene),其中結構基因依序為 lacZ、lacY 及 lacA,皆由位於啟動子前端的調節基因(Regulator gene)lacI 控制基因表現,乳糖不存在時,調節基因會製造抑制蛋白(repressor)與操縱基因結合,使得 RNA 聚合酶無法與啟動子的結合,以抑制基因表現,乳糖存在時,乳糖會與抑制蛋白結合,使其無法活化,而能順利的進行轉錄。

近年來,許多學者提出了許多能夠準確預測 Operon 的特性,目前已使用的特性主要分為下列 5 種類別[2]:相鄰基因的距離(Intergenic distance)、基因族群的保存(Conserved gene clusters)、相關功能(Functional relations)、以基因體序列為基礎(Genome sequence based)及實驗證據(Experimental evidence),在上述的類別中,最具代表性的生物特性是在 Operon 邊界預測啟動子及終止子序列[1],而最簡單的預測特性則是觀察操作組中相鄰基因(Within operon pair, WO pair)的距離,是否小於轉錄單元邊界的相鄰基因(Transcription unit border pair, TUB pair)距離,距離不僅為最簡單的預測特性,使用距離辨識操作組的方式,也能獲得不錯的結果[2]。

1 前言

遺傳物質中儲存了許多訊息,透過轉錄的過程讀取所需的訊息後,細胞即可利用這些訊息製造 RNA 或蛋白質,而操作組(Operon)為轉錄的基本單元,因此想要了解轉錄的規則,預測 Operon 就成了一大關鍵。Operon 在藥物設計及蛋白質功能的研究上,揭露許多有價值的資訊,但目前所知的 Operon 不多,且生物學家以實驗檢測 Operon 相當困難且耗時[1],因此如何利用生物資訊的技術去發展一個有效的預測方法,成為目前相當重要且待解決的議題。在原始生物中,細菌的基因體是由數千個基因所組成,Operon 中包含了一個或多個同向連續的基因,它們會共同轉錄成單股的 mRNA 序列,通常相同 Operon 中的基因不是擁有相同的生物功能,就是在功能上互相影響。人類第一個發現的 Operon 是位於大腸桿菌中的乳糖 Operon,主

目前文獻中已提出預測操作組的方法,包含利用模糊基因演算法[1]、基因演算法[3]、支撐向量機[4]、隱藏馬爾科夫模型[5]及貝氏網路演算法[6],還有不需訓練集的預測方法[7],皆有不錯的預測結果。文獻支撐向量機[4]將相鄰基因的距離、代謝路徑、操作組對(Operon pair, OP)的保存數以及系統發育譜的交互資訊(Mutual information of phylogenetic profiles)作為輸入的向量,藉由分析各個向量的特性,將其分為操作組對及非操作組對(Non-operon pair, NOP)兩個類別,實驗結果獲得 0.90 左右的預測正確率。隱藏馬爾科夫模型[5]對於基因搜尋是一種相當具有價值的技術,因為它可以彈性的選擇各種特性進行預測,此文獻藉由預測操作組前端的 Promoter,以預測操作組的結構。貝氏網路演算法將相鄰基因的距離、密碼子、轉錄信號(Transcription signals)及表現資料等生物特性作為依據,藉由統計評估 OP 及 NOP 的機率,若 OP 的機率較大則判斷該相鄰基因位於相

同的 Operon 中。由於較新的基因體所能利用的基因註解較少，因此 Westover *et al.* [7] 提出以不需訓練集合進行操作組預測，藉由分群的方式適當將基因對分成 OP 及 NOP 兩個群集。Jacob *et al.* [1] 提出以模糊基因演算法為基礎，利用四個生物特性設計適應函數，使用的生物特性分別為：相鄰基因的距離、代謝路徑(Pathway)、保存於多個基因體中(Conservation across multiple genomes)、蛋白質功能的相似度(Similarity of protein function)，其特點在於依據上述特性設計了一套評分方法，不需要藉由複雜的數學公式計算，也可正確的對每條染色體(Chromosome)進行評分，使基因演算法能夠以此為依據，經由不斷的迭代來提升預測正確率。另外，基因演算法[3]所使用的四個生物特性分別為：相鄰基因的距離、代謝路徑、相鄰類基因功能的聚簇(Cluster of orthologous groups gene function, COG)和微陣列表示資料(Microarray expression data)，其中利用區域熵值最小化方法(Local-entropy-minimization method)計算相鄰基因的距離分數，若相鄰基因具有相同的代謝路徑則給予 1 分，否則不予給分，COG 及微陣列表示資料則是分別利用對數似然法(Log-likelihood)及皮爾森相關係數(Pearson correlation coefficient)進行評分，將以上 4 個生物特性的分數相加，作為相鄰基因的分數，藉此計算假定操作組(Putative operon)的分數，最後再將所有假定操作組的分數相加作為染色體的分數，利用這套評分機制作為評估染色體優劣的依據。上述兩篇文獻僅使用距離進行初始化，忽略了方向對於操作組預測的重要性，使得基因演算法無法於初始化時獲得較佳的母體染色體，也因為設定較低的交配率及突變率，較難藉由迭代的過程找尋染色體最佳解。

本文提出一個有效的基因演算法，應用於大腸桿菌(*Escherichia coli* K12-MG 1655)、枯草桿菌(*Bacillus subtilis*)及綠膿桿菌(*Pseudomonas aeruginosa* PA01)的基因體，以距離特性為基礎，並且增加方向的限制進行初始化，使母體在初始化後，便能獲得較佳的染色體母體，接著再藉由交配與突變的步驟，於每次迭代對母體進行更新。本研究在生物特性上的挑選，使用了相鄰基因的距離、代謝路徑及 COG 作為計算適應函數值的依據，亦分別將三個特性的七種組合作為適應函數，而獲得七個操作組預測的結果。由於本研究與文獻模糊基因演算法及基因演算法採用相同演算方法及特性來預測 Operon，因此我們將所得的預測結果與文獻進行比較，以證明本實驗的改良效果。實驗結果指出，使用距離搭配代謝路徑進行操作組預測的結果，與其他使用 4 個特性的基因演算法進行比較，不僅減少預測所需的時間，亦能獲得較高的預測正確率。

2 研究背景

2.1 問題定義

欲對所得的預測結果計算預測正確率，必須先對 OP 及 NOP 進行定義，本研究將 OP 定義為陽性，NOP 則定義為陰性。圖 1 中灰色的區塊表示該操作組由一個基因組成，黑色區塊表示該操作組由兩個以上的基因組成，而白色的區塊則是表示此基因尚未經由實驗證實，由圖中可知，OP 是指位於操作組中的相鄰基因，而 NOP 的必要條件與 OP 相同，即相鄰基因皆須位於相同方向，若操作組為單一基因組成，下一個基因為未知的狀態，則將此對基因對稱為 NOP，但操作組由多個基因組成時，則會因為操作組邊界尾端的不確定性[8]，無法將其稱為 NOP，而位於操作組的第一個基因與前一個基因皆稱為 NOP。




圖 1. 操作組對示意圖

2.2 生物特性

操作組中的基因具有許多相關的生物特性，本研究所使用的特性為下列 3 項：

- **相鄰基因的距離**：此特性可預測具有完整基因體序列的操作組，為了在降解(Degradation)的過程保護 mRNA，因此位於相同操作組的基因具有相鄰距離短之特性。如圖 2 所示，Gene₂、Gene₃ 及 Gene₄ 位於相同操作組，因此三個基因之間的距離會比 Gene₁ 及 Gene₂ 或 Gene₄ 及 Gene₅ 之間的距離短，距離的計算方式為相鄰基因的鹼基個數，會有重疊(Overlap)的情況發生，如圖 3 所示，OP 出現頻率最大的距離為 -4[9]，而 NOP 的距離分配頻率則是隨著距離的增加，逐漸高於 OP 的距離頻率，因此可藉由此特性辨別操作組。
- **相鄰類基因功能的聚簇**：總共分為三個等級，於第一個等級中又分為四個主要類別，而各個主要類別又細分為多個功能類別，若相鄰基因具有相同的主要類別，則有可能位於相同的操作組。
- **代謝路徑**：相鄰基因若有相同的代謝路徑，則有可能為相同的操作組。




圖 2. 操作組示意圖

表 1. 正確率評估公式表

預測結果 \ 真實資料	+	-	正負類預測評估
+	TP	FP	正類預測率 $PPR=TP/(TP+FP)$
-	FN	TN	負類預測率 $NPR=TN/(FN+TN)$
正確率評估	敏感度 $SN=TP/(TP+FN)$	特異度 $SP=TN/(FP+TN)$	預測正確率 $ACC=(TP+TN)/(TP+FP+TN+FN)$




圖 3. 距離分配頻譜

2.3 正確率評估

本研究利用醫學診斷最常使用的評估方式進行評估，如表 1 所示，若真實資料為陽性，且評估正確，則稱為真陽性(True Positive, TP)，反之則稱為真陰性(True Negative, TN)，若真實資料為陽性，卻評估為陰性，稱之為偽陰性(False Negative, FN)，反之則稱為偽陽性(False Positive, FP)，接著可藉由上述參數計算正類預測率(Positive Prediction Rate)、負類預測率(Negative Prediction Rate)、預測正類能力的敏感度(Sensitivity, SN)、預測負類能力的特異度(Specificity, SP)及評估整體預測能力的預測正確率(Accuracy, ACC)[10]；其中敏感度與特異度會存在一個相互拉扯(Trade-off)的關係，也就是說其中一者提高，另一者必定會降低，因此需藉由接受器操作特性曲線(Receiver operating characteristic curve, ROC curve)表示所有敏感度及特異度的相互關係，接著將斜率為 1 的直線與 ROC 曲線相切，該切點則為兩者相加的最大值，而曲線下的面積(Area under the curve, AUC)越大表示所得之預測正確率越高。

3 研究方法

3.1 資料來源

目前，文獻上只有大腸桿菌及枯草桿菌兩個基因體的操作組經由實驗證實[10]，因此本研究主要針對這兩個基因體進行操作組預測，此外文獻[3]中曾對綠膿桿菌基因體進行預測，因此本實驗也加入此基因體之預測，以獲得較客觀的結果。基因體資料皆由 GenBank 資料庫(<http://www.ncbi.nlm.nih.gov/>)下載，分別擁有 4488、4225 及 5651 個基因，其中記錄了各個基因的定義、名稱、編號、起始位置、終止位置、方向及產物名稱；大腸桿菌及枯草桿菌的操作組實驗資料分別由 OperonDB (<http://regulondb.ccg.unam.mx/>) [11] 及 DBTBS (<http://dbtbs.hgc.jp/>) [12] 兩個最具代表性的資料庫取得，*Pseudomonas aeruginosa* PA01 基因體的操作組資料則由 ODB (<http://odb.kuicr.kyoto-u.ac.jp/>) [13] 取得，其中記錄了各個操作組的名稱、基因個數、方向以及基因名稱；代謝路徑及 COG 資料則分別由 KEGG (<http://www.genome.ad.jp/kegg/pathway.html>) 及 NCBI (<http://www.ncbi.nlm.nih.gov/COG/>) 取得。

表 2. 各基因體相關資訊表

基因體	基因個數	已知操作組個數	已知操作組對	已知非操作組對
Escherichia coli K12-MG 1655	4488	2670	1785	1293
Bacillus subtilis	4225	1112	888	669
Pseudomonas aeruginosa PA01	5651	33	269	118

3.2 基因演算法(Genetic Algorithms)

基因演算法於 1975 年由 John Holland 所提出 [14]，理論基礎建構於達爾文所提出的物競天擇、適者生存進化論，是一種進化式演算法 (Evolutionary Algorithm, EA)，包含三個重要的基本運算子：選擇(Selection)、交配(Crossover)及突變(Mutation)。選擇運算子採用輪盤選擇法 (Roulette wheel selection) 挑選適應值較高的染色體進行交配，適應值越高被選取的機率就越大，反之被選取機率則越小。交配運算子的主要目的在於挑選父代及母代染色體的優點，產生較優良的子代染色體。突變運算子則是採用隨機多點同時搜尋的方式，增加染色體的多樣性，以避免落入區域最佳解的情形。本研究所使用的基因演算法是根據二進制的編碼方式進行，在初始化後即計算各個染色體的適應函數，以便使用輪盤選擇法挑選染色體進行單點交配，接著利用交配所得的子代染色體進行突變，最後再將適應函數值較佳的子代取代母體染色體，經由上述方式多次的迭代後，即可獲得適應函數值最佳的染色體。詳細的步驟分別介紹於下列各小節。

3.2.1 染色體編碼

本研究以二進制編碼的方式建構染色體，編碼為 1，表示此基因與下一個基因為 OP；編碼為 0，則表示此基因與下一個基因為 NOP，也可將此視為該操作組的最後一個基因。如圖 4 所示，若產生的二進制染色體為 110010，表示 Gene₁、Gene₂ 及 Gene₃ 屬於第一個操作組，Gene₄ 自成為一個操作組，而 Gene₅ 及 Gene₆ 則屬於最後一個操作組。




圖 4. 編碼示意圖

3.2.2 初始化

在本研究中，我們利用相鄰基因的距離及基因方向產生 20 組二進制染色體，每組染色體

藉由隨機產生 0 到 300 的亂數進行初始化。如圖 5 所示，假設取亂數 75 作為判斷門檻值，Gene₁ 及 Gene₂ 的距離為 70，並且於基因體中為同方向的情況，則將 Gene₁ 編碼為 1，而 Gene₂ 及 Gene₃ 的距離為 80，大於判斷門檻值，則將 Gene₂ 編碼為 0，若相鄰基因的距離小於亂數所設的門檻值，但方向相反，仍將其編碼為 0。計算距離的方式如公式 1 所示 [15]，其中 Gene_{1_finish} 為上游基因的鹼基終結位置，Gene_{2_start} 則為下游基因的鹼基起始位置。

$$\text{distance} = \text{Gene}_2_start - (\text{Gene}_1_finish + 1) \quad (1)$$




圖 5. 初始化示意圖

3.2.3 適應函數

由許多的文獻提供得知，對於操作組的預測問題，相鄰基因的距離特性相當具有影響力 [6][7][9][16][17]，因此本研究以此特性為主，並加入其它文獻所使用的特性進行實驗，如表 3 所示，距離的適應函數設計，是以區域熵值最小化方法 (Local-entropy-minimization method) [3]，評估每段距離間距的分數，若相鄰基因的距離介於該間距，則以該間距所得的分數作為評分的依據，如表 3 所示，由於 OP 的距離以 -4 頻率最大，因此距離介於 -6 至 1 之間所得的分數為 0.791443，而距離大於 561 或小於 -149 則給予最低分數 -1。假設兩基因具有相同的代謝路徑則給予一分，否則不予給分 [3]。COG 亦是參照文獻利用對數似然法所計算出的結果作為評分依據，如表 4 所示，相鄰基因皆為 Information storage and processing 類別，則給予該基因對 1.0733 分，若屬於不相同的類別，則給予該基因對 -1.1789 分。以圖 6 為例說明詳細的評分程序，染色體編碼為 011010，以表 3、4 得知各個相鄰基因對的分數後，計算各操作組中基因對的平均分數，由於第一個操作組的基因個數為 1，因此操作組的分數為 0，而第二個操作組的分數則是三個基因對分數之平均，以此類推，最後將所有的操作組分數加總，即為此條染色體的分數。

表 3. 相鄰基因的距離之評分表

間距	分數	間距	分數	間距	分數
[561,40611]	-1	[380,560]	-0.3902	[290,379]	-0.4007
[235,289]	-0.2879	[211,234]	-0.1502	[186,210]	-0.0617
[167,185]	-0.0148	[140,166]	-0.1074	[128,139]	-0.0817
[114,127]	-0.0148	[98,113]	-0.0192	[91,97]	0.1233
[82,90]	0.2081	[77,81]	0.0089	[69,76]	0.0573
[65,68]	0.0226	[54,64]	0.2317	[49,53]	0.029
[47,48]	0.188722	[38,46]	0.408327	[32,37]	0.374738
[30,31]	0.408327	[28,29]	0.456436	[21,27]	0.531
[10,20]	0.7355	[5,9]	0.5862	[2,4]	0.6549
[-6,1]	0.791443	[-15,-7]	0.66271	[-18,-16]	0.188722
[-24,-19]	0.278072	[-70,-25]	0.733235	[-149,-71]	-1

註：利用區域熵值最小化方法，針對每段距離間距進行評分[3]。

表 4. COG 之評分表

COG 功能類別	基因組對頻率	非基因組對頻率	Log-likelihoods
Information storage and processing	0.074	0.035	1.0733
Cellular processing and signaling	0.132	0.040	1.7251
Metabolism	0.463	0.182	1.3467
Different COG categories	0.319	0.722	-1.1789

註：利用對數似然法，針對每個類別進行評分[3]。




圖 6. 適應函數示意圖

3.2.4 選擇

本研究的基因演算法採用輪盤選擇法挑選兩條母體染色體，主要依據每條母體染色體的適應函數值來計算挑選機率。公式(2)(3)為輪盤選擇法的計算公式，其中 $P\text{-num}$ 為母體中的染色體個數， $fit(i)$ 則為該染色體的適應函數值，而 fit_{sum} 則為所有染色體的適應函數值加總，再將機率正規化於 0 到 1 間。在進行挑選染色體前，本實驗隨機產生介於 0 到 1 之間的亂數，若亂數介於某染色體的機率範圍，則將此染色體挑選出來，以上述方式挑選兩次，接著將挑選的兩條母體染色體進行交配動作。

$$P_i = \sum_{j=1}^i p(j), i=1, \dots, P\text{-num} \quad (2)$$

$$P(j) = \frac{fit(j)}{fit_{sum}} \quad (3)$$

3.2.5 交配

染色體交配方式為單點交配，藉由隨機挑選染色體的一點作為交配點，將挑選出的兩條染色體於交配點進行切割，分別將前段的編碼與另一條後段的編碼結合，產生兩條新的子代染色體。如圖 7 所示，母代₁及母代₂經由交配點切割後，將母代₁的前段染色體 111 與母代₂的後段染色體 110 結合，產生子代₁的染色體 111110，子代₂染色體則是利用母代₂的前段染色體 110 與母代₁的後段染色體 010 結合，產生子代₂染色體 110010。




圖 7. 單點交配示意圖

3.2.6 突變

本研究的突變方式是針對交配後所產生之子代進行突變，而突變點則是挑選 NOP 位元進行判斷，若該點所得的隨機亂數值小於本研究所設定的突變率，則進行突變動作，主要分為下列兩種方式：

- (1) 前端突變：如圖 8 所示，若挑選的 NOP 位元與下一個基因不同方向，則進行評估與前一個基因的基因對分數，若分數低於基因對

平均分數，則將前一個基因位元突變為 0，即為最後一個基因獨立成一個操作組。

- (2) 後端突變：如圖 9 所示，若挑選的 NOP 位元與下一個基因同方向，且相鄰基因對的分數大於所有基因對分數的平均，則將此位元突變為 1，即為兩個操作組合併。




圖 8. 前端突變示意圖




圖 9. 後端突變示意圖

3.2.7 替換

本實驗從交配及突變過程所產生的四個子代中，挑選出適應值最佳的兩條子代染色體，與所有母體染色體的適應值進行排序，並將最差的兩條染色體移除，維持母體的染色體數目。

3.3 演算法流程

GA 流程步驟依序如下：

- 步驟一：設定基因演算法的相關參數，分別為染色體個數 $P\text{-num}$ 、迭代次數 G 、交配率 $X\text{-rate}$ 、突變率 $M\text{-rate}$ 。
- 步驟二：加入方向的限制，並且藉由產生 20 組 0 至 300 的亂數，讓距離以此為依據進行初始化。
- 步驟三：藉由評分機制評估每條染色體的適應函數值。
- 步驟四：以輪盤選擇法挑選兩條染色體進行交配。
- 步驟五：依據交配率及突變率，執行交配及突變動作。

步驟六：將最佳的兩個子代與所有母代進行排序，取出最佳的 P 條染色體。

步驟七：判斷是否達到終止條件，若符合則終止程式，否則回步驟三。

4 實驗結果與討論

4.1 參數設定

本研究在基因演算法的參數設定如下，母體族群染色體個數 $P\text{-num}=20$ ，迭代次數 $G=100$ ，交配率 $X\text{-rate}=1.0$ ，突變率 $M\text{-rate}=1/P$ [18]，由於文獻的初始化亂數設定介於 0 至 300 [3]，本實驗為了與文獻預測結果進行比較，以及突顯加入方向進行初始化的改善，因此參照文獻設定初始化亂數的範圍。

4.2 結果

在本研究中，我們經由基因演算法的迭代過程，找尋適應函數值最佳的染色體，再與實驗證實的操作組資料進行比對，分別記錄 TP、FN、TN 及 FP，作為計算預測正確率、敏感度及特異度的依據，接著利用這些數據針對特性選取做進一步的分析，以挑選最佳的特性子集合，最後再與文獻的預測結果進行比較。表 5 為本研究使用三個預測特性的特性選取比較表，分別記錄三個基因體使用 7 種特性組合的結果，以便觀察特性對於操作組的預測效能，表中大腸桿菌以距離搭配代謝路徑的預測正確率最高，以 COG 特性作為預測根據的結果最差，枯草桿菌及綠膿桿菌皆以代謝路徑搭配 COG 的預測結果最好，以代謝路徑做為預測特性的結果最差，三個基因體中的特異度以綠膿桿菌所得的預測結果最好，皆為 1.000，也就是說可以完全正確的預測 NOP。表 5 列出未加入方向限制的結果，除了綠膿桿菌在使用距離搭配 COG 特性的情況下，較加入方向限制的結果高出 0.005，其餘皆為加入方向限制的結果佳，其中又以大腸桿菌的效果最為明顯。表 6 分別列出了距離、代謝路徑或距離搭配代謝路徑的預測正確率、敏感度及特異度，與文獻基因演算法及模糊基因演算法進行比較，在單一特性的預測結果中，除了大腸桿菌基因體在使用代謝路徑做為預測特性時，較模糊基因演算法低了 0.009，其他皆優於文獻，甚至優於使用 4 個特性的預測結果；使用距離搭配代謝路徑做為預測依據，應用於大腸桿菌基因體的預測結果，較使用 4 個特性預測的基因演算法多 0.04，而與使用 4 個特性的模糊基因演算法平手，在枯草桿菌基因體中，預測結果分別優於基因演算法及模糊基因演算法 0.023 及 0.024，在綠膿桿菌基因體中，則是優於基因演算法 0.103，實驗結果證明，本研究確實提升了基因演算法於操作組預測的預測正確率。

4.3 討論

基因演算法雖然可以藉由迭代的過程，不斷的更新母體染色體，但若能在初始化時即獲得較佳的染色體，接著再藉由迭代的過程，試圖找尋適應函數值更大的染色體，便能有效提升整體的預測正確率。文獻中所使用的基因演算法，在初始化的部分只有利用相鄰基因的距離作為依據，本研究則增加了方向作為判斷條件，因此染色體在初始化後，便能趨近於最佳解，接著再藉由迭代的過程，找尋最佳的染色體結果。由於操作組中的基因必為同向，而不同方向的基因必定位於不同的操作組中，因此本研究於初始化利用方向的特性對操作組作初步的辨識，由表 5 得知，操作組預測在未加入方向限制進行初始化的結果較差，因為加入了方向限制可有效的預測 NOP，以提升特異度及預測正確率，藉此說明了方向對於操作組預測的重要性。然而基因演算法具有進化速度慢，以及突變率較小的特性，導致經常落入區域最佳解，而無法找到最佳的染色體編碼，因此我們藉由設定較大的交配率及突變率，改善迭代對於更新母體染色體的不足，以提升找到染色體最佳解的機率。本研究的染色體為二進制編碼方式，相較於文獻基因演算法[3]與模糊基因演算法[1]中的實數編碼方式，不僅在交配及突變後，不需調整染色體編碼的內容，還能使用其他二進制的分類器進行預測，使得往後欲於此領域深入研究的學者，能夠在分類器的選擇上更具彈性。

由許多文獻得知距離對於操作組預測的重要性[6][7][9][16][17]，但由表 5 得知，於大腸桿菌基因體中使用單一特性預測操作組，以距離為依據所得之預測正確率最高，但在枯草桿菌及綠膿桿菌基因體中，卻以 COG 特性預測結果最佳，主要原因在於枯草桿菌及綠膿桿菌的距離分配與其他基因體有些許不同[17]，因此枯草桿菌及綠膿桿菌若加入了距離特性進行預測，正確率就會因此下降。代謝路徑及 COG 於操作組預測的重要性相同[3]，但代謝路徑會因資料庫中資料不足的原因，導致在不同基因體作為預測特性時，具有不同的預測能力，而 COG 則是因為預測結果會具有較多的 FP [3]，此缺點不僅降低了特異度及預測正確率，還需耗費較多的預測時間。上述特性皆具有個別的優缺點，因此如何挑選最佳的特性組合，亦為本研究的重要目標。

圖 10 為本研究利用統計分析軟體 SPSS，根據真實資料與執行結果所繪製的 ROC 曲線圖，(A)(C)(E)依序為大腸桿菌、枯草桿菌及綠膿桿菌使用單一特性的預測結果，(B)(D)(F)則依序為刪除某一特性所獲得的預測結果，經由觀察 (A)(B)中 COG 曲線及無 COG 曲線下的面積，可明顯得知 COG 缺乏大腸桿菌的操作組預測能力，但在枯草桿菌及綠膿桿菌基因組則具

有不錯的預測能力，此外經由觀察(A)(C)(E)發現於大腸桿菌中代謝路徑較 COG 具有辨識操作組的能力，但在另外兩個基因組的辨識能力則較 COG 遜色。綜觀上述結果得知，各個操作組所適用的辨識特性不同，因此本研究利用特徵選取的概念，針對距離、代謝路徑及 COG 三個特性進行分析，以挑選最佳的特性組合。由表 5 得知，以距離搭配 COG 與距離搭配代謝路徑的預測結果進行比較，皆為距離搭配代謝路徑所得之結果佳，若將 COG 特性也加入預測，會因為 COG 特性預測的缺點，導致 FP 增加，而降低了特異度，同時也降低了預測正確率，雖然在枯草桿菌及綠膿桿菌基因體的操作組預測中，由於距離特性的因素，導致代謝路徑搭配 COG 較搭配距離可獲得較好的預測結果，但基於提升效果不大，且需花費較多時間的情況下，本研究挑選距離及代謝路徑特性做為預測操作組的依據。

在敏感度的部分，由於本研究使用較少的預測特性，使得敏感度較文獻低，然而敏感度與特異度具有相互影響的關係，因此相對提高了特異度。實驗結果顯示，由於整體方法的改善，不僅使得預測正確率優於使用較多評分準則的基因演算法及模糊基因演算法，也因為使用較少特性作為評分準則的關係，大幅的降低預測所需的時間，以達到最佳的成本效益。

5 結論

本研究提出用基因演算法於基因體之操作組預測，以二進制的染色體編碼方式，改善實數編碼需於交配及突變後調整的缺點。在初始化的部份，除了利用距離的特性，還增加了方向的限制，使得演算法於迭代步驟前即可獲得較佳的母體染色體。適應函數則是以特性選取的概念挑選距離及代謝路徑特性作為評分依據，接著再藉由交配及突變的步驟，於每次的迭代對染色體進行更新，以獲得最佳的預測正確率。實驗結果顯示，本研究方法不僅提升了大腸桿菌、枯草桿菌及綠膿桿菌操作組的預測正確率，也有效減少了預測所需的時間。因此，未來我們會增加不同的生物特性進行判斷，或是利用其他的演算法進行預測，以達到更佳預測結果。

參考文獻

- [1] E. Jacob, R. Sasikumar and K. N. R. Nair. A fuzzy guided genetic algorithm for operon prediction. *Bioinformatics*, Vol. 21, no. 8, pp. 1403-1407, 2004.
- [2] Rutger W.W. Brouwer, Oscar P. kuipers and Sacha A. F. T. van Hijum. The relative value of operon predictions. *Bioinformatics*, pp.1-9,

- 2008.
- [3] Shuqin Wang, Yan Wang, Wei Du, Fangxun Sun, Xiumei Wang, Chunguang Zhou and Yanchun Liang. A multi-approaches-guided genetic algorithm with application to operon prediction. *Artificial Intelligence in Medicine*, Vol. 41, pp. 151-159, 2007.
 - [4] Guo-qing Zhang, Zhi-wei Cao, Qing-ming Luo, Yu-dong Cai and Yi-xue Li. Operon prediction based on SVM. *Comput Biol Chem*, Vol. 30, pp. 233-240, 2006.
 - [5] Tetsushi Yada, Mitsuteru Nakao, Yasushi Totoki and Kenta Nakai. Modeling and predicting transcriptional units of Escherichia coli genes using hidden Markov models. *Bioinformatics*, Vol. 15, no. 12, pp. 987-993, 1999.
 - [6] Joseph Bockhorst, Mark Craven, David Page, Jude Shavlik and Jeremy Glasner. A Bayesian network approach to operon prediction. *Bioinformatics*, Vol. 19, pp. 1227-1235, 2003.
 - [7] B. P. Westover, J. D. Buhler, J. L. Sonnenburg and J. I. Gordon. Operon prediction without a training set. *Bioinformatics*, Vol. 21, no. 7, pp. 880-888, 2004.
 - [8] Chiara Sabatti, Lars Rohlin, Min-Kyu Oh and James C. Liao. Co-expression pattern from DNA microarray experiments as a tool for operon prediction. *Nucleic Acids Research*, Vol. 30, no. 13, pp. 2886-2893, 2002.
 - [9] Yongpan Yan and John Moulton. Deception of Operons. *Wiley InterScience*, Vol. 64, pp. 615-628, 2006.
 - [10] Phuongan Dam, Victor Olman, Kyle Harris, Zhengchang Su and Ying Xu. Operon prediction using both genome-specific and general genomic information. *Nucleic Acids Research*, Vol. 35, no. 1, pp. 288-298, 2007.
 - [11] Mihaela Pertea, Kunmi Ayanbule, Megan Smedinghoff and Steven L. Salzberg. OperonDB: a comprehensive database of predicted operons in microbial genomes. *Nucleic Acids Research*, pp.1-4, 2008.
 - [12] Nicolas Sierro, Yuko Makita, Michiel de Hoon and Kenta Nakai. DBTBS: a database of transcriptional regulation in *Bacillus subtilis* containing upstream intergenic conservation information. *Nucleic Acids Research*, Vol.36, pp. D93-D96, 2008.
 - [13] Shujiro Okuda, Toshiaki Katayama, Shuichi Kawashima, Susumu Goto and Minoru Kanehisa. ODB: a database of operons accumulating known operons across multiple genomes. *Nucleic Acids Research*, Vol. 34, pp. D358-D362, 2006.
 - [14] John H. Holland. Adaptation in Natural and Artificial System. *The University of Michigan press*, 1975.
 - [15] Heladia Salgado, Gabriel Moreno-Hagelsieb, Temple F. Smith and Julio Collado-Vides. Operons in *Escherichia coli*: Genomic analyses and predictions. *Proceedings of the National Academy of Sciences of the United States of America*, Vol. 97, no. 12, pp. 6652-6657, 2000.
 - [16] Gabriel Moreno-Hagelsieb and Julio Collado-Vides. A powerful non-homology method for the prediction of operons in prokaryotes. *Bioinformatics*, Vol. 18, pp. S329-S336, 2002.
 - [17] Liangsu Wang, John D. Trawick, Robert Yamamoto and Carlos Zamudio. Genome-wide operon prediction in *Staphylococcus aureus*. *Nucleic Acids Research*, Vol. 32, no. 12, pp. 3689-3702, 2004.
 - [18] Osman K. Erol and Ibrahim Eksin. A new optimization method: Big Bang-Big Crunch. *Advances in Engineering software*, Vol. 37, pp. 106-111, 2006.

表 5. 本研究特性選取之正確率比較表

基因體	特性選取	加入方向限制			未加入方向限制		
	(D, P, COG)	正確率	敏感度	特異度	正確率	敏感度	特異度
大腸桿菌	(0, 0, 1)	0.790	0.977	0.662	0.617	0.971	0.375
	(0, 1, 0)	0.856	0.777	0.909	0.799	0.751	0.832
	(0, 1, 1)	0.885	0.827	0.924	0.805	0.850	0.775
	(1, 0, 0)	0.897	0.845	0.932	0.809	0.844	0.786
	(1, 0, 1)	0.897	0.848	0.931	0.808	0.849	0.780
	(1, 1, 0)	0.900	0.843	0.939	0.815	0.852	0.791
	(1, 1, 1)	0.897	0.850	0.930	0.808	0.849	0.780
枯草桿菌	(0, 0, 1)	0.904	0.786	0.998	0.873	0.775	0.952
	(0, 1, 0)	0.852	0.672	0.995	0.849	0.700	0.967
	(0, 1, 1)	0.908	0.797	0.996	0.870	0.773	0.949
	(1, 0, 0)	0.902	0.782	0.998	0.877	0.782	0.954
	(1, 0, 1)	0.904	0.787	0.998	0.878	0.786	0.952
	(1, 1, 0)	0.906	0.792	0.998	0.874	0.780	0.949
	(1, 1, 1)	0.904	0.786	0.998	0.878	0.785	0.952
綠膿桿菌	(0, 0, 1)	0.925	0.878	1.000	0.913	0.867	0.988
	(0, 1, 0)	0.879	0.804	1.000	0.877	0.801	0.994
	(0, 1, 1)	0.927	0.881	1.000	0.916	0.870	0.988
	(1, 0, 0)	0.904	0.844	1.000	0.893	0.833	0.988
	(1, 0, 1)	0.904	0.844	1.000	0.909	0.859	0.988
	(1, 1, 0)	0.916	0.863	1.000	0.902	0.848	0.988
	(1, 1, 1)	0.911	0.856	1.000	0.902	0.848	0.988

註：此表為本研究三個基因體的特性組合預測結果，特性選取欄位的二進制位元依序表示 distance、pathway、COG 特性的使用，位元為 1，則表示選取該特性；位元為 0，則表示不選取該特性作為適應函數。

表 6. 研究方法及評分準則之正確率比較表

基因體	研究方法	特性選取	正確率	敏感度	特異度
		(D, P, COG, ME, PF, C, P)			
大腸桿菌	本研究方法	(1, 0, 0, 0, 0, 0, 0)	0.897	0.845	0.932
		(0, 1, 0, 0, 0, 0, 0)	0.856	0.777	0.909
		(1, 1, 0, 0, 0, 0, 0)	0.900	0.843	0.939
	基因演算法[3]	(1, 1, 1, 1, 0, 0, 0)	0.860	0.894	0.813
	模糊基因演算法[1]	(1, 0, 0, 0, 0, 0, 0)	0.825	NA	NA
		(0, 1, 0, 0, 0, 0, 0)	0.865	NA	NA
		(1, 1, 0, 0, 1, 1, 0)	0.900	NA	NA
	支持向量機[4]	(1, 1, 0, 0, 0, 1, 1)	0.856	0.888	0.802
枯草桿菌	本研究方法	(1, 0, 0, 0, 0, 0, 0)	0.902	0.782	0.998
		(0, 1, 0, 0, 0, 0, 0)	0.852	0.672	0.995
		(1, 1, 0, 0, 0, 0, 0)	0.906	0.792	0.998
	基因演算法[3]	(1, 1, 1, 1, 0, 0, 0)	0.883	0.873	0.897
	模糊基因演算法[1]	(1, 0, 0, 0, 0, 0, 0)	0.857	NA	NA
		(0, 1, 0, 0, 0, 0, 0)	0.753	NA	NA
		(1, 1, 0, 0, 0, 0, 0)	0.882	NA	NA
	支持向量機[4]	(1, 1, 0, 0, 0, 1, 1)	0.889	0.900	0.860
綠膿桿菌	本研究方法	(1, 0, 0, 0, 0, 0, 0)	0.904	0.844	1.000
		(0, 1, 0, 0, 0, 0, 0)	0.879	0.804	1.000
		(1, 1, 0, 0, 0, 0, 0)	0.916	0.863	1.000
	基因演算法[3]	(1, 1, 1, 1, 0, 0, 0)	0.813	0.870	0.763

註：特性選取的二進制位元依序表示 distance、pathway、COG、microarray expression、protein function、conservation 及 phylogenetic profiles 特性的使用，位元為 1，則表示選取該特性；位元為 0，則表示不選取該特性作為適應函數。數據中的 NA 表示文獻中無該資料。




圖 10. 操作組預測之 ROC 曲線