

基於鑑別性特徵之超暗人臉辨識

黃登淵

電機工程學系

大葉大學，彰化，台灣

kevin@mail.dyu.edu.tw

徐茂翔

電機工程學系

大葉大學，彰化，台灣

SpiritGodest@gmail.com

胡武誌

資訊工程學系

澎湖科技大學，馬公，台灣

wchu@npu.edu.tw

摘要

在光線不足的環境下進行人臉識別是一項相當困難的挑戰，本研究利用直方圖匹配(Histogram Matching; HM)作為超暗影像之前處理，來強化人臉影像的重要特徵，包含眼睛與嘴巴等；緊接著，利用線性鑑別式分析法(Linear Discriminant Analysis; LDA)作為影像特徵的降維；最後利用支持向量機(Support Vector Machine; SVM)來進行人臉識別，同時並與歐氏距離分類器及餘弦距離分類器進行辨識率之比較。根據實驗結果，在訓練樣本五張與十張的條件下，當採用直方圖匹配時，可分別使人臉辨識率由 55% 提升至 94%，66% 提升至 96% 之水準。

關鍵字：人臉識別、直方圖匹配、區域二元樣式、線性鑑別式分析法、支持向量機。

1 介紹

常見的生物辨識特徵包含有指紋(fingerprint)、視網膜(retina)與虹膜(iris)等。但近年來，人類其它的重要特徵，包含指模與手掌的幾何形狀(finger/palm geometry)、聲音(voice)、簽名(signature)與人臉(face)等也受到廣泛的注意。但是，生物辨識系統(biometrics)仍具有一些致命的缺點，例如虹膜辨識雖然精確度很高，但所需設備價格昂貴，且不容易為一般大眾所接受；至於指紋辨識雖具有可靠與非侵入之雙重特性，但對於一般不願配合的民眾仍然不合適。相反地，若以人臉辨識來做為基礎，卻可在可靠度與民眾接受度之間取得一平衡點，同時在社會安全與個人隱私等方面也可獲得一定的保障。

臉部識別由於其非線性的特徵，在辨識上有其難度。近年來，許多創新的做法使得人臉的辨識率大大的提升。這些解決方案大致可分成基於 Gabor 濾波器與小波[1,2]、神經網路[3]、區域二元樣式[4-6]，線性或非線性子空間預測[7-12]。

人臉識別基本上是一個線性與高維度問題，其中神經網路可以在人臉辨識上有很好的效果。Er 等人 [3] 提出了一種混合梯度模式與線性最小乘法的方法，在使用徑向基函數(RBF)神經分類器時，對高維的小訓練集進行降維的

動作。他們首先利用主成分分析法(PCA)進行人臉影像的降維，並從中提取出最具鑑別性的特徵，將之輸入至 RBF 神經網路。然而，在他們的研究中還遇到了一些困難，其中包括過學習、訓練過度、小樣本的尺寸效應與奇異共變性矩陣的問題等。其結果表示，此系統無論在錯誤率計算、分類以及學習效率皆有著出色的表現。

近年來，區域二元樣式(local binary patterns)對人臉的描述由於其對姿態和光照變化[4-6]的穩健性，獲得了廣泛關注。Ahonen 等人[4]提出了基於 LBP 紋理特徵的臉部影像表示之人臉辨識。在此研究中，首先利用 LBP 提取人臉的特徵，接著連接成增強的特徵向量作為一人臉描述。作者使用 FERET 人臉資料庫對他們所提出的方法進行效果的評估。實驗結果表示 LBP 特徵向量作為人臉影像的描述有卓越的表現。Lahdenoja 等人[5]提出 uniform LBP 的對稱性為一新的識別概念。在實驗證明中，利用人類的感官與 LBP 使用 FERET 人臉資料庫進行人臉辨識，證實對稱的性概念是一種有效的鑑別。


在過去幾十年，線性和非線性子空間投影方法在人臉識別中很受歡迎，如主成分分析法(Principal Component Analysis: PCA)，獨立分量分析法[7-11](Independent Component Analysis: ICA)和線性鑑別分析法[7,8,12](Linear Discriminant Analysis: LDA)，在過去幾年已被證實是相當成功的人臉識別方法。在子空間的人臉識別方法，特徵提取是最重要的問題，其目的是為了減少原始人臉影像的高為空間。其中 PCA 與 ICA 為非監督式學習法，指其在轉換時並不考慮類別與類別間之差異問題；相反地，LDA 則為監督式學習法，主要在於提供以「分類」為目的之解決方案，技術重點在於尋找使得類別間矩陣與類別內矩陣之比值為最大之特徵向量。然而，PCA 對於人臉變化強健性不高，例如面部表情，光照和佩戴眼鏡[13]；在另一方面，LDA 的和 Gabor 小波[14]被認為是處理這些問題的最好的方法。

尋找能夠對有效描述人臉外觀的方法是使人臉辨識能否成功的關鍵問題。由於直方圖匹配與 LBP 特徵描述對光線變化的強健性，本研究將其使用於影像之前處理以解決光線不足情況。作為高維度之人臉影像的降維與提取特徵的過程使用的方法為線性鑑別分析法。在人臉影像的分類是利用支持向量機(SVM)。

本文的其餘部分的結構如下：第 2 節說明人臉識別的研究方法，第 3 節為實驗結果和討論，在最後一節闡述結論和未來的工作。

2 人臉辨識方法

本研究提出的人臉識別方法，如圖一所示。原始人臉影像首先利用直方圖匹配處理，其中經處理後之 LBP 人臉影像與原圖影像也會做為樣本比較。緊接著利用線性判別分析進行人臉影像降維，以擷取出具鑑別性的特徵向量。最後利用支持向量機進行人臉識別。在人臉識別分類器上，本研究同時採用歐式距離與餘弦距離進行結果的比較。



圖一、基於 LDA 與 SVM 超暗人臉辨識流程圖

2.1 直方圖匹配法

直方圖匹配可以有效地做為超暗人臉之影像前處理，其方法描述如下：

$$p_r(r_k) = \frac{n_k}{n} \quad k = 0, 1, 2, \dots, L-1 \quad (1)$$

其中式(1)之 n 表示影像之總點數， n_k 表示灰階值 r_k 所有的點數，而 $L(=256)$ 代表為影像之全部灰階值數量。令 S_k 為原始影像的累積機率，如圖二(a)所示，表示如下：

$$s_k = T(r_k) = \sum_{i=0}^k p_r(r_i) = \sum_{i=0}^k \frac{n_i}{n} \quad (2)$$


令 v_k 為已處理過之影像的累積機率，如圖二(b)所示：

$$v_k = G(z_k) = \sum_{i=0}^k p_z(z_i) = s_k \quad (3)$$

經由逆轉換，由原影像映射至經過處理的影像灰階值可由式(4)表示：

$$z_k = G^{-1}[T(r_k)] = G^{-1}[s_k] \quad (4)$$

經由直方圖匹配，我們需要指定一個曲線的累積函數來表示處理過後的影像。我們指定的曲線為 $g(z) = Cz^\gamma$ ，其中 z 為灰階值，而 C 值等於 $1.0/255^\gamma$ ，在本研究中，取 $\gamma=0.75$ 。




圖二、影像直方圖匹配：(a)經由 $T(r_k)$ 的 r_k 映射到 s_k 的影像；(b) s_k 反映射到它所對應的 z_k 。

2.2 Local Binary Patterns (LBP)

LBP 運算子最初由 Ojala 等人[6]於 1996 年所提出，它是一個與灰階無關之紋理運算子，具有與亮度無關之特性。

欲獲得具 LBP 編碼資訊的影像步驟如圖三所示。令 Γ 為一灰階影像，其大小為 3×3 之像素區塊，並令其中心像素 $p_c(x, y)$ 之灰階強度為門檻值 I_c ，鄰近像素依序與門檻值 I_c 進行比較，假使鄰近像素 $p_n(x, y)$ 大於門檻值 I_c ，則令其像素值 1，否則令其為 0；比較完成後，將產生一序列之二進位碼。由起始點(記號處)以順時針開始配合對應之權重值計算，即可獲取 $p_c(x, y)$ 之 LBP 數據。



圖三、取得 LBP 編碼之演算流程圖


LBP 運算子更可擴張半徑 R 並與等距之 P 個像素點做 LBP 運算，如圖四所示。設定中心像素點為門檻值 I_c ，所需運算之鄰近像素為 $I_n = \{I_0, I_1, \dots, I_{P-1}\}$ 。則此令 LBP 編碼為 $LBP_{P,R}$ ，計算方式如下：

$$LBP_{P,R}(x_c, y_c) = \sum_{n=0}^{P-1} s(I_n - I_c) \times 2^n \quad (5)$$


其中 $s(\xi)$ 定義如下：

$$s(\xi) = \begin{cases} 1 & \xi > 0 \\ 0 & \xi \leq 0 \end{cases} \quad (6)$$

人臉影像之 LBP 編碼在不同光線變化條件下的結果如圖五所示。此影像序列由左至右分別為原圖、light value = -70、contrast value = -100、gamma value = 2.0 與 gamma value = 0.4，選定之 LBP 描述子為 $LBP_{8,1}$ 。從中所得之 LBP 編碼影像展示於圖五下列，由結果可以觀察到，LBP 紋理在光線變化的環境下並無顯著的差異。



圖四、不同(P,R)設定值下之 LBP 運算子



圖五、於不同亮度條件下所得之 LBP 影像

2.3 LDA 理論基礎

利用線性鑑別式分析方法(LDA 演算法)先找出轉換矩陣 W ，然後再將原影像空間 X 投影至新的特徵向量，以得到轉換特徵向量 Y ，其中 $Y = W^T X$ ，因此透過以上轉換過程，可明顯改善類別間之鑑別性。以下簡要說明其運作原理：

假設現在有 K 類不同的人臉影像，每類有 M 張，且每張原始人臉影像維度為 n 維向量，令原始影像中第 k 類第 m 張為 X_m^k ，則類別內散佈矩陣 S_w (within-class scatter matrix; S_w) 定義如下：

$$S_w = \sum_{k=1}^K \sum_{m=1}^M (X_m^k - \bar{X}^k)(X_m^k - \bar{X}^k)^T \quad (7)$$

$$\bar{X}^k = \frac{1}{M} \sum_{m=1}^M X_m^k \quad (8)$$

其中 $\bar{X}^k$ 表示第 k 類中所有影像的平均值。至於不同類別間之散佈矩陣 S_B (Between-Class Scatter Matrix; S_B)，其定義如下：

$$S_B = \sum_{k=1}^K (\bar{X}^k - \bar{X})(\bar{X}^k - \bar{X})^T \quad (9)$$

$$\bar{X} = \frac{1}{KM} \sum_{k=1}^K \sum_{m=1}^M X_m^k \quad (10)$$

其中 $\bar{X}$ 表示所有原始影像之平均值。

眾所周知，LDA 演算法轉換的目的，就是希望能找到轉換矩陣 W ，使得轉換後同一類別內之特徵空間(feature space)與該類別中心點的距離縮小，而不同類別間中心點之差距能增大，因此

$$Y_m^k = W^T X_m^k \quad (11)$$

換句話說，就是要「最大化」費雪準則(Fisher's criterion)，讓轉換後類別內散佈矩陣的跡(trace)或行列式值縮小，並同時拉大類別間散佈矩陣的跡(trace)或行列式值，如(12)式所示。

$$(F)_{\max} = \frac{Tr(S_B)}{Tr(S_w)} \quad (12)$$

則原影像空間中第 k 類平均值 $\bar{X}^k$ 經轉換後的平均值 $\bar{Y}_m^k$ 為：

$$\begin{aligned} Y_m^k &= \frac{1}{M} \sum_{m=1}^M Y_m^k = \frac{1}{M} \sum_{m=1}^M W^T X_m^k \\ &= \frac{1}{M} \left(\sum_{m=1}^M X_m^k \right) = W^T \bar{X}^k \end{aligned} \quad (13)$$

而轉換後全部特徵參數的平均值 $\bar{Y}$ 為：

$$\begin{aligned} \bar{Y} &= \frac{1}{KM} \sum_{k=1}^K \sum_{m=1}^M Y_m^k = \frac{1}{KM} \sum_{k=1}^K \sum_{m=1}^M W^T X_m^k \\ &= W^T \left(\frac{1}{KM} \sum_{k=1}^K \sum_{m=1}^M X_m^k \right) \\ &= W^T \bar{X} \end{aligned} \quad (14)$$

因此轉換後之類別內散佈矩陣 Ω_w 可以表示為：

$$\begin{aligned}
\Omega_W &= \sum_{k=1}^K \sum_{m=1}^M (Y_m^k - \bar{Y}^k) (Y_m^k - \bar{Y}^k)^T \\
&= \sum_{k=1}^K \sum_{m=1}^M W^T (X_m^k - \bar{X}^k) (X_m^k - \bar{X}^k)^T W \\
&= W^T \left(\sum_{k=1}^K \sum_{m=1}^M (X_m^k - \bar{X}^k) (X_m^k - \bar{X}^k)^T \right) W \\
&= W^T S_W W
\end{aligned} \quad (15)$$

而轉換後之類別間散佈矩陣 Ω_B 可以表示為：

$$\begin{aligned}
\Omega_B &= \sum_{k=1}^K \sum_{m=1}^M (Y^k - \bar{Y}^k) (Y^k - \bar{Y}^k)^T \\
&= \sum_{k=1}^K W^T (\bar{X}^k - \bar{X}) (\bar{X}^k - \bar{X})^T W \\
&= W^T S_B W
\end{aligned} \quad (16)$$

因此轉換後費雪準則 $(F)_{\max} = \frac{Tr(S_B)}{Tr(S_W)}$ 可改

寫成：

$$(F)_{\max} = \frac{Tr(W^T S_B W)}{Tr(W^T S_W W)} \quad (17)$$

接下來假設滿足此條件式的轉換矩陣 W_{opt} 為：

$$W_{opt} = \arg \max_w \frac{Tr(W^T S_B W)}{Tr(W^T S_W W)} \quad (18)$$

根據極值原理，最大化費雪準則相當於(16)式對 W 進行一階導數並令其為0，經過適當整理後，可獲知 W 為矩陣 $S_W^{-1} S_B$ 運算後，其特徵向量所組成之矩陣。

2.4 SVM 理論基礎

原則上，SVM分類器首先透過建模的方式以建立一個最佳的分類目標函數，並提出最低化結構風險的概念，以求得所謂最佳分類之超平面，該超平面即稱之為支持向量，求取超平面的目的在於使不同類別間的資料具有最大的間距與最小的分類誤差。

要執行不同類別之間的分類，非線性之SVM分類器將輸入的資料 (x_i, y_i) 經由非線性運算子 $\Phi(x)$ 映射至高維度的特徵空間，其中 $x_i \in R^N$ 而 $y_i \in \{+1, -1\}$ 如圖六所示。如此，可以計算出作為決策表面之最佳的超平面

$$f(x) = \text{sgn} \left(\sum_i y_i \alpha_i K(x_i, x) + b \right) \quad (19)$$


其中 $\text{sgn}(\bullet)$ 代為一符號函式，而 $K(x_i, x) = \Phi(x_i)^T \Phi(x)$ 預定義為滿足Mercer's條件之核函數。在此研究中，RBF函數之定義如下：

$$K(x_i, x) = \exp \left(-\gamma \|x_i - x\|^2 \right), \gamma > 0 \quad (20)$$

其中 $\gamma = 0.03125$ ，而式(18)之 α_i 與 b 可經由以下之二次規劃問題來求得

$$\begin{aligned}
&\max \left[\sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j) \right] \\
&\text{s.t. } \sum_i \alpha_i y_i = 0 \\
&0 < \alpha_i < C, \forall i
\end{aligned} \quad (21)$$

參數 C 表示SVM學習間距最大化與錯誤最小化間之妥協，故又稱為規則化參數，在此研究中 $C=1$ 。SVM是一種二元分類器，但利用所謂的一對一比較法，它亦可延伸為多類別之人臉識別分類器。此外，本研究同時使用餘弦距離分類器與歐式距離分類器與SVM分類器之結果做比較。



圖六、經由核函數將非線性之輸入資料映射至線性之高維特徵度特徵空間

3 實驗結果與討論

本研究之實驗環境中央處理器為 Intel Core Duo processor T7500、記憶體為 4GB DDR2、作業系統為 Window XP SP3、開發軟體為 Borland C++ Builder 6.0。使用之人臉資料庫為 Yale Face Database B，其中包含 28 人，每人 9 種不同姿勢、64 種光線變化，共 16,128 張影像。本實驗所輸入之人臉影像如圖七所示，第一列為影像原圖、第二列為 LBP 編碼影像、最後一列為經直方圖匹配處理後之影像。



圖七、Yale Face Database B 人臉資料庫
(a)原圖、(b)LBP 編碼影像、(c)直方圖匹配影像

在此論文中，我們提出一可以解決光線不足情況下進行人臉識別的方法。首先利用直方圖等化與 LBP 描述子進行影像的前處理。而線性判別分析法則是作為降低人臉特徵向量的方法。在人臉識別過程中使用的是 SVM 分類器，同時與餘弦距離分類器和歐式距離分類器的結果做比較。

Yale Face Database B 資料庫的人臉類別有 15 類，本實驗中每類任選 20 張影像進行訓練與測試。在此研究中我們進行兩組實驗，分別為訓練樣本 5 張與訓練樣本 10 張，而測試樣本皆為 10 張。在此我們進行訓練樣本張數對人臉識別率的比較。

表 1 為不同輸入資料、不同分類器與不同訓練樣本數之人臉識別辨識率。從實驗結果可以觀察到，由於原影像之鑑別度不夠顯著，人臉辨識率並不理想，即使將訓練張數提升為 10 張，其辨識結果同樣令人無法接受。相較原圖影像，LBP 編碼影像與直方圖匹配影像在辨識結果上皆有著不錯的表現，其中直方圖匹配影像有更優異的表現，在使用 SVM 分類器以及訓練張數 10 張條件下，辨識結果更可達到 96%。在訓練樣本五張與十張的條件下，SVM 選用 LDA 之特徵點為 30 點的情況下，當採用直方圖匹配時，可分別使人臉辨識率由 55% 提升至 94%，66% 提升至 96% 之水準。

表一、不同樣本與不同分類器下之辨識結果

分類器	訓練張數	原圖 + LDA	LBP + LDA	HM + LDA
歐式距離	5	57%	89%	92%
	10	68%	89%	95%
餘弦距離	5	62%	89%	92%
	10	67%	89%	95%
SVM	5	55%	93%	94%
	10	66%	93%	96%

4 結論

在此研究中，我們所提出的方法結合直方圖匹配做為超暗人臉前處理，再利用 LDA 進行特徵擷取與 SVM 分類器進行人臉身分識別，在超暗亮度的環境條件下有著不錯的結果，其辨識率在訓練張數 5 張與 10 張的條件下，分別可達 94% 與 96% 之水平。本文採用直方圖匹配作

為超暗人臉前處理步驟，可以有效的強化人臉特徵。

在未來的工作中，本研究將持續針對各種不一樣的條件與環境進行人臉識別的研究，例如不同的臉部姿勢、表情或者是遮蔽的情況下，使得人臉識別的技術更加純熟。

5 誌謝

本研究屬於國科會研究計畫 NSC 99-2221-E-212-022-「植基於人及其行為動作之視訊檢索系統」的部份研發成果，在此謹向國科會致上感謝之意。

6 參考文獻

- [1] Chengjun Liu, Harry Wechsler, "Gabor feature based classification using the enhanced Fisher linear discriminant model for face recognition," *IEEE Transaction on Image Processing*, Vol. 11, No. 4, pp. 467-476, 2002.
- [2] C. Garcia, G. Zikos, and G. Tziritas, "Wavelet packet analysis for face recognition," *Image and Vision Computing*, Vol. 18, pp. 289-297, 2000.
- [3] Meng Joo Er, Shiqian Wu, Juwei Lu, and Hock Lye Toh, "Face recognition with radial basis function (RBF) neural networks," *IEEE Transactions on Neural Networks*, Vol. 13, No. 3, pp. 697-710, 2002.
- [4] Timo Ahonen, Abdenour Hadid, and Matti Pietikäinen, "Face description with local binary patterns: application to face recognition," *IEEE Trans. Pattern Anal. Machine Intell.*, Vol. 28, No. 12, pp. 2037-2041, 2006.
- [5] Olli Lahdenoja, Mika Laiho, and Ari Paasio, "Reducing the feature vector length in local binary pattern based face recognition," *IEEE International Conference on Image Processing, Genoa, Italy, Sept. 11-14, 2005*, Vol. 2, pp. 914-917.
- [6] Timo Ojala, Matti Pietikäinen, and David Harwood, "A comparative study of texture measures with classification based on feature distributions," *Pattern Recognition*, Vol. 29, No. 1, pp. 51-59, 1996.
- [7] Peter N. Belhumeur, Joao P. Hespanha, and David J. Kriegman, "Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection," *IEEE Trans. Pattern Anal. Machine Intell.*, Vol. 19, pp. 711-720, 1997.
- [8] Aleix M. Martinez and Avinash C. Kak, "PCA versus LDA," *IEEE Transactions on Pattern Analysis and Machine Intelligence*,

- Vol. 23, No. 2, pp. 228-233, 2001.
- [9] Matthew Turk, and Alex Pentland, "Eigenfaces for recognition," *Journal of Cognitive Neuroscience*, Vol. 3, No. 1, pp. 71-86, 1991.
- [10] Daniel L. Swets and John Weng, "Using Discriminant Eigenfeatures for Image Retrieval," *IEEE Trans. Pattern Analysis and Machine Intelligence*, Vol. 18, No. 8, pp. 831-836, 1996.
- [11] Jie Wang, K. N. Plataniotis and A. N. Venetsanopoulos, "Selecting discriminate eigenfaces for face recognition," *Pattern Recognition Letters*, Vol. 26, pp. 1470-1482, 2005.
- [12] A. Z. Kouzani, F. He, K. Sammut and A. Bouzerdoum, "Illumination Invariant Face Recognition," *Proceedings of the 1998 IEEE International Conference on Systems, Man, and Cybernetics, San Diego, CA , 11-14 October*, Vol. 5, pp. 4240-4245, 1998.
- [13] Li-Fen Chen, Hong-Yuan Mark Liao, Ming-Tat Ko, Ja-Chen Lin, and Gwo-Jong. Yu, "A new LDA-based face recognition system which can solve the small sample size problem," *Pattern recognition*, Vol. 33, pp. 1713-1726, 2000.
- [14] Chengjun Liu, and Harry Wechsler, "Gabor feature based classification using the enhanced fisher linear discriminant model for face recognition," *IEEE Transactions on Image Processing*, Vol. 11, No. 4, pp. 467-476, 2002.
- [15] Vladimir N. Vapnik, Statistical learning theory, John Wiley and Sons, New York, 1998, pp. 423-424.
- [16] The extended Yale Face Database B is available
<http://vision.ucsd.edu/~leekc/ExtYaleDatabase/athosref.html>