

雙重底粒子族群最佳化於細胞週期相關控制基因

之單核苷酸多型性條碼辨識

Li-Yeh Chuang¹, Yu-Da Lin², Cheng-Hong Yang^{2*}

¹Dept. of Chemical Eng., I-Shou University, Kaohsiung, Taiwan. (chuang@isu.edu.tw)

²Dept. of Electronic Eng., National Kaohsiung University of Applied Sciences, Kaohsiung. (e0955767257@yahoo.com.tw, chyang@cc.kuas.edu.tw)

摘要

基因與基因間存在著影響疾病發生的關聯性，此關聯性的組合如同疾病的辨識條碼，因此近年研究大量利用疾病樣本與非疾病樣本進行對照以找到彼此最大差異的組合。然而，基因與基因間關聯性存在的可能性會隨著因子的數量而成指數型增加，因此利用統計工具分析所有組合以找出最大差異的疾病辨識條碼，需耗費龐大的實驗成本。本研究利用近年被提出的雙重底粒子族群最佳化演算法於搜尋多因子組合的疾病辨識條碼，其演算法擁有優越的混沌特性可大幅提升粒子族群最佳化搜尋的方向及有效脫離區域最佳解之特性。本實驗在 18 個細胞週期控制基因中挑選出 33 個乳癌疾病相關的單核苷酸多型性進行模擬測試粒子族群最佳化演算法及雙重底粒子族群最佳化演算法。研究結果顯示利用粒子族群最佳化演算法以辨識具有統計意義的疾病條碼時，高組合數量難以求得具有統計意義的疾病條碼。然而，雙重底粒子族群最佳化演算法成功辨識多個統計意義的疾病條碼於高組合數量。

1 前言

眾多疾病發生原因分析實驗中，病例對照研究法(case-control study)為有效且廣泛被使用的疾病分析技巧。病例對照研究法針對特殊病患及非此疾病的人收集相關資訊以利比較兩群組間彼此的差異。研究推測疾病發生的原因須提供大量的統計數據以證明實驗結果的可信度，病例對照研究法已成功應用於多種疾病分析，且提供健全的統計數據為佐證，例如癌症：乳癌(breast cancer) [1-3]、大腸癌(colon cancer) [4]、攝護腺癌(prostate cancer) [5]、或疾病：骨質疏鬆症[6]等。

單核苷酸多型性 (Single Nucleotide Polymorphism, SNP)是個體與個體間在染色體上擁有差異的位置，即造成個體與個體之間產生差別的原因之一(外觀、體質)，因此大量被利用於疾病分析。病例對照研究法可分析潛伏期

較長的罕見疾病，亦可對疾病同時進行多種危險因子研究；因此病例對照研究法能分析某疾病相關基因上存在的單核苷酸多型性之資訊在疾病樣本與非疾病樣本的最大差異性。由於全基因體相關研究 (Genome-wide Association Studies, GWAS)被提出，分析基因中彼此之間的單核苷酸多型性關連性分析為近五年熱門的研究之一，亦使得現代遺傳學及流行病學產生重大突破。然而，單核苷酸多型性關連性分析結果所產生的因子組合如同針對某疾病的辨識條碼，因此稱為單核苷酸多型性條碼辨識。

單核苷酸多型性條碼辨識問題中龐大的因子組合可能性為疾病分析實驗最困難的挑戰。數學上，假設資料樣本由 N 個單核苷酸多型性所組成，並且要推測 M 個單核苷酸多型性所組合的關連性時，將有 $C(N, M) * S^M = N! / [M! (N-M)!] * S^M$ 種的組合可能性，其中符號 S 為基因型 (genotype) 可能的數量 (分成 AA、Aa 及 aa 三種)。儘管許多方法提出平行運算以降低計算時間仍被定義為高複雜度問題。相關研究中已有許多以統計方法為基礎的演算法被提出，例如 BEAM [7]、logistic regression [8, 9]、logic regression [10]、MDR [11]、polymorphism interaction analysis (PIA) [12]、support vector machines (SVM) [13]等方法。然而，這些方法中雖然已能有效處理單核苷酸多型性數量所產生的邊際效用(marginal effect)及大規模的資料樣本(即克服樣本數增加對演算法之影響)；但是對於多因子(單核苷酸多型性)組合的分析能力仍無法有效搜尋至具有統計意義的疾病條碼。

本研究提出以雙重底粒子族群最佳化演算法搜尋具有統計意義的疾病條碼。研究利用 33 個乳癌疾病相關的單核苷酸多型性於 18 個細胞週期控制基因進行資料集模擬，測試粒子族群最佳化演算法及雙重底粒子族群最佳化演算法。實驗將以結果產生的資訊進行統計計算(疾病樣本數量與非疾病數量之差異、勝算比及 P 值)以比較粒子族群最佳化演算法及雙重底粒子族群最佳化演算法之搜尋能力及討論雙重底粒子族群最佳化方法的優點。

2 研究方法

粒子族群最佳化演算法

粒子族群最佳化 (Particle Swarm Optimization, PSO) 演算法由 Kennedy 和 Eberhar [14] 於 1995 年提出，作者觀察魚群及鳥群的覓食行為以及在社會心理學的基礎下，以數學向量的概念設計出新的演化式計算(evolutionary computation)方法。粒子族群最佳化演算法以社會行為為中個體與個體間之信息交流的機制來搜尋某一目標物。此個體在演算法中稱為粒子且可視為在整個問題空間中的一種可能解。每個粒子皆擁有各自的速度及目標，其目標可分為粒子各自的飛行經驗及根據信息交流的機制所獲得的同伴飛行經驗，根據此兩目標以調整粒子的搜尋路徑以朝向更具價值的空間區域。因此，粒子族群最佳化演算法優越的策略能有效探勘複雜問題中最佳解之空間區域。然而，在 1998 年 Eberhart 提出粒子族群最佳化在速度上擁有過早收斂之缺點，因此增加慣性權重值於粒子族群最佳化之更新公式，並提出 w 由 0.9 線性遞減至 0.4，稱為線性遞減系統 [15]，能有效減緩粒子群落入區域最佳解之時間以增加求解效能。其 w 公式如公式(1)所示， w 參數會影響全域及區域探勘，當 w 值較大時會趨向於全域探勘，反之則趨向於區域探勘，因此能有效平衡全域及區域探勘二大特性。本研究中，粒子族群最佳化演算法為採用線性遞減系統。

$$w_{LDW} = (w_{\max} - w_{\min}) * \frac{Iteration_{\max} - Iteration_i}{Iteration_{\max}} + w_{\min} \quad (1)$$

公式(1)中， $w_{\max}$ 與 $w_{\min}$ 分別為 0.9 與 0.4， $Iteration_{\max}$ 與 $Iteration_i$ 分別為迭代的最大次數與目前迭代的次數。粒子族群最佳化演算法中每個粒子皆以 D 維度的向量表示，例如第 i 個粒子的位置與速度表示為 $Px_i = (px_{i1}, px_{i2}, \dots, px_{iD})$ 與 $Pv_i = (pv_{i1}, pv_{i2}, \dots, pv_{iD})$ 表示，其中位置與速度範圍限制於 $[X_{\min}, X_{\max}]^D$ 與 $[V_{\min}, V_{\max}]^D$ 。此外，粒子記錄各自搜尋區域之最佳適應值稱 $pbest_i$ ，表示為 $pbest_i = (p_{i1}, p_{i2}, \dots, p_{iD})$ ；所有 $pbest$ 之最佳適應值則稱 $gbest$ ，表示為 $gbest = (g_1, g_2, \dots, g_D)$ 。迭代中粒子利用公式(2)及(3)更新速度及位置。

$$pv_{id}^{new} = w * pv_{id}^{old} + c_1 * rand() * (p_{id} - px_{id}^{old}) + c_2 * rand() * (g_d - px_{id}^{old}) \quad (2)$$

$$px_{id}^{new} = px_{id}^{old} + pv_{id}^{new} \quad (3)$$


公式(2)中， c_1 、 c_2 稱為學習因子，目的是控制 $pbest$ 與 $gbest$ 影響粒子的程度； $rand()$ 為隨機選取亂數[0,1]； px_{id}^{old} 與 pv_{id}^{old} 為第 i 顆粒子中第 d 維度的未更新位置及速度， px_{id}^{new} 與 pv_{id}^{new} 為第

i 顆粒子中第 d 維度的更新位置及速度。


粒子族群最佳化求解過程中，每個粒子將依問題設計的適應值函數(fitness function)進行適應值(fitness value)計算，其適應值根據問題需求可分為最大值或最小值之搜尋目標。每顆粒子根據適應值以評估個體最佳經驗($pbest$)及群體最佳經驗($gbest$)並計算下次的移動速度以更新粒子的位置，經過多次迭代的位置更新，粒子群將會收斂於某一空間範圍內進行區域式的搜尋，即全域搜尋至區域搜尋，以此特性找尋至最佳解。粒子群移動過程中，一旦某一粒子發現更好的解時，此時粒子群體就會根據該粒子所分享的訊息進行修正，經過一段時間後，粒子群將會再度集中在新的區域附近尋找其他可能的解；最後依據終止條件(例如最大迭代次數或達到適應值門檻)決定演算法是否終止。

雙重底粒子族群最佳化演算法

本研究以楊等人提出的雙重底粒子族群最佳化(double bottom particle swarm optimization)[16]演算法辨識具有統計意義的單核苷酸多型性條碼。雙重底粒子族群最佳化演算法導入雙重底混沌 map 於粒子族群最佳化演算法的更新公式，其中雙重底混沌 map 是根據粒子族群最佳化演算法的特性所設計的混沌公式。在粒子族群最佳化演算法中，更新公式中的 $c_1 * rand() * (p_{id} - px_{id}^{old})$ 負責調控 $pbest$ 對於粒子的影響程度，而 $c_2 * rand() * (g - px_{id}^{old})$ 則調控 $gbest$ 的影響程度。假若亂數 $rand()$ 的值低於 0.5 時，則影響程度將會很小；假若亂數 $rand()$ 的值等於 0.5，則影響程度為平衡；假若亂數 $rand()$ 的值大於 0.5，則影響程度將會很大。因此根據此特性，楊等人利用混沌理論特性，即不可預期性的週期亂數，調控亂數值較容易分佈於 0、0.5 及 1 數值附近，以提升粒子族群最佳化演算法搜索最佳解之能力。圖 1 為使用一般亂數及雙重底混沌 map 產生的亂數於 1000 次測試，統計 0 到 1 之間所出現的次數。



(a) 一般亂數產生的頻率



(b) 雙重底混沌 map 產生的頻率

圖 1. 1000 次隨機亂數之頻率統計圖

雙重底混沌 map 公式如公式(4)所示。

$$DBMr_{t+1} = [\sin(2\pi DBMr_t) + 1] / 2, n \in \mathbb{N} \quad (4)$$

公式中 t 為目前的迭代次數， n 為任一整數。此外，粒子族群最佳化更新公式將修改成公式(5)。

$$pv_{id}^{new} = w \times pv_{id}^{old} + c_1 \times DBMr_1 \times (p_{id} - px_{id}^{old}) + c_2 \times DBMr_2 \times (g_d - px_{id}^{old}) \quad (5)$$

公式(5)中 $DBMr$ 為公式(4)的計算結果。雙重底粒子族群最佳化演算法之流程如圖 2 所示。演算法一開始將對所有粒子進行初始化步驟，當所有粒子的向量值皆填滿後則進行評估適應值，再根據適應值找出每顆粒子的 $pbest$ 及群體間的 $gbest$ ，此時每顆粒子即可根據自我的 $pbest$ 及 $gbest$ 計算速度以更新位置。每當更新位置後，更新公式的 w 值及 $DBMr$ 值將會隨迭代進行更改其內容值。經過多次迭代後，當滿足停止條件則停止演算法執行，此時 $gbest$ 的資訊即為最佳解，以下將詳細介紹各步驟。

虛擬程式碼

```

01: Begin
02: Randomly initialize particles,  $DBMr_1$ ,  $DBMr_2$ 
03: While (Stopping criterion is not met)
04:   Estimate particle fitness
05:   Find  $pbest$ 
06:   Find  $gbest$ 
07:   For  $n = 1$  to population size
08:     For  $d = 1$  to particle dimension size
09:       Update the velocity and position by Eq. 5 and 3
10:     Next  $d$ 
11:   Next  $n$ 
12:   Update the  $w$  value by Eq. 1
13:   Update the value of  $DBMr$  by Eq. 4
14: Next
15: End

```

圖 2. 雙重底粒子族群最佳化演算法虛擬程式碼

粒子編碼及初始化

在辨識單核苷酸多型性條碼問題中，需求得的目的為單核苷酸多型性的組合及各單核苷酸多型性所對應的基因型。粒子族群最佳化中，由於每一個粒子皆視為一組解，粒子中的每一個向量維度代表著所選取的單核苷酸多型性號碼及其相對應基因型，如公式(6)所示。

$$Px_i = (S_{ij}, G_{ij}), i = 1, 2, \dots, m, j = 1, 2, \dots, n \quad (6)$$

公式(6)中 m 代表整個粒子群的大小， n 表示單核苷酸多型性條碼長度，即 n 因子組合；上述表示第 i 個粒子在決定第 j 個 SNP 時的選取情形， S_{ij} 表示所選取的單核苷酸多型性， G_{ij} 則表示 S_{ij} 被選取時所表現的基因型。由於單核苷酸多型性編碼的部分不可重複選取，因此 S_{ij} 在選取的過程不能重複，而基因型選取的部分由於是依附在各自的單核苷酸多型性之下所以沒有重複的限制，因此 G_{ij} 在選取時並沒有任何限

制；因此粒子的長度亦隨著選取單核苷酸多型性的組合數量而變動。粒子初始化步驟中，將對每一顆粒子的每一個維度進行亂數產生可能的值。圖 3 為粒子的初始化示意圖，圖中第 1 個粒子選取號碼第 3、7 及 13 的單核苷酸多型性，其中第 3 個單核苷酸多型性的基因型為 AA；第 7 個單核苷酸多型性的基因型為 AA；第 13 個單核苷酸多型性的基因型為 Aa。族群初始化利用隨機方式產生初始族群。初始族群中每個粒子針對 SNP 及 genotype 兩個不同的部分，故粒子位置隨機產生的範圍也有所不同。




圖 3. 粒子初始化示意圖

評估適應函數

本研究在適應函數方面利用在疾病樣本與非疾病樣本中符合單核苷酸多型性條碼的數量之差異值做為適應函數公式設計，如公式(7)所示。

$$F(Px_i) = n(\text{Case} \cap Px_i) - n(\text{Control} \cap Px_i) \quad (7)$$

公式中 $n(\text{Case} \cap Px_i)$ 代表在疾病樣本中符合單核苷酸多型性條碼的數量、 $n(\text{Control} \cap Px_i)$ 代表在非疾病樣本中符合單核苷酸多型性條碼的數量、 Px_i 代表第 i 顆粒子。

3 資料集來源與實驗結果

資料集來源

本研究測試資料來源由乳腺癌協會[17]中取得細胞週期控制基因之相關的 33 個單核苷酸多型性。我們從乳腺癌協會提供的單核苷酸多型性基因型頻率中，根據單核苷酸多型性基因型原始頻率以產生模擬資料集，以測試在複雜的單核苷酸多型性之關連性於乳癌的易感性。其中因為資料集為虛擬資料集，因此結果並不能反映真實分佈在病例組和對照組的真實結論，結果僅為測試雙重底粒子族群最佳化演算法能力而非真實乳癌的易感性。

表 1

粒子族群最佳化辨識乳癌病例與非乳癌病例間數量最大差異值之單核苷酸多型性條碼

SNP 數量	SNP 組合	Genotype 組合	Case 數量/Control 數量	差異值	勝算比 (95%CI)	P 值
2	21,24	AA-AA	1747/1560	187	1.18	<0.001*
	Others		3253/3440		(1.09-1.29)	
3	3,11,24	aa-AA-AA	830/798	32	1.05	0.386
	Others		4170/4202		(0.94-1.17)	
4	11,16,19,30	AA-aa-Aa-AA	129/100	29	1.30	0.053
	Others		4871/4900		(0.99-1.70)	
5	9,11,19,20,22	Aa-AA-AA-Aa-AA	180/168	12	1.07	0.513
	Others		4820/4832		(0.86-1.34)	
6	7,9,20,21,22,24	Aa-Aa-Aa-AA-aa-AA	25/20	5	1.25	0.456
	Others		4975/4980		(0.67-2.35)	
7	2,9,15,20,26,30,33	Aa-Aa-AA-Aa-AA-AA-AA	67/59	8	1.14	0.474
	Others		4933/4941		(0.79-1.64)	
8	1,11,13,14,27,29,32,33	AA-AA-Aa-AA-Aa-AA-Aa-AA	20/17	3	1.18	0.622
	Others		4980/4983		(0.59-2.36)	

註: SNP: 單核苷酸多型性; Genotype: 基因型; Case: 乳癌病例; Control: 非乳癌病例; 95%CI: 95%信賴區間; *:P 值小於 0.05

表 2

雙重底粒子族群最佳化辨識乳癌病例與非乳癌病例間數量最大差異值之單核苷酸多型性條碼

SNP 數量	SNP 組合	Genotype 組合	Case 數量/Control 數量	差異值	勝算比 (95%CI)	P 值
2	21,24	AA-AA	1747/1560	187	1.18	<0.001*
	Others		3253/3440		(1.09-1.29)	
3	10,21,24	AA-AA-AA	1620/1443	177	1.18	<0.001*
	Others		3380/3557		(1.08-1.29)	
4	10,21,24,26	AA-AA-AA-AA	1462/1313	149	1.16	0.001*
	Others		3538/3687		(1.06-1.27)	
5	10,13,24,26,28	AA-Aa-AA-AA-AA	1054/923	131	1.18	0.001*
	Others		3946/4077		(1.07-1.30)	
6	10,11,13,24,26,28	AA-AA-Aa-AA-AA-AA	891/777	114	1.18	0.002*
	Others		4109/4223		(1.06-1.31)	
7	7,10,11,13,24,26,28	AA-AA-AA-Aa-AA-AA-AA	609/524	85	1.19	0.002*
	Others		4391/4476		(1.05-1.34)	
8	7,10,11,13,24,26,28,32	AA-AA-AA-Aa-AA-AA-AA-AA	462/399	63	1.17	0.025*
	Others		4538/4601		(1.02-1.35)	

註: SNP: 單核苷酸多型性; Genotype: 基因型; Case: 乳癌病例; Control: 非乳癌病例; 95%CI: 95%信賴區間; *:P 值小於 0.05

參數設定

本實驗中，粒子族群最佳化演算法、雙重底粒子族群最佳化演算法之參數設定部份，最大迭代次數為 100，粒子總數為 50，慣性權重值 $w_{max}=0.9$ 、 $w_{min}=0.4$ ，學習因子 $c_1=c_2=2$ ，雙重底混沌公式中 n 值設定為 2。實驗測試中粒子族群最佳化演算法及雙重底粒子族群最佳化演算法粒子採用相同的粒子初始化結果。

實驗結果

表 1 及表 2 分別為粒子族群最佳化演算法及雙重底粒子族群最佳化演算法之實驗結果。表格中 SNP 數量表示單核苷酸多型性之組合數量，即因子組合數。SNP 組合欄位為被挑選到的單核苷酸多型性；Genotype 組合欄位為 SNP 組合欄位中單核苷酸多型性對應的基因型，其中 SNP 組合及 Genotype 組合欄位為單核苷酸多型性條碼。Case 數量/Control 數量欄位分別表示疾病樣本中符合單核苷酸多型性條碼的數量及非疾病樣本中符合單核苷酸多型性條碼的數量。差異值為 Case 數量減去 Control 數量，例如表 1 中 SNP (21, 24) 的 Case 數量為 1747、Control 數

量為 1560，兩者間差異值為 187。勝算比為利用 SPSS 20 統計工具所計算之結果，其中勝算比值大於 1 時代表危險性、 P 值若小於 0.05 則代表此單核苷酸多型性條碼具有統計意義。

表 1 中，粒子族群最佳化演算法僅於 SNP 數量 2 的單核苷酸多型性條碼具有統計意義，儘管勝算比優於表 2 雙重底粒子族群最佳化演算法之結果，但因不具統計意義，因此這些條碼並不能被採用。表 2 中，雙重底粒子族群最佳化演算法之差異值除了 SNP 數量 2 以外，其他皆優於表 1 粒子族群最佳化演算法之差異值，其優越的結果顯示雙重底粒子族群最佳化演算法能於 2 到 8 個因子組合數中，找到具有統計意義的單核苷酸多型性條碼。

4. 討論

單核苷酸多型性為生物基因組中最常見的變異點，且被證實與疾病和癌症有關聯，因此近年來探討單核苷酸多型性與人類疾病關聯性的分析及針對複雜疾病利用單核苷酸多型性研究已成為相當熱門的研究主題。疾病預測及防治

方面，保護預測(勝算比低於 1 時)則告知某些基因之間的關連性較不容易導致某種疾病產生，對於預防方面幫助極大；而風險預測結果(勝算比高於 1 時)則提供某些基因之關連性容易導致病症發生，對於診斷及治療幫助極大。

本研究目的為設計一個改良的粒子族群最佳化演算法於辨識具有統計意義的單核苷酸多型性條碼。我們利用模擬乳癌相關單核苷酸多型性之資料集對粒子族群最佳化演算法與雙重底粒子族群最佳化演算法測試在相同初始條件下所搜尋到癌症樣本與非癌症樣本之最大差異值的單核苷酸多型性間關連性。實驗結果顯示雙重底粒子族群最佳化演算法能較粒子族群最佳化演算法找到更優良的結果。

在單核苷酸多型性條碼問題中，若單核苷酸多型性之組合數量越高時，疾病樣本中符合單核苷酸多型性條碼的數量及非疾病樣本中符合單核苷酸多型性條碼的數量皆會快速下降，因此造成許多組合的適應值計算結果會接近 0，導致若鄰近擁有些許差異值的組合將會被視為區域最佳解，也因此粒子群將容易陷入區域最佳解問題。楊等人在提出雙重底粒子族群最佳化演算法時已對多種數學函式進行測試，並比較多種近年被提出的改良式粒子族群最佳化演算法，其結果已被證明其搜尋更佳解的特性優於其他改良式粒子族群最佳化演算法。其中雙重底混沌 map 亦利用李氏指數進行混沌特性測試，其優點能滿足粒子族群最佳化演算法中亂數 $rand()_1$ 及 $rand()_2$ 重要的 3 個數值分佈，即 0、0.5 及 1。這些亂數分佈能有效克服粒子群於區域最佳解之問題，其本研究亦證明雙重底粒子族群最佳化演算法之優秀搜尋能力，如圖 4 所示，圖中顯示 DBMPSO 為雙重底粒子族群最佳化演算法之結果；PSO 為粒子族群最佳化演算法之結果。在 2 到 8 的組合數量中，Case 與 control 之差異值能證明雙重底粒子族群最佳化演算法的搜尋最佳解的能力較粒子族群最佳化演算法好。




圖 4. Case 與 control 之差異值在各 SNP 組合數量之統計圖

在時間複雜度分析上，粒子族群最佳化演算法與雙重底粒子族群最佳化演算法的時間複雜度相同，其複雜度為 $O(MN)$ ，其中 M 代表總粒子數、N 代表最大迭代次數。在雙重底粒子族群

最佳化演算法中，雙重底混沌公式僅修改粒子族群最佳化演算法的更新公式，因此對於演算法執行速度上兩者相等。演算法參數分析上，雙重底粒子族群最佳化演算法之參數 n 為客觀不受資料集所限制，其已被證明為當 $n \geq 2$ 時公式產生的值具有混沌特性[16]，因此根據題目的特性可分析不同 n 所產生的結果進行比較，以找到最佳的 n 值。楊等人測試多種數學函式後建議 $n=2$ 為最佳值[16]。此外，本研究已測試過 $n=2, 4$ 及 8 ，其結果皆相同。粒子群大小及迭代次數皆能提昇演算法之求解能力，其參數已被 Eberhart 等人證明[15]，粒子群大小由 30 至 80 為佳，迭代次數依問題大小設定，但時間複雜度 $O(MN)$ 顯示演算法執行會隨粒子群大小及迭代次數之增加而提昇執行時間。

5 結論

本研究提出雙重底粒子族群最佳化演算法於辨識單核苷酸多型性條碼。其演算法於此問題之優點可分 4 點：1) 雙重底粒子族群最佳化演算法提供強大的分析於 GWAS 研究，以利產生最佳的單核苷酸多型性間關連性在病例組和對照組之間的最大區別；2) 雙重底粒子族群最佳化演算法為一種改進過的演算法，其求解優於粒子族群最佳化演算法及搜尋時間較窮舉搜索方法少且能找到可利用的解；3) 雙重底粒子族群最佳化演算法只需探討三個參數，即粒子群大小、迭代次數和參數 n ，無需進行複雜的參數設置；4) 雙重底粒子族群最佳化演算法的計算複雜度與數據集大小無關，因此能克服高維度單核苷酸多型性在 GWAS 研究中複雜關連性的計算時間限制。

參考文獻

- [1] J. Conde, S. N. Silva, A. P. Azevedo, V. Teixeira, J. E. Pina, J. Rueff, and J. F. Gaspar, "Association of common variants in mismatch repair genes and breast cancer susceptibility: a multigene study," *BMC Cancer*, vol. 9, pp. 344, 2009.
- [2] W. Han, K. Y. Kim, S. J. Yang, D. Y. Noh, D. Kang, and K. Kwack, "SNP-SNP interactions between DNA repair genes were associated with breast cancer risk in a Korean population," *Cancer*, p. in press, Jul 2011.
- [3] V. U. Onay, L. Briollais, J. A. Knight, E. Shi, Y. Y. Wang, S. Wells, H. Li, I. Rajendram, I. L. Andrulis, and H. Ozelik, "SNP-SNP interactions in breast cancer susceptibility," *Bmc Cancer*, vol. 6, May 2006.
- [4] S. Tuupainen, M. Turunen, R. Lehtonen, O. Hallikas, S. Vanharanta, T. Kivioja, M. Bjorklund, G. H. Wei, J. Yan, I. Niittymaki, J. P. Mecklin, H. Jarvinen, A.

- Ristimäki, M. Di-Bernardo, P. East, L. Carvajal-Carmona, R. S. Houlston, I. Tomlinson, K. Palin, E. Ukkonen, A. Karhu, J. Taipale, and L. A. Aaltonen, "The common colorectal cancer predisposition SNP rs6983267 at chromosome 8q24 confers potential to enhanced Wnt signaling," *Nature Genetics*, vol. 41, pp. 885-U37, Aug 2009.
- [5] G. Thomas, K. B. Jacobs, M. Yeager, P. Kraft, S. Wacholder, N. Orr, K. Yu, N. Chatterjee, R. Welch, A. Hutchinson, A. Crenshaw, G. Cancel-Tassin, B. J. Staats, Z. Wang, J. Gonzalez-Bosquet, J. Fang, X. Deng, S. I. Berndt, E. E. Calle, H. S. Feigelson, M. J. Thun, C. Rodriguez, D. Albanes, J. Virtamo, S. Weinstein, F. R. Schumacher, E. Giovannucci, W. C. Willett, O. Cussenot, A. Valeri, G. L. Andriole, E. D. Crawford, M. Tucker, D. S. Gerhard, J. F. Fraumeni, R. Hoover, R. B. Hayes, D. J. Hunter, and S. J. Chanock, "Multiple loci identified in a genome-wide association study of prostate cancer," *Nature Genetics*, vol. 40, pp. 310-315, Mar 2008.
- [6] U. Styrkarsdóttir, B. V. Halldorsson, S. Gretarsdóttir, D. F. Gudbjartsson, G. B. Walters, T. Ingvarsson, T. Jonsdóttir, J. Saemundsdóttir, J. R. Center, T. V. Nguyen, Y. Bagger, J. R. Gulcher, J. A. Eisman, C. Christiansen, G. Sigurdsson, A. Kong, U. Thorsteinsdóttir, and K. Stefansson, "Multiple genetic loci for bone mineral density and fractures," *New England Journal of Medicine*, vol. 358, pp. 2355-2365, May 2008.
- [7] Y. Zhang and J. S. Liu, "Bayesian inference of epistatic interactions in case-control studies," *Nature Genetics*, vol. 39, pp. 1167-1173, Sep 2007.
- [8] J. Marchini, P. Donnelly, and L. R. Cardon, "Genome-wide strategies for detecting multiple loci that influence complex diseases," *Nature Genetics*, vol. 37, pp. 413-417, Apr 2005.
- [9] M. Y. Park and T. Hastie, "Penalized logistic regression for detecting gene interactions," *Biostatistics*, vol. 9, pp. 30-50, Jan 2008.
- [10] C. Kooperberg and I. Ruczinski, "Identifying interacting SNPs using Monte Carlo logic regression," *Genetic Epidemiology*, vol. 28, pp. 157-170, Feb 2005.
- [11] M. D. Ritchie, L. W. Hahn, N. Roodi, L. R. Bailey, W. D. Dupont, F. F. Parl, and J. H. Moore, "Multifactor-dimensionality reduction reveals high-order interactions among estrogen-metabolism genes in sporadic breast cancer," *Am J Hum Genet*, vol. 69, pp. 138-47, Jul 2001.
- [12] L. E. Mechanic, B. T. Luke, J. E. Goodman, S. J. Chanock, and C. C. Harris, "Polymorphism Interaction Analysis (PIA): a method for investigating complex gene-gene interactions," *BMC Bioinformatics*, vol. 9, pp. 146, 2008.
- [13] S. H. Chen, J. Sun, L. Dimitrov, A. R. Turner, T. S. Adams, D. A. Meyers, B. L. Chang, S. L. Zheng, H. Gronberg, J. Xu, and F. C. Hsu, "A support vector machine approach for detecting gene-gene interaction," *Genet Epidemiol*, vol. 32, pp. 152-67, Feb 2008.
- [14] J. Kennedy and R. C. Eberhart, "Particle swarm optimization," in *Proceedings IEEE International Conference on Neural Networks*, Perth, Australia, 1995, pp. 1942-1948.
- [15] Y. Shi and R. C. Eberhart, "A modified particle swarm optimizer," in *Proc. of IEEE International Conference on Evolutionary Computation*, Anchorage, AK, USA, 1998, pp. 69-73.
- [16] C. H. Yang, S. W. Tsai, L. Y. Chuang, and Cheng-Huei Yang, "An improved particle swarm optimization with double-bottom chaotic maps for numerical optimization," *Applied Mathematics and Computation*, vol. 219, pp. 260-279, 2012.
- [17] P. D. P. Pharoah, J. Tyrer, A. M. Dunning, D. F. Easton, B. A. J. Ponder, and S. Investigators, "Association between common variation in 120 candidate genes and breast cancer risk," *PLoS Genetics*, vol. 3, pp. 401-406, Mar 2007.