

比較基因表達網絡來尋找疾病相關的變化

謝承翰，鐘文鈺

國立高雄應用科技大學

資訊工程系

afbi1925@gmail.com, wychung@kuas.edu.tw

摘要

為了尋找遺傳標記與疾病間的關聯，一般會以統計方法在資料中找出具有顯著相關性的基因。但在此分析過程中往往會遺失一些對該疾病有影響，但不是主要因素的變異。因此，我們希望能將這些基因集合起來，發掘其整體影響性。特別是複雜疾病通常非單一變異造成，而是一群相互影響的基因產生變化而形成的。為了找出真正與疾病相關的變異，本論文以健康(control)和病人(case)的基因表達(*gene expression profile*)加以分析，分別建造出*gene co-expression network*，找出 control 與 case 間的差異。利用自定的算法篩選出與該疾病有高度相關的基因，讓生物與醫學研究人員參考。本論文以肝癌為例，分數最高的十組基因，功能均與肝癌相關。因此可見研究基因表達網絡的改變，的確可以找出有用的疾病相關基因。複雜疾病的研究很容易忽略影響力較小的變異，我們的方法能將這些被忽略的基因做整體的考量，期待能精準了解疾病成因並且縮短研究與治療的時間。

1 研究動機與研究問題

複雜疾病的產生，往往是因為某些明顯的致病基因以及其它無直接影響的基因群，相互關聯而造成的。以往的研究是先假設某些已知基因為致病因素[1]，但此方式會漏掉其它相關性比較弱的基因。為了彌補此候選策略的缺點，我們希望能夠利用生物資訊方法，偵測出以往無法找到的致病基因。我們利用基因表達網絡(*gene co-expression network*)[2]來觀察病患與健康的人之間的變化。將圖形上的點定義為基因，邊則為兩個基因在表達量上的正關聯性。此關聯性是指基因與基因間的表達量(mRNA的數量，目前常以microarray或next-generation sequencing技術來測量)是否有同時上升或下降的趨勢。基因間的關聯性消失或產生，可能導致某些基因的功能無法作用，進而使生物體出現問題。所以我們假設疾病的產生與基因間的關聯性變化有關。從基因網絡圖中觀察基因關聯性的變化，由變化程度來預測疾病相關基因。研究基因間的交互作用以及蛋白質間的交互作用是現在複雜疾病研究的關鍵。

本篇論文使用皮爾森相關係數做基因間的關聯性計算，再將所得的相關係數，設定閾值

(threshold)製成圖形，得到病患與健康人的基因網絡圖。從中觀察degree、clustering coefficient、shortest path、connected component等圖形特性的不同[3,4]。為了能夠找出哪些基因共同作用而導致某疾病的產生，我們比較case與control的adjacency matrices。然後我們設計出一算分公式來量化基因與基因間相互作用的改變分數。分數越高代表該基因組影響該疾病的可能性越高。透過計分公式計算每個基因配對的分數，篩選分數最高的基因組。往後在研究疾病時，即可從這些高分數的基因著手。最後以肝癌的資料來做測試。我們的方法[5]先以不同的閾值找出各十組基因對，然後再做交集。最後結果有三個基因，均為已知的肝癌相關基因；以最高閾值所得到的十組基因，也與癌症有關。可見考量整體基因連結的改變，將是後基因體學研究的重要方向之一。

2 研究方法與步驟

本篇論文的資料來自 NCBI (National Center for Biotechnology Information, <http://www.ncbi.nlm.nih.gov>)網站的 GEO (Gene Expression Omnibus) 資料庫。健康人的基因表達量資料編號為GSE16921，以及患有肝癌的病患基因表達量資料編號為GSE47197。

2.1 資料前置處理

Case (實驗組)共有124 筆病患資料，共有15,341 個基因。其中有 61 筆是肝癌，其餘為肝炎資料。在本篇研究我們只取肝癌的部分來做分析。下載的資料中擁有 Array ID 和 GSM ID，每個 GSM 欄位為某個病患的基因表達量資料。Array ID 需再從 Microarray 的對應表中查表，才能找出每個表達量所對應的基因。另外，有些基因同時有好幾個測量值，所以我們取其平均值代表該基因的表達量。Control (對照組)共有41筆健康的人的基因表達量資料，共有三個欄位，分別為Gene ID, Gene Name, Expression Value。每筆資料中都含有30,302個基因。

在本篇研究中我們刪除非 NM 以及 NR 開頭的基因(NM與NR為NCBI資料庫中以人工方式決定的mRNA與noncoding RNA序列)。Case 刪除1,026 個基因，control 刪除 736 個基因。由於case 和 control 的資料來自不同測試平台，因此會有一些基因只存在 case 或是 control 中。為了只保留兩者皆有的基因，我們將資料做交叉比對，使交集的基因被保留下來。Case 在這比對過程中

刪除了 720 個基因，control 刪除了 15,971 個基因。最後總共保留了 13,594 個基因。

Control 表達量分布在 0 至 8500，而case 表達量分布在 -12 至 14。由於分布狀況差異過大，因此我們選擇對資料做正規化。正規化的方法有以下幾種，分別為數據中心化、離差標準化、數據正規化、總和標準化和最大值標準化等。本篇論文採用最大值標準化的方法對資料做正規化。其作法是將某一基因的表達量，去除以各自樣本中的最大值，希望藉此可除去影響 control 與 case 數據的系統性因素。

2.2 實驗流程

資料處理及分析步驟簡述如下：

- (1). 將原始資料做處理，留下有用資訊及篩選出 case 與 control 交集的基因。
- (2). 計算每組基因的皮爾森相關係數。
- (3). 藉由閾值將相關係數轉換成圖形。該圖形是以相鄰矩陣(adjacency matrix)的架構呈現。對圖形計算 degree、clustering coefficient、shortest path、connected component等。並分析 case 與 control 的差異。
- (4). 用自訂公式(請參閱2.3節)計算任兩個基因配對在表達網絡中的改變分數。
- (5). 將閾值 0.7、0.8 與 0.9 下找出的基因組列出，再透過網路查詢和比對肝癌基因體資料庫，確認找出的基因是否與肝癌相關。最後用 Cytoscape (<http://www.cytoscape.org/>) 畫出疾病基因網絡圖。

皮爾森相關係數的構想是希望藉由觀察兩個變數間的關係，是同時增長或是同時變小，或者是相反(逆向成長)，來定義兩個基因是否有關聯。在計算前觀察 control 與 case 的資料，發現有些基因的表達量為 0，這情形會影響到皮爾森相關係數的計算。因為當有一個變數的值為 0 時，不管另一個變數的值為何，必定就隨著另一變數的值改變，而非由兩個變數共同決定是成長或下降，亦或反向成長。所以在計算前我們加入一個條件限制，當兩個基因間的表達量任一個為 0，該組不納入計算。例如，A 基因表達量為(0, 0)，B 基因表達量為(1, 0, 10)。首先 A 基因第一個 sample 的表達量為 0，B 基因第一個 sample 表達量為 1。由於 A 基因為 0，因此該組不納入計算。另外一個條件是，如果納入計算的樣本數少於 5 個時，則該組 Pearson Correlation Coefficient 為 0。利用上述的條件我們可以計算出 case 和 control 的相關係數值。

計算完 Pearson Correlation Coefficient 後，再來將相關係數製成相鄰矩陣。首先要決定閾值。我們採用 degree 差距最小的 0.9 做實驗，之後再比較 0.7 與 0.8 的結果，並討論刪除的邊是否影響基因的篩選。觀察 control 與 case 的基因關聯是否有變化，我們先計算常見的圖形參數。首先，計算兩張圖的 degree。Degree為一點與其它點間的連線個數。在基因網絡中的意思代表此基因與其它多少個基因會同時改變其表達量。同時改變表達量的基因可能共同作用在相同的pathway中，因此功能的相關性高。Clustering coefficient [3] 的

意義為某一點其所連接的點間是否相互有連接。以社群網路舉例說明如下：當 A 與 B、C、D 為朋友時，想知道 B、C、D 是否相互也熟識。如果這個值越高代表 A 所連接的點間有某個程度上的相似性(例如這四個人是同班同學)。應用在基因上就是這群基因的緊密程度。相關度越高，代表這群基因所形成的網絡會越接近一個 clique。

2.3 Case 與 control matrices 比較及分數計算

比較 case 和 control 兩個相鄰矩陣，如果發現兩矩陣間個位置呈現不同值，也就是 1/0 或 0/1 的改變，就當作一個變化。例如在 control 中基因 A 對基因 B 的關係為 1，在 case 中基因 A 對基因 B 的關係為 0，這狀況就會算成一個變化。將所有基因兩兩配對做變化量計算，下面的算分公式即由此變化量延伸而出。本篇論文的目的即是假設變化量程度與疾病相關，因此可以利用自定的算分公式找出高程度變化量的基因組合。

$$H_{AB} = a * \sum \frac{b_A || b_B}{N-2} * 1000,$$

$a \in \{1, -1\}$,

$b_A : (X_{A,i})_{case} \oplus (X_{A,i})_{control}$,

$b_B : (X_{B,i})_{case} \oplus (X_{B,i})_{control}$,


$X_{A,i}$: 基因 A 與基因 i 的關聯性,

$X_{B,i}$: 基因 B 與基因 i 的關聯性,

i: 基因編號,

N: 基因總數。

此計分方式分為三個部分，第一部分為基因 A、B 間的矩陣變化量。如果 A、B 基因在 control 與 case 的 adjacency matrices 發生變化則為 1，如無則為 -1。第二部分為 A、B 與其他基因變化量，發生變化則列入計算(任一不同即表示改變)。第三部分乘上 1000 是避免計算出的分數過低。以圖一中 A、B 兩個基因為例，第一部份要觀察兩個基因間是否有改變。在 case 中 A 和 B 的關聯性為 1，在 control 中為 0。因為有改變，所以第一部份為 1。第二部份由於 A 與 B 基因在前面已經做過判斷，因此從 C 基因開始計算。Case 中 A、B 基因對 C 的關聯性為(1,0)，在 control 中對 C 的關聯性為(1,0)。因為(1,0)=(1,0)，所以對 C 的關聯沒發生變化。再來對 D 基因做判斷，在 case 中與 D 的關聯為(1,1)，在 control 中為(1,0)，因為(1,1) ≠ (1,0)，所以列入計算。對 E 基因的關聯，(1,0) = (1,0)，所以不列入計算。因此總共有變化的次數為一。分母為總基因數減2，在此例子中，總基因數為 5。




圖一 比較網絡圖的連結變化。(A)Case, (B) Control。

最後將前二部分計算出來的值乘上1000，避免數值太小，無法區分。計算出來A、B的分數為333。若最後分數為負，則表示這兩個基因配對，在正常人與病患中並無直接改變(但與其它基因的關係可能會有變化)。

3 實驗結果與分析


由於 control 與 case 的原始表達量分布差距過大，為了將差距縮小，我們對原始資料做正規化。經由最大值正規化後，control 與 case 的最大值均控制在1。雖然經由正規化後，數值的分布曲線還是有差異，但總 degree 數的差距有大幅的縮小，分布也比較趨近normal distribution。




圖二 Degree distribution. (A) Control，(B) Case。

Degree 在基因網絡圖上為一點與其他點間的連接(edge)個數。一個基因的 edge 越多，代表與該基因關聯的其它基因就越多。計算control與case中每個基因的degree，並將其分布狀況畫出(圖二)。Control 的 degree 分布範圍從 0 至 1118，其中最高的基因為 NM_001010887。Case 最大值為 296，分布範圍從 0 至 300，其中 degree 最大的基因為 NR_026696。從分布狀況可以知道健康人基因間的關聯數比病患多。將 control 與 case 的 degree 做相減，相差的最大值為 1082，該基因是 NM_001010887。在 13,594 個基因中，有一萬多筆基因的 degree 差距在 0 至 100 間，少數基因差距在 200 以上。

觀察每個基因的相鄰點關聯狀況是否有改變，可以計算 clustering coefficient。Clustering coefficient 統計分布狀況如圖三。



圖三 鄰居相關性的計算(clustering coefficient)。(A) Control，(B) Case。



圖四 健康與病患的基因表達網絡圖比較。

我們起初認為 control 與 case 的 clustering coefficient 的差距，與相差 5 萬條邊有關。所以我們對 case 的圖隨機加了 5 萬條邊，但結果並沒有減少差距。因此猜測 control 多的 5 萬條邊不是隨機的結構。因為隨機增加 5 萬條邊後，case 的 clustering coefficient 值並沒有隨著提高，顯示 control 多的 5 萬條邊可能集中在某些固定的基因，而不是分散開的。

我們假設複雜疾病的發生原因，與基因間的關聯性變化有關。某些基因的表達被抑制或轉譯的蛋白質過量，進而與其他基因的蛋白質發生相互作用，消失或產生的化學反應最後導致疾病產生。因此本篇論文想從高變化量的基因間，篩選與疾病相關的基因。圖四為 control 和 case 的圖做變化量統計，變化量的最大值為 1146，該基因是 NM_001010887(同時也是 degree、degree difference 最高的基因)。

最後做閾值的篩選，選出分數最高的 10 組基因，如表一。其所有分數的平均值為 -11.2529，最大值為 115.583。相對於閾值 0.7、0.8 的結果，閾值 0.9 有較多的基因組在 control 是有相關的。另外隨著閾值提高，篩選出的基因在 control 中有

表一 分數最高的十對基因組。

GeneA	GeneB	degree (control)	degree (case)	shortest path	score
NM_001010887	NM_138364	1118/536	36/163	1/3	115.583
NM_005341	NM_183421	512/767	153/82	1/3	100.427
NM_007105	NM_032775	705/555	87/149	1/3	97.852
NM_025103	NM_173627	583/693	155/93	1/3	95.424
NM_025247	NM_172250	556/898	82/15	1/3	93.658
NM_207307	NR_024368	565/744	77/23	1/2	91.892
NM_001143757	NM_006113	570/606	25/35	2/1	89.244
NM_022550	NM_173082	613/772	73/47	1/3	87.331
NM_017904	NM_018717	508/611	132/187	2/1	86.595
NM_014506	NM_017987	540/645	37/21	1/3	85.565

更多是相互有關聯，但由於某種原因導致這些基因關聯性消失在case中，因此可能使得生物機能無法正常運作。

4 結論

本篇論文主要在探討不同階段的疾病基因網絡圖的差異性。以變化量為研究核心，假設基因間的關聯性的改變與疾病的產生是有相關的，因此希望藉由關聯性的變化程度，再利用算分公式篩選出與疾病相關的基因。由實驗結果我們再進一步確認了找出的基因皆與已知的疾病因子相關，可見以基因間的關聯性變化確實是有效數據。

目前在設計算分公式時只考慮了關聯性變化，未來我們希望能將最短路徑的變化程度也加入算分公式中。另外，在圖形方面我們將利用相關係數計算邊的權重。為了呈現出相關係數越高則基因間的距離越近的概念，可以由倒數、 $1 -$ 基因間的相關係數或 L_k norm等方法來取得邊的權重。將權重關係應用在上述的公式，由關聯性差異加上距離的變化程度，或許能更精確預測疾病基因。同時我們也希望之後可以朝多重疾病程度來進行研究與分析。因為複雜疾病往往有輕微到嚴

重的不同程度。如果可以把不同時期的基因網絡圖，以本文的想法延伸後，做多重比較，相信將能夠找出疾病變化的關鍵基因，以期幫助醫藥的研究進展。

參考文獻

1. The Wellcome Trust Case Control Consortium, Genome-wide association study of 14,000 cases of seven common diseases and 3,000 shared controls, *Nature*, Vol. 447, pp. 661-678, 2007.
2. Bin Zhang and Steve Horvath, A general framework for weighted gene co-expression network analysis, *Statistical Applications in Genetics and Molecular Biology*, Vol. 4(1), article 17, 2005.
3. Albert-László Barabási and Zoltán N. Oltvai, Network biology: understanding the cell's functional organization, *Nature Reviews Genetics*, Vol. 5, pp. 101-113, 2004.
4. Holger Ebel, Lutz-Ingo Mielsch and Stefan Bornholdt, Scale-free topology of e-mail networks, *Physical Review E* 66, 035103, 2002.
5. 謝承翰, 利用基因表達網路尋找與疾病相關的單核苷酸多態性變異, 國立高雄應用科技大學資訊工程學系碩士論文, July, 2014.